

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Exercices ACA – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

21 septembre 2026

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 2. Les principes généraux de la statistique
Les paramètres statistiques élémentaires
Exercices ACA – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

La partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler un fichier C.S.V.
- Faire des sorties graphiques
- Utiliser les bibliothèques `Pandas` (données) et `Matplotlib` (graphiques)
N.B. `pd` et `plt` sont des alias qui remplacent respectivement `pandas` et `matplotlib.pyplot`.
- Calculer des effectifs
- Calculer des fréquences
- Faire des graphiques (diagrammes en bâton et circulaires, et histogrammes)
- Découvrir les méthodes de `Pandas` permettant de calculer les paramètres d'une série statistique
- Tracer une boîte de dispersion

2 Manipulations

1. Dans le dossier `src`, créer un dossier `data` et y introduire le fichier `Produits-alimentaires-2024.csv` disponible dans la Seance-02 du GitHub
N.B. `country_names.xls` et `hs92-6-digit.xls` contient respectivement les métadonnées des codes ISO des territoires et des produits des produits échangés.
2. Dans le dossier `src`, introduire le fichier `main.py` de la séance disponible dans la Seance-02 du GitHub
3. Ouvrir le fichier `main.py` dans votre éditeur de code (Notepad++ ou VS Code)
4. Repérer l'instruction `with`. Elle permet par l'intermédiaire d'une variable appelée `fichier` de lire le fichier C.S.V. grâce à la méthode `read_csv(...)` de la bibliothèque `Pandas`.
N.B. Bien que `Pandas` puisse lire les fichiers Excel, il faut vous habituer à utiliser des formats textuels comme le format C.S.V.
5. Afficher sur le terminal exécutant le conteneur la variable `contenu` avec la méthode de `Pandas DataFrame(...)`
6. Calculer avec la fonction native `len(...)` le nombre de lignes et de colonnes du tableau de données et les afficher sur le terminal
7. Afficher sur le terminal le nom des colonnes, c'est-à-dire la première ligne avec la méthode `Pandas head()`
8. Faire le point sur la nature statistique des variables en utilisant le lien vers les métadonnées fourni en commentaire. Faire une liste sur le type de chaque colonne (`int`, `float`, `str` ou `bool`).
9. À l'aide du nom des colonnes affiché, sélectionner les exportations et les importations en tonnes
10. Calculer les effectifs totaux des exportations et des importations pour chaque territoire. Afficher le résultat sur le terminal. Normalement, vous devez obtenir deux valeurs identiques.
Attention! Pour effectuer le calcul, il faut supprimer les valeurs "-" des deux colonnes. Il faut par conséquent imbriquer une boucle et une condition afin de ne compter que les nombres.
11. À l'aide de `Matplotlib` et de la boucle imbriquée que vous devez compléter, faire des diagrammes en barres avec le volume total des exportations et des importations en dollars courants (USD) pour chaque territoire référence. Créer les fichiers images des diagrammes.
 - a. Créer un sous-dossier `img` dans le dossier `src`.
 - b. Sélectionner les colonnes `origin_id`, `export_val` et `import_val`. Les mettre en paramètres de la fonction `listedesterritoires( code du territoire, exportations, importations )` (bien respect l'ordre indiqué sinon la fonction calculera n'importe quoi). Cette fonction calcule la valeur totale des exportations et des importations en dollars courants (USD).

c. Construire la liste des territoires

Indice. Utiliser la méthode native `append(...)`

d. Sélectionner chaque territoire de référence avec une boucle et compter la somme des exportations et des importations.

Indice. Utiliser la méthode Pandas `sum(...)`

e. Construire les diagrammes circulaires avec les données extraites pour chaque territoire de référence, utiliser le code ISO pour titrer vos graphiques, et les sauvegarder dans le dossier `img`

N.B. 1. Vous allez créer de nombreux fichiers. Créer un nouveau sous-dossier pour stocker vos images.

N.B. 2. Privilégier le format `*.png`, qui est un format léger non propriétaire

12. Sélectionner les colonnes contenant des caractères quantitatifs (`distance`, `export USD`, `import USD`, `export ton` et `import ton`)? Ces cinq colonnes contiennent des chaînes de caractères. Avant de lancer n'importe quel calcul, il faut nettoyer chaque colonne avec la fonction `nettoyage(...)` qui prend en paramètre la colonne à nettoyer. Pour vous aider, utiliser une liste permettant de découper les données en fonction du territoire. Vous pouvez utiliser `liste = getliste(...)` qui prend en paramètre la colonne `origin_id`. Créer un nouvel objet Pandas :

```
donnees2titre = ["distance", "export_val_2", "import_val_2",  
                 "export_ton_2", "import_ton_2"]
```

```
donnees2 = pd.DataFrame({donnees2titre[0] : liste des distances  
                        nettoyées, donnees2titre[1] : liste des exportations (USD) nettoyées,  
                        donnees2titre[2] : liste des importations (USD) nettoyées, donnees2titre[3] :  
                        des exportations (tonnes) nettoyées, donnees2titre[4] : liste des impor-  
                        tations (tonnes) nettoyées})
```

Il faut remplacer les expressions en italique par le nom de vos listes. À l'aide de la boucle imbriquée à compléter, calculer sous la forme d'une liste :

- les moyennes de chaque colonne avec la bonne méthode de Pandas ;
- les médianes de chaque colonne avec la bonne méthode de Pandas ;
- les modes de chaque colonne avec la bonne méthode de Pandas ;
- l'écart type de chaque colonne avec la bonne méthode de Pandas ;
- l'écart absolu à la moyenne de chaque colonne avec la bonne méthode de Pandas ;
- l'étendue de chaque colonne.

N.B. 1. Utiliser la méthode de la valeur absolue `abs()` disponible dans Numpy

N.B. 2. Utiliser les méthodes `min()` et `max()` disponibles dans Pandas

En utilisant la méthode `round()` de Pandas, arrondir tous les paramètres à deux décimaux.

13. Afficher la liste des paramètres sur le terminal

14. Calculer les distances interquartile et interdécile de chaque colonne quantitative avec la méthode `quantile()` dans `Pandas`?
N.B. Vous pouvez utiliser la boucle précédente pour calculer les deux distances inter-quantiles.
15. À l'aide de `Matplotlib` et d'une boucle, faire des boîtes à moustache de chaque colonne quantitative. Stocker les résultats dans un dossier `img`.
Attention! Vous devez nommer les fichiers avec d'autres noms que ceux des diagrammes circulaires créés précédemment.
16. Dans le dossier `src`, introduire le dossier `data` le fichier `restaurants-paris-2023.csv` disponible dans le dossier `data` de la Seance-02 du `GitHub`, et le télécharger dans votre dossier `data`
N.B. Le fichier `BDCOM.pdf` contient les métadonnées de la base de données à utiliser.
17. Sélectionner la colonne `surf` et écrire un algorithme pour catégoriser et dénombrer le nombre de restaurants ayant une surface comprise :
 - entre 0 et 300 m² ou $]0, 300]$ (code 1);
 - entre 300 et 1 000 m² ou $]300, 1000]$ (code 2);
 - supérieur ou égal 1 000 m² ou $]1000, +\infty[$ (code 3).

Vous concevrez un organigramme pour expliquer votre solution. L'objectif de cette dernière question est d'apprendre à catégoriser des variables quantitatives.

Je rappelle la différence entre un diagramme en bâtons et un histogramme. Le premier sert à représenter des données, le second, à représenter une distribution statistique. Cela signifie sur la totalité des surfaces des rectangles vaut 1 (cf. cours sur les distributions).

3 Bonus

Sans remarque pour vous aider (conditions réelles), refaire les diagrammes circulaires dans un dossier `img2` en vous aidant du fichier `country_names.xls` remplacer les codes ISO dans le titre des graphiques par le véritable nom du territoire.

Dans des dossiers `csv` et `xlsx`, sortir les listes calculées avec la bonne méthode `Pandas` au format `C.S.V.` et `Excel`. N'oubliez pas de titrer les colonnes et les lignes de vos sorties si nécessaire.

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 3. Les distributions statistiques

Exercices ACA – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

1 Objectifs

- Savoir afficher une distribution statistique. Ce savoir est utilisé pour comparer une distribution observée avec une distribution théorique.

2 Manipulations

1. Utiliser des méthodes `scipy.stats` ou écrire une fonction (informatique) qui vous permettra de visualiser et d'enregistrer dans un dossier `img` :
 - les distributions statistiques de variables discrètes suivantes :
 - la loi de Dirac ;
 - la loi uniforme discrète ;
 - la loi binomiale ;
 - la loi de Poisson ;
 - la loi de Zipf-Mandelbrot.
 - les distributions statistiques de variables continues suivantes :
 - la loi de Poisson ;
 - la loi normale ;

- la loi log-normale ;
- la loi uniforme ;
- la loi du χ^2 ;
- la loi de Pareto.

2. Faire des fonctions (informatiques) pour calculer la moyenne et l'écart type des distributions précédentes.

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 4. Les statistiques inférentielles

Exercices ACA – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

14 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler harmonieusement les fonctions natives avec les méthodes Pandas
- Comprendre les trois théories permettant de valider un résultat en analyse de données

2 Manipulations

N.B. Il est très compliqué de trouver des données « réelles ». La plupart d'entre elles ne sont pas publiées. Il faut vous approprier les trois méthodes pour bien comprendre leur intérêt. De fait, les données utilisées sont obtenues par simulation aléatoire. Comme vous l'avez lu dans le topo de la séance, les méthodes sont quasiment infinies.

1. Théorie de l'échantillonnage

Problème à résoudre. Vous réalisez une enquête d'opinion. On suppose que la population mère est composée de 2 185 individus. Si vous leur posez une question quelconque, nécessitant une opinion tranchant de type : « Pour », « Contre » ou « Sans opinion ». On suppose que, pour la population mère, il existe 852 personnes « Pour », 911 personnes « Contre » et 422 personnes « Sans opinion ».

Exercice simulant une situation réelle. Vous n’avez pas accès à la totalité de l’information précédente. Ici, on parle de 2 185 individus, mais imaginez que votre population soit celle de la France entière ou du monde. Vous n’avez pas accès à ce que pense tout le monde. Il faut de fait l’échantillonner. Avec des outils de simulation, il est facile de générer 100 échantillons. aléatoires.

- Dans le dossier `src`, introduire le dossier `data` le fichier `Echantillonnage-100-Echantillons.csv` disponible dans la Seance-04 du GitHub
- Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l’adresse et le nom du fichier. Le fichier contient le résultat d’un tirage au hasard sans remise dans la population initiale de 100 échantillons. Sur chaque ligne, il est compté le nombre d’individus ayant telle ou telle opinion.
- Pour chaque colonne, calculer la moyenne obtenue. Le nombre de personnes devant être entier, il faut arrondir votre calcul avec aucune décimale en respectant la règle de l’arrondi avec la fonction native `round()`.
- Pour comparer l’échantillon avec sa population mère, il faut calculer les fréquences. Pour ce, calculer la somme des trois moyennes obtenues, puis diviser ce résultat à l’ensemble de vos moyennes. Calculer également suivant le même principe les fréquences de la population mère afin de comparer les deux résultats. Arrondir les fréquences obtenues à deux décimales.
- Vous devez constater un écart entre les valeurs observées en moyennant les échantillons et les valeurs réelles de la population mère. Calculer l’intervalle de fluctuation de chacune des fréquences à un seuil de 95 %, soit $z_C = 1,96$.
- Dans votre rapport, expliquer le lien entre l’intervalle de fluctuation et les valeurs réelles de la population mère. Que pouvez-vous en conclure par rapport aux échantillons utilisés pour le calcul ?

2. Théorie de l’estimation

Problème à résoudre. Dans le cas d’espèce, et c’est un des cas les plus fréquents en sciences humaines et sociales, on ne possède qu’un échantillon de la population mère. Comment avoir confiance en lui ? Ici, la méthode consiste à construire des intervalles de confiance.

- Prendre le premier échantillon de la liste précédente en utilisant la méthode `Pandas.iloc(0)`, le paramètre 0 correspondant à votre première ligne de données. Il faudra utiliser des fonctions natives, donc convertissez l’objet `Pandas` en castant une `list()`.
- Calculer la somme de la ligne, puis comme avec le cas précédent, les fréquences en utilisant l’effectif total de l’échantillon isolé.
- L’intervalle de confiance ne dépend que de la taille de l’échantillon, c’est-à-dire la somme précédente. Calculez cet intervalle pour chaque opinion.

- Dans votre rapport, vous interpréterez le résultat obtenu et vous le comparerez avec le résultat précédent.

N.B. N'hésitez pas à comparer le résultat avec plusieurs lignes de l'échantillon afin de valider votre jugement.

3. Théorie de la décision

Problème à résoudre. Intervalles de fluctuation ou intervalles de confiance peuvent être insuffisants pour valider un résultat. En fonction de la nature des variables (quantitatives ou qualitatives), les statisticiens ont inventé et inventent encore de nombreux tests statistiques. Le test de Shapiro-Wilks permet de tester si une distribution suit la loi normale.

- Vous disposez de deux fichiers `Loi-normale-Test-1.csv` et `Loi-normale-Test-2.csv`. Il s'agit d'une série de nombres aléatoires traduisant une distribution statistique. En utilisant la méthode de `scipy.stats.shapiro()`. Laquelle est une distribution normale ?
- Vous expliquerez dans votre rapport pourquoi.

N.B. Il vous faudra essentiellement connaître les types de tests en fonction des situations.

3 Bonus

Lors du test de la décision, l'une des lois n'est pas normale. En vous aidant de la séance précédente, quelle est sa distribution ?

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 5. La statistique d'ordre des variables qualitatives

Exercices ACA – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

20 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler des fonctions locales et comprendre la nécessité de factoriser son code en une liste de fonctions ou de procédures exécutant une tâche unique
- Créer des fonctions locales spécifiques au traitement d'un problème
- Comprendre l'analyse de variables qualitatives ordinales

2 Manipulations

1. Dans le dossier `src`, introduire le dossier `data` le fichier `classement-restaurants-paris-2023-par-enseignes.csv` disponible dans la `Seance-05` du `GitHub`
2. Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l'adresse et le nom du fichier.
3. Isoler la colonne `Nombre d'établissement`.

4. Ordonner la liste obtenue avec la fonction locale `ordreDecroissant()` proposée. Elle prend en paramètre une liste.
5. Visualiser la loi rang-taille en créant une image de sortie.
6. L'image obtenue est illisible. Il vous faut convertir les axes en logarithme. Pour ce, utiliser la fonction locale `conversionLog()` proposée. Elle prend en paramètre une liste.
7. Est-il possible de faire un test sur les rangs ? (mettre votre réponse sous la forme d'un commentaire dans le fichier)
8. Dans le dossier `src`, introduire le dossier `data` le fichier `Le-Monde-HS-Etats-du-monde-2007-2026.csv` disponible dans la Seance-05 du GitHub
9. Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l'adresse et le nom du fichier.
10. Isoler les colonnes « État », « Pop 2007 », « Pop 2026 », « Densité 2007 » et « Densité 2026 »
11. En utilisant la fonction locale `ordrePopulation()`, ordonner de manière décroissante les listes « Pop 2007 », « Pop 2026 », « Densité 2007 » et « Densité 2026 ». Elle prend en paramètres la liste à ordonner et la liste des États.
12. En utilisant la fonction locale `classementPays()`, préparer la comparaison des listes sur la population et la densité. Elle prend en paramètres les deux classements (pour le nombre d'habitants et pour la densité) obtenus avec `ordrePopulation()`. En classant le résultat avec la méthode `sort()`, vous obtenez une liste avec deux colonnes ordonnées par rapport au classement de 2007.
13. Isoler les deux colonnes sous la forme de liste différentes en utilisant une boucle
14. Dans la bibliothèque `scipy.stat`, utiliser les méthodes `spearmanr()` et `kendalltau()` pour calculer le coefficient de corrélation des rangs et la concordance des rangs. Les deux méthodes prennent en paramètres les deux classements que vous avez respectivement calculés pour le nombre d'habitants et pour la densité. Vous commenterez ce résultat dans votre rapport d'activité.

2.1 Bonus

Afin de vous faciliter la vie, car les codes n'étaient pas simples à trouver, vous avez utilisé des fonctions que j'ai créées. C'est l'un des bonus qui peut vous rapporter le plus de points. Vous devrez créer des fonctions locales permettant de calculer rapidement une analyse de rangs.

Pour les restaurants, vous avez à votre disposition une extraction des données du fichier `restaurants-paris-2017`. Les enseignes n'étant pas présentes, elles ont été reconstituées en comparant les adresses postales entre la liste des restaurants en 2017 et la liste des restaurants en 2023. Le résultat est le fichier

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 6. Régression et corrélation statistique de deux variables

Exercices ACA – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

21 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Apprendre à gérer les données censurées
- Manipulation des outils de la régression et de la corrélation simple

2 Manipulations

Existe-t-il un lien entre la valeur des importations et des exportations en dollars courants par territoire au niveau des produits alimentaires ?

1. Ouvrir le fichier `Produits-alimentaires-vs-autres.csv`. Isoler chaque colonne `Année`, `Code-ISO`, `Total-export-alimentaire-USD`, `Total-import-alimentaire-USD`, `Total-export-autres-USD`, `Total-import-autres-USD`, `Total-export-USD` et `Total-import-USD`. Ainsi, le fichier regroupe deux agrégats de flux par territoire : (a) les flux concernant les produits alimentaires en dollars courants (`Total-export-alimentaire-USD`

et `Total-import-alimentaire-USD`); (b) les flux concernant les produits non alimentaires (`Total-export-autres-USD` et `Total-import-autres-USD`). Il contient la somme des deux (`Total-export-USD` et `Total-import-USD`).

2. On considère qu'il existe un lien entre importations et exportations. Il est à noter que chaque colonne peut jouer le rôle de la variable explicative de l'autre. Calculer une régression linéaire simple entre chaque paire de colonnes avec la méthode `scipy.stats.linregress(x, y)` prenant en arguments `x`, les importations comme variable à expliquer, et `y`, les exportations comme variable explicative. Que se passe-t-il au niveau des résultats si vous inversez les `x` et `y` ?
3. Calculer la corrélation simple entre chaque paire de colonnes. Vous pouvez utiliser indifféremment les bibliothèques `Pandas` ou `Scipy`.
4. Faire trois graphiques de synthèse permettant de visualiser les trois droites de régression obtenues.
5. Dans votre rapport, vous commenterez votre résultat sous la forme d'un ou deux paragraphes.

3 Bonus

Vous avez écrit un algorithme permettant de traiter deux colonnes se rapportant à la même année. Écrivez un algorithme permettant de généraliser votre résultat à toutes les années de 1995 à 2024 grâce aux fichiers fournis. N'oubliez pas d'organiser correctement vos fichiers de sortie.

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 7. Étude de deux variables qualitatives

Exercices ACA – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

21 septembre 2026

1 Objectifs

- Manipuler des variables qualitatives avec Python
- Calculer les principaux indicateurs de liaison avec la bibliothèque `scipy.stats`

2 Manipulations

À partir du fichier `restaurants-paris-2023.csv`, le fichier `arrondissements-enseignes.csv` a été construit. Il s'agit d'un tableau couplant en ligne, les arrondissements de Paris, et en colonne, les enseignes connues.

La fonction `tableauDeContingence()` permet de créer un tableau de contingence prenant en arguments la colonne des arrondissements et un dictionnaire composé du nom des colonnes en clé et de la colonne associée en valeur. J'ai simplifié le tableau initial. Si vous avez compris le cours, vous avez compris qu'il s'agit d'un tableau de contingence entre deux variables qualitatives. Normalement, vous le calculerez un tableau croisé dynamique avec la méthode de la bibliothèque `Pandas`, `crosstab()`. Toutefois, il arrive souvent, comme dans le cas présent, que le tableau de contingence n'arrive pas être calculé. De fait, on ne peut pas utiliser les méthodes de `Pandas` directement, notamment pour calculer les marges.

1. Calculer les marges des lignes et des colonnes en vous servant des fonctions locales `sommeDesColonnes()` et `sommeDesLignes()`.

2. Faire une condition vérifiant si le total des marges des lignes et le total des marges des colonnes est identique.
3. Faire un test d'indépendance du χ^2 à partir de la bibliothèque `scipy.stats` et de sa méthode `chi2_contingency()`. Existe-t-il une liaison ?
4. Calculer l'intensité de liaison ϕ^2 de Pearson à partir des résultats précédents.
5. Dans votre rapport, faire un court paragraphe expliquant vos résultats.

3 Bonus

Les points bonus sont attribués par rapport aux chapitres d'approfondissement.

Avec le fichier `Echantillonnage-100-Echantillons.csv`, faire une analyse ANOVA.

Avec le tableau de données, calculer une A.F.C. et faisant le commentaire.