

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Exercices EnviTERR – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

15 septembre 2026

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 4. Les statistiques inférentielles

Exercices EnviTERR – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

14 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler harmonieusement les fonctions natives avec les méthodes Pandas
- Comprendre les trois théories permettant de valider un résultat en analyse de données

2 Manipulations

N.B. Il est très compliqué de trouver des données « réelles ». La plupart d'entre elles ne sont pas publiées. Il faut vous approprier les trois méthodes pour bien comprendre leur intérêt. De fait, les données utilisées sont obtenues par simulation aléatoire. Comme vous l'avez lu dans le topo de la séance, les méthodes sont quasiment infinies.

1. Théorie de l'échantillonnage

Problème à résoudre. Vous réalisez une enquête d'opinion. On suppose que la population mère est composée de 2 185 individus. Si vous leur posez une question quelconque, nécessitant une opinion tranchant de type : « Pour », « Contre » ou « Sans opinion ». On suppose que, pour la population mère, il existe 852 personnes « Pour », 911 personnes « Contre » et 422 personnes « Sans opinion ».

Exercice simulant une situation réelle. Vous n’avez pas accès à la totalité de l’information précédente. Ici, on parle de 2 185 individus, mais imaginez que votre population soit celle de la France entière ou du monde. Vous n’avez pas accès à ce que pense tout le monde. Il faut de fait l’échantillonner. Avec des outils de simulation, il est facile de générer 100 échantillons. aléatoires.

- Dans le dossier `src`, introduire le dossier `data` le fichier `Echantillonnage-100-Echantillons.csv` disponible dans la Seance-04 du GitHub
- Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l’adresse et le nom du fichier. Le fichier contient le résultat d’un tirage au hasard sans remise dans la population initiale de 100 échantillons. Sur chaque ligne, il est compté le nombre d’individus ayant telle ou telle opinion.
- Pour chaque colonne, calculer la moyenne obtenue. Le nombre de personnes devant être entier, il faut arrondir votre calcul avec aucune décimale en respectant la règle de l’arrondi avec la fonction native `round()`.
- Pour comparer l’échantillon avec sa population mère, il faut calculer les fréquences. Pour ce, calculer la somme des trois moyennes obtenues, puis diviser ce résultat à l’ensemble de vos moyennes. Calculer également suivant le même principe les fréquences de la population mère afin de comparer les deux résultats. Arrondir les fréquences obtenues à deux décimales.
- Vous devez constater un écart entre les valeurs observées en moyennant les échantillons et les valeurs réelles de la population mère. Calculer l’intervalle de fluctuation de chacune des fréquences à un seuil de 95 %, soit $z_C = 1,96$.
- Dans votre rapport, expliquer le lien entre l’intervalle de fluctuation et les valeurs réelles de la population mère. Que pouvez-vous en conclure par rapport aux échantillons utilisés pour le calcul ?

2. Théorie de l’estimation

Problème à résoudre. Dans le cas d’espèce, et c’est un des cas les plus fréquents en sciences humaines et sociales, on ne possède qu’un échantillon de la population mère. Comment avoir confiance en lui ? Ici, la méthode consiste à construire des intervalles de confiance.

- Prendre le premier échantillon de la liste précédente en utilisant la méthode `Pandas.iloc(0)`, le paramètre 0 correspondant à votre première ligne de données. Il faudra utiliser des fonctions natives, donc convertissez l’objet `Pandas` en castant une `list()`.
- Calculer la somme de la ligne, puis comme avec le cas précédent, les fréquences en utilisant l’effectif total de l’échantillon isolé.
- L’intervalle de confiance ne dépend que de la taille de l’échantillon, c’est-à-dire la somme précédente. Calculez cet intervalle pour chaque opinion.

- Dans votre rapport, vous interpréterez le résultat obtenu et vous le comparerez avec le résultat précédent.

N.B. N'hésitez pas à comparer le résultat avec plusieurs lignes de l'échantillon afin de valider votre jugement.

3. Théorie de la décision

Problème à résoudre. Intervalles de fluctuation ou intervalles de confiance peuvent être insuffisants pour valider un résultat. En fonction de la nature des variables (quantitatives ou qualitatives), les statisticiens ont inventé et inventent encore de nombreux tests statistiques. Le test de Shapiro-Wilks permet de tester si une distribution suit la loi normale.

- Vous disposez de deux fichiers `Loi-normale-Test-1.csv` et `Loi-normale-Test-2.csv`. Il s'agit d'une série de nombres aléatoires traduisant une distribution statistique. En utilisant la méthode de `scipy.stats.shapiro()`. Laquelle est une distribution normale ?
- Vous expliquerez dans votre rapport pourquoi.

N.B. Il vous faudra essentiellement connaître les types de tests en fonction des situations.

3 Bonus

Lors du test de la décision, l'une des lois n'est pas normale. En vous aidant de la séance précédente, quelle est sa distribution ?

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 5. La statistique d'ordre des variables
qualitatives
Exercices EnviTERR – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler des fonctions locales et comprendre la nécessité de factoriser son code en une liste de fonctions ou de procédures exécutant une tâche unique
- Créer des fonctions locales spécifiques au traitement d'un problème
- Comprendre l'analyse de variables qualitatives ordinales

2 Manipulations

1. Dans le dossier `src`, introduire le dossier `data` le fichier `island-index.csv` disponible dans la `Seance-05` du GitHub
2. Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l'adresse et le nom du fichier.
3. Isoler la colonne « Surface (km²) » et lui ajouter dans cette liste :
 - Asie / Afrique / Europe : 85 545 323 km²

- Amérique : 37 856 841 km²
- Antarctique : 7 768 030 km²
- Australie : 7 605 049 km²

Attention ! Il faudra forcer le typage en castant les valeurs en `float()`.

Attention ! Ne mettez pas l'unité de mesure dans la liste informatique

4. Ordonner la liste obtenue avec la fonction locale `ordreDecroissant()` proposée. Elle prend en paramètre une liste.
5. Visualiser la loi rang-taille en créant une image de sortie.
6. L'image obtenue est illisible. Il vous faut convertir les axes en logarithme. Pour ce, utiliser la fonction locale `conversionLog()` proposée. Elle prend en paramètre une liste.
7. Est-il possible de faire un test sur les rangs ? (mettre votre réponse sous la forme d'un commentaire dans le fichier)
8. Dans le dossier `src`, introduire le dossier `data` le fichier `Le-Monde-HS-Etats-du-monde-2007-2026.csv` disponible dans la Seance-06 du GitHub
9. Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l'adresse et le nom du fichier.
10. Isoler les colonnes « État », « Pop 2007 », « Pop 2026 », « Densité 2007 » et « Densité 2026 »
11. En utilisant la fonction locale `ordrePopulation()`, ordonner de manière décroissante les listes « Pop 2007 », « Pop 2026 », « Densité 2007 » et « Densité 2026 ». Elle prend en paramètres la liste à ordonner et la liste des États.
12. En utilisant la fonction locale `classementPays()`, préparer la comparaison des listes sur la population et la densité. Elle prend en paramètres les deux classements (pour le nombre d'habitants et pour la densité) obtenus avec `ordrePopulation()`. En classant le résultat avec la méthode `sort()`, vous obtenez une liste avec deux colonnes ordonnées par rapport au classement de 2007.
13. Isoler les deux colonnes sous la forme de liste différents en utilisant une boucle
14. Dans la bibliothèque `scipy.stat`, utiliser les méthodes `spearmanr()` et `kendalltau()` pour calculer le coefficient de corrélation des rangs et la concordance des rangs. Les deux méthodes prennent en paramètres les deux classements que vous avez respectivement calculés pour le nombre d'habitants et pour la densité. Vous commenterez ce résultat dans votre rapport d'activité.

2.1 Bonus

Afin de vous faciliter la vie, car les codes n'étaient pas simples à trouver, vous avez utiliser des fonctions que j'ai créées. C'est l'un des bonus qui peut vous rapporter le plus de points.

Vous devrez créer des fonctions locales permettant de calculer rapidement une analyse de rangs.

Pour les îles, proposer un algorithme et un code pour comparer le classement obtenu avec les surfaces et un autre classement obtenu avec les traits de côte en utilisant le coefficient de corrélation et la concordance des rangs.

Pour la population mondiale, 1. factoriser le code d'analyse des classements sous la forme d'une fonction renvoyant les coefficients de corrélation des rangs et la concordances des rangs ; 2. faire un algorithme et un code permettant d'analyser la concordance des rangs de l'ensemble des classements annuels de 2007 à 2026.

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 6. Régression et corrélation statistique de
deux variables
Exercices EnviTERR – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Apprendre à gérer les données censurées
- Manipulation des outils de la régression et de la corrélation simple

2 Manipulations

Existe-t-il un lien entre le produit intérieur brut (P.I.B.) et la consommation énergétique ?
Le fichier de données que vous allez analyser est issu des données de la Banque mondiale (<https://donnees.banquemondiale.org/>). Il regroupe deux jeux de données :

- le P.I.B. de chaque territoire (étatique ou non) de 1962 à 2024 en dollars courants (c'est-à-dire sans prendre en compte l'inflation) ;
- la consommation énergétique en kilogrammes équivalent pétrole de 1962 à 2024.

J'ai opéré les principales opérations de nettoyage, et fais en sorte que vous ayez le moins de difficultés possibles à obtenir le résultat recherché.

1. Il existe un décalage entre les données du P.I.B. et de la consommation énergétique. Il faut de fait sélectionner en utilisant Pandas les colonnes `PIB_2022` et `Utilisation_d_energie_2022` dans le fichier `pib-vs-energie.csv`.
2. Malheureusement, plusieurs données sont censurées. Il vous faut créer un algorithme qui ne sélectionnera que les couples complets, c'est-à-dire ayant une valeur pour le P.I.B. et la consommation énergétique. Dit autrement, vous devez exclure les données manquantes (aucune valeur pour l'un et l'autre), et les données partielles (une donnée chez l'une, mais pas l'autre).
3. On considère que la variable explicative est la consommation énergétique et la variable à expliquer est le P.I.B. Calculer une régression linéaire simple entre les deux colonnes avec la méthode `scipy.stats.linregress(x, y)` prenant en arguments `x`, la variable à expliquer, et `y`, la variable explicative.
4. Calculer la corrélation simple entre les deux colonnes. Vous pouvez utiliser indifféremment les bibliothèques Pandas ou Scipy.
5. Faire un graphique de synthèse permettant de visualiser la droite de régression obtenue.
6. Dans votre rapport, vous commenterez votre résultat sous la forme d'un ou deux paragraphes.

3 Bonus

Vous avez écrit un algorithme permettant de traiter deux colonnes se rapportant à la même année. Écrivez un algorithme permettant de généraliser votre résultat à toutes les années de 1962 à 2022. N'oubliez pas d'organiser correctement vos fichiers de sortie.

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 7. Étude de deux variables qualitatives

Exercices EnviTERR – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

15 septembre 2026

1 Objectifs

- Manipuler des variables qualitatives avec Python
- Calculer les principaux indicateurs de liaison avec la bibliothèque `scipy.stats`

2 Manipulations

Vous allez utiliser les données 2006-2020 de l'Union nationale des industries de carrières et matériaux de construction (U.N.I.C.E.M.) et de l'Union nationale des producteurs de granulats (U.N.P.G.) concernant la relation entre le lieu de production et les années de production <https://www.unicem.fr/services-aux-entreprises/documentation/statistiques>. Si vous avez compris le cours, vous avez compris qu'il s'agit d'un tableau de contingence avec deux variables qualitatives. Normalement, vous le calculerez un tableau croisé dynamique avec la méthode de la bibliothèque Pandas, `crosstab()`. Toutefois, il arrive souvent, comme dans le cas présent, que le tableau de contingence n'ait pas à être calculé. De fait, on ne peut pas utiliser les méthodes de Pandas directement, notamment pour calculer les marges.

Au cas où vous ne connaissez pas ce que sont les granulats, vous pouvez lire le flyer de l'U.N.I.C.E.M. fournit dans les données `UNPG-2017-Tout-savoir-sur-les-granulats.pdf`.

Après avoir chargé les données contenues dans le fichier `France-Granulats-2006-2020-par-region.csv`, appliquer la fonction locale

`tableauDeContingence(..., ...)` qui prend deux paramètres : la colonne de référence, ici, celle des régions, et un dictionnaire contenant le nom des autres colonnes et leurs données.

1. Calculer les marges des lignes et des colonnes en vous servant des fonctions locales `sommeDesColonnes()` et `sommeDesLignes()`.
2. Faire une condition vérifiant si le total des marges des lignes et le total des marges des colonnes est identique.
3. Faire un test d'indépendance du χ^2 à partir de la bibliothèque `scipy.stats` et de sa méthode `chi2_contingency()`. Existe-t-il une liaison ?
4. Calculer l'intensité de liaison ϕ^2 de Pearson à partir des résultats précédents.
5. Dans votre rapport, faire un court paragraphe expliquant vos résultats.

3 Bonus

Les points bonus sont attribués par rapport aux chapitres d'approfondissement.

Avec le fichier `Echantillonnage-100-Echantillons.csv`, faire une analyse ANOVA.

Avec le tableau de données, calculer une A.F.C. et faisant le commentaire.

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 8. Les méthodes statistiques multivariées
descriptives
Exercices EnviTERR – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Apprendre à utiliser la bibliothèque `Scikit-learn`
- Apprendre à utiliser la bibliothèque `Prince`

2 Manipulations

1. Faire une A.C.P. avec le fichier `france-temperatures.csv`.
 - a. Récupérer les données.
 - b. Isoler la colonne des individus "Villes" et isoler les colonnes numériques en utilisant la méthode `drop(columns = ["Villes"])`
 - c. Centrer-réduire les données numériques en utilisant `StandardScaler()` et `fit_transform()`.
 - d. Faire une A.C.P. avec 12 facteurs sur les données numériques centrées-réduites avec l'objet `PCA` et sa méthode `fit()`. L'afficher sur la console. Que constatez-vous ?

- e. Afficher la variance expliquée, la variance expliquée en pourcentage et calculer les valeurs propres.
- f. En utilisant `Pandas` et sa méthode `DataFrame`, afficher le résultat de l'A.C.P.
- g. Calculer les coordonnées des individus et faire un graphique permettant de créer l'image du *mapping* des individus (les deux premiers facteurs) dans un dossier `img`.
- h. Calculer et afficher la contribution des individus aux facteurs. Calculer et afficher la qualité de la projection des individus (les cosinus carrés). Qu'en concluez-vous ?
- i. Calculer les coordonnées des variables et créer l'image du cercle de corrélation associé dans un dossier `img`.

N.B. Vous pouvez vous aider du site <https://fxjollois.github.io/cours-2019-2020/lp-iot-python-ds/seance2-ACP-classif.html>.

2. Faire une A.C.M. avec le fichier `chiens.csv`.
 - a. Récupérer les données.
 - b. Isoler la colonne `Race` (les individus) et isoler dans un tableau `Pandas` les colonnes `Taille`, `Poids`, `Vitesse`, `Intelligence`, `Affection`, `Agressivité`, `Fonction`, `Origine` (les variables).
 - c. Transformer le tableau des variables en tableau disjonctif complet (T.D.C.) en utilisant la méthode `Pandas get_dummies()`
 - d. L'A.C.M. se calcule avec la bibliothèque `Prince` à partir du T.D.C. calculé par `Pandas` et dans ce format avec les méthodes `MCA` et `fit()`. Calculer une A.C.M. à huit facteurs.
 - e. Calculer les valeurs propres.
 - f. Calculer les coordonnées des lignes et des colonnes des variables.
 - g. Créer une image du *mapping* des deux premiers facteurs dans un dossier `img`.
 - h. Calculer les qualités des données des lignes et des colonnes (les cosinus carrés).

3 Bonus

Faire une C.A.H. à partir des résultats de l'A.C.P. étudiée.

Attention! Il faudra vous documenter au-delà de la documentation fournie par le `GitHub`.

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 9. Les méthodes statistiques multivariées
explicatives
Exercices EnviTERR – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

Courage, c'est presque fini !

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Apprendre à faire une régression linéaire multiple avec Pandas.
- Apprendre à faire une régression linéaire multiple avec Sklearn.

2 Manipulations

L'exercice est relativement simple. À la différence des méthodes factorielles, ici, il s'agit juste de déterminer des coefficients. De fait, deux séries de données vous seront proposées.

1. Ouvrir le fichier `temperature.csv`. Le fichier contient 33 villes des États-Unis (champ `Ville`). Les individus sont caractérisés par une variable à expliquer `Température_en_janvier` et trois variables explicatives `Latitude` (en degré décimal), `Longitude` (en degré décimal) et `altitude` (en mètre).

- Calculer la corrélation entre les quatre variables avec la méthode `corr()` de Pandas.
 - Afficher les statistiques descriptives avec `describe()` de Pandas.
 - Isoler le champ `Ville` et isoler les données en distinguant `Température_en_janvier`, la variable à expliquer, et `Latitude`, `Longitude` et `altitude`, les variables à expliquer.
 - Avec la bibliothèque `statsmodels.api`, calculer la régression linéaire liant la variable à expliquer avec les variables explicatives.
 - En utilisant les attributs et les méthodes de `statsmodels.api`, calculer les paramètres de la régression linéaires (les coefficients), le coefficient de détermination, le résumé de la régression et les *p-values*.
 - Avec `Scikit-Learn`, isoler les coefficients avec l'attribut `coef_`. Isoler la constante de l'ajustement avec la méthode `intercept_`.
 - Dans votre rapport, commenter et analyser les résultats obtenus.
2. Ouvrir le fichier `geomarketing.csv`. Il s'agit d'un exercice que vous pourriez avoir dans une organisation qui vous emploierait. Il faut expliquer la variable `ca`, le chiffre d'affaires de chaque individu représentant le magasin fictif `Big Bazar`.
- Une A.C.P. a été, au préalable, réalisée sur l'ensemble des variables. Elle a révélé que les variables significatives étaient :
 - `ca`;
 - `surface_totale`;
 - `potentiel_Z20`;
 - `nb_primaire_Z10`;
 - `nb_primaire_Z20`;
 - `nb_gsa_Z10`;
 - `nb_pharmacie_Z5`;
 - `nb_conc2_Z10`;
 - `nb_conc2_Z20`;
 - `P10_POP_Z15`;
 - `P10_MEN_Z10`.
 - Isoler `ca` et isoler les neuf variables significatives.
 - En utilisant les attributs et les méthodes de `statsmodels.api`, calculer les paramètres de la régression linéaires (les coefficients), le coefficient de détermination, le résumé de la régression et les *p-values*.
 - Dans votre rapport, commenter et analyser les résultats obtenus.

3 Bonus

À partir du fichier `geomarketing.csv`, opérer la régression avec la totalité des variables, comparer avec les variables sélectionnées par une A.C.P., et, dans votre rapport, commenter et analyser les résultats obtenus.