

Cours d'analyse de données en géographie
Niveau Master 1 – GEANDO
Support pour les étudiants
Instructions et conseils pour tous les étudiants

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

5 octobre 2026

Devise du cours : « Apprendre pour coder,
coder pour comprendre,
comprendre pour coder,
coder pour apprendre. »

Semaine	Checklist	Fait
1	Bien lire le livret d'accueil et les compléments sur GitHub	
	Suivre la séance de présentation	
	Créer ses comptes GitHub, Docker et Discord	
	Installer les outils sur son P.C. (option, mais vivement recommandé)	
	Commencer à apprendre tout seul le Python	
2	Semaine de pause entre les deux premières séances pour apprendre le Python	
	Constituer les groupes de travail (option)	
	Pour le niveau 2, lire, réviser, comprendre les séances 2 et 3	
	Lire le ou les chapitres d'analyse de données de la séance suivante (GitHub) et vous aidant des questions de cours de la séance (à faire avant chaque cas pratique)	
3	Première mise en pratique Niveau 1 : Principes généraux de la statistique et paramètres statistiques élémentaires Niveau 2 : Statistiques inférentielles	
	Questions	
	Premier dépôt du GitHub	
	Première utilisation de Docker	
	Première utilisation de NotePad++ ou de Visual Studio Code	
	Lire le topo sur les humanités numériques Comprendre le lien entre l'ensemble des cas pratiques et les humanités numériques	
	Début de la rédaction du rapport d'activité	
4	Niveau 1 : Distributions statistiques Niveau 2 : Statistique d'ordre des variables qualitatives	
	Rédiger le rapport d'activité	
5	Niveau 1 : Statistiques inférentielles Niveau 2 : Régression et corrélation statistique entre deux variables	
	Rédiger le rapport d'activité	
6	Niveau 1 : Statistique d'ordre des variables qualitative Niveau 2 : Relations entre deux variables	
	Rédiger le rapport d'activité	
7	Niveau 1 : Régression et corrélation statistique entre deux variables Niveau 2 : Analyse multivariées : les méthodes descriptives	
	Rédiger le rapport d'activité	
8	Niveau 1 : Relations entre deux variables Niveau 2 : Analyse multivariées : les méthodes explicatives	
	Rédiger le rapport d'activité	
9 à 13	Rédiger et rendre le rapport d'activité	

TABLE 1 – Pistes pour organiser votre semestre

Première partie

Pour commencer avec de bonnes bases...

Séance 1

Présentation du contenu du cours et mise en route

Objectifs de la séance

- Présentation des objectifs pédagogiques
- Prise en main de `GitHub`
- Prise en main de `Docker`
- Établissement d'une architecture propre
- Prise en main de `Python` avec `Docker`
- Découverte de `Python`

1.1 Présentation des objectifs pédagogiques

1.1.1 Règles générales du fonctionnement du cours

Avant chaque séance, vous **devez lire** son contenu se trouvant dans ce livret **et** tous les éléments présents sur mon compte ouvert sur la plateforme `GitHub`. L'organisation du cours suit la **logique de la pédagogie inversée**. Chaque séance proposera un exercice d'application sur le contenu que vous aurez lu. Elle ne résumera **jamais** ce que vous n'avez pas lu. Bien entendu, si vous avez des questions, je reste à votre disposition en cours ou par le serveur `Discord` que ce soit **pendant** la durée du module ou **après** lorsque vous manipulerez les données de votre mémoire dans la limite de mes compétences et de mon temps disponible.

Chaque séance se déroulera de la même manière.

1. Vos questions sur ce que vous avez lu
2. Présentation de l'analyse de données du jour
3. Téléchargement des ressources sur `GitHub`
4. Travail en local avec `Python` sous `Docker`

L'ENSEIGNEMENT : TRADITIONNEL vs ACTIF



Suit le programme ✗
 Transmet les savoirs ✗
 Bonnes réponses attendues ✗
 Corrige sans expliquer ✗
 Monologue ✗
 Valorise la rapidité ✗
 Contrôles surprises ✗
 Décourage l'erreur ✗
 Cours magistral ✗
 Finir le programme ✗



Adapte aux élèves ✓
 Fait construire les savoirs ✓
 Raisonnement encouragé ✓
 Utilise l'erreur ✓
 Dialogue ✓
 Valorise la compréhension ✓
 Évaluation continue ✓
 Apprentissage par l'erreur ✓
 Activités variées ✓
 Donner envie d'apprendre ✓



François Giltaire

Les mathématiques, c'est par le jeu !

FIGURE 1.1 – Enseignement traditionnel vs. enseignement actif

Source : LinkedIn

5. Remise des résultats que vous avez obtenus en fin de cours dans un portfolio sur votre compte `GitHub`

Une explication de la plateforme `GitHub` est disponible sur `GitHub`.

— <https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees>

Un contenu détaillé de l'utilisation de `Python` est disponible sur `GitHub`.

— <https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees/tree/main/Python>

Un formulaire mathématique est à votre disposition sur `GitHub`.

— <https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees/tree/main/Formulaire-mathematique>

1.1.2 Calendriers

SCT – Niveau 1

Attention ! Les séances s’alternent tantôt à 10h00-12h00, tantôt à 12h00-14h00.

7 séances :

Séance 1. Mercredi 23 septembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 2. Mercredi 7 octobre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 3. Mercredi 7 octobre 2026 – 12h00-14h00 – Clignancourt : Salle 217

Séance 4. Mercredi 14 octobre 2026 – 12h00-14h00 – Clignancourt : Salle 217

Séance 5. Mercredi 4 novembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 6. Mercredi 25 novembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 7. Mercredi 9 décembre 2026 – 12h00-14h00 – Clignancourt : Salle 217

ACA – Niveau 1

7 séances :

Séance 1. Mardi 30 septembre 2026 – 09h30-11h30 – Institut de géographie : Salle 301

Séance 2. Mardi 13 octobre 2026 – 13h00-15h00 – Institut de géographie : Salle 301

Attention ! Si vous ne pouvez pas venir mardi à cause d’un stage, dans la limite des places disponibles, venez le mercredi 14 octobre 2026 – Clignancourt – Salle 217 – 12h00-14h00. Si vous faites ce choix, le groupe d’accueil ayant déjà eu les explications sur le code vous devrait réaliser les exercices sans ce cours.

Séance 3. Mardi 20 octobre 2026 — 13h00-15h00 – Institut de géographie : Salle 301

Attention ! Si vous ne pouvez pas venir mardi à cause d’un stage, dans la limite des places disponibles, venez le mercredi 21 octobre 2026 – Clignancourt – Salle 217 – 12h00-14h00.

Séance 4. Mardi 3 novembre 2026 – 13h00-15h00 – Institut de géographie : Salle 301

Attention ! Si vous ne pouvez pas venir mardi à cause d’un stage, dans la limite des places disponibles, venez le mercredi 04 novembre 2026 – Clignancourt – Salle 217 – 12h00-14h00.

Séance 5. Mardi 17 novembre 2026 – 14h00-16h00 – Institut de géographie : Salle 301

Attention ! Si vous ne pouvez pas venir mardi à cause d’un stage, dans la limite des places disponibles, venez le mercredi 18 novembre 2026 – Clignancourt – Salle 217 – 12h00-14h00.

Séance 6. Mardi 1^{er} décembre 2026 – 11h00-13h00 – Institut de géographie : Salle 301

Attention ! Si vous ne pouvez pas venir mardi à cause d'un stage, dans la limite des places disponibles, venez le mercredi 02 décembre 2026 – Clignancourt – Salle 217 – 12h00-14h00.

Séance 7. Mardi 8 décembre 2026 – 13h00-15h00 – Institut de géographie : Salle 301

Attention ! Si vous ne pouvez pas venir mardi à cause d'un stage, dans la limite des places disponibles, venez le Mercredi 09 décembre 2026 - Clignancourt - Salle 217 - 12h00-14h00.

Remarque importante 1. Sylvaine Boulanger et moi-même attendons de vous que vous ayez une discipline de fer afin d'être honnête sur votre jour de cours. Il n'y a que 5-7 places le mercredi dans vos groupes d'accueil (SCT ou GéoSUDS).

Remarque importante 2. Vous allez voyager de la salle 217 à la salle 301 sans arrêt. L'usage d'un ordinateur portable personnel est vivement conseillé afin d'effectuer la transition d'une salle à l'autre dans de bonnes conditions.

GéoSUDS – Niveau 1

7 séances :

Séance 1. Mercredi 16 septembre 2026 – 12h00-14h00 – Clignancourt : Salle 217

Séance 2. Mercredi 30 septembre 2026 – 12h00-14h00 – Clignancourt : Salle 217

Séance 3. Mercredi 21 octobre 2026 – 12h00-14h00 – Clignancourt : Salle 217

Séance 4. Mercredi 4 novembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 5. Mercredi 18 novembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 6. Mercredi 25 novembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 7. Mercredi 2 décembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

GEOINT – Niveau 2

7 séances :

Séance 1. Mercredi 16 septembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 2. Mercredi 30 septembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 3. Mercredi 14 octobre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 4. Mercredi 21 octobre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 5. Mercredi 18 novembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 6. Mercredi 2 décembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

Séance 7. Mercredi 9 décembre 2026 – 10h00-12h00 – Clignancourt : Salle 217

EnviTERR – Niveau 2

7 séances :

Séance 1. Mardi 29 septembre 2026 – 11h30-13h30 – Institut : Salle 301

Séance 2. Mardi 13 octobre 2026 – 11h00-13h00 – Institut : Salle 301

Séance 3. Mardi 20 octobre 2026 – 11h00-13h00 – Institut : Salle 301

Séance 4. Mardi 3 novembre 2026 – 11h00-13h00 – Institut : Salle 301

Séance 5. Mardi 17 novembre 2026 – 11h00-13h00 – Institut : Salle 301

Séance 6. Mardi 24 novembre 2026 – 12h00-14h00 – Institut : Salle 301

Attention ! Décalage d'une heure dans la séance.

Séance 7. Mardi 8 décembre 2026 – 11h00-13h00 – Institut : Salle 301

	ACA / SCT	GéoSUDS	GéoINT	EnviTERR	
Séance 1	Séance identique pour tous les groupes				- Objectifs pédagogiques - Prise en main de GitHub - Prise en main de Docker - Prise en main de Python avec Docker
	23/09/2026	16/09/2026	16/09/2026	29/09/2026	
Séance 2	07/10/2026	30/09/2026			- Principes généraux de la statistique - Paramètres statistiques élémentaires
Séance 3	07/10/2026	21/10/2026			Distributions statistiques
Séance 4	14/10/2026	04/11/2026	30/09/2026	13/10/2026	Statistiques inférentielles
Séance 5	04/11/2026	18/11/2026	14/10/2026	20/10/2026	Statistique d'ordre des variables qualitatives
Séance 6	25/11/2026	25/11/2026	21/10/2026	03/11/2026	Régression et corrélation statistique de deux variables quantitatives
Séance 7	09/12/2026	02/12/2026	18/11/2026	17/11/2026	Étude de deux variables qualitatives
Séance 8			02/12/2026	24/11/2026	Les méthodes multivariées descriptives
Séance 9			09/12/2026	08/12/2026	Les méthodes multivariées explicatives

github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees

FIGURE 1.2 – Synthèse du planning 2026-2027

1.1.3 Niveaux

En fonction de votre niveau, vous ne ferez pas les mêmes séances numérotées dans ce livret et dans votre livret spécialisé.

Niveau 1. 1, 2, 3, 4, 5, 6, 7

Niveau 2. 1, 4, 5, 6, 7, 8, 9

Remarque importante. Il appartient aux étudiants de rattraper les séances 2 et 3 si les notions élémentaires ne sont pas maîtrisées. Vous pouvez réaliser les exercices associés à ces séances, mais ils ne seront pas évalués.

1.1.4 Introduction générale à l'analyse des données

Ce cours d'analyse de données est à la croisée de trois grands champs :

- la géographie, évidemment ;
- les données ;
- l'informatique, notamment grâce au langage de programmation Python.

En quelques heures de cours, il est difficile d'être exhaustif sur l'ensemble de ces champs. C'est pour cela qu'il sera orienté sur la manipulation des données avec le langage de programmation Python, que vous devrez, à force le pratiquer, un minimum maîtriser à la fin des séances.




FIGURE 1.3 – Positionnement du cours

Source : Maxime Forriez (2025)

Objectifs à atteindre

- Connaître et savoir manipuler différents formats de données, notamment géographiques
- Apprendre à lire des équations mathématiques et à savoir les utiliser dans un contexte de mathématiques appliquées à la géographie

- Connaître les principales méthodes statistiques (univariées, bivariées et multivariées)
- Savoir utiliser les bonnes méthodes en fonction des données géographiques à analyser, mais également des objectifs à atteindre
- Apprendre utiliser des outils informatiques professionnels (Git et Docker)
- Connaître et apprendre à utiliser les outils de calcul informatique grâce à un langage de programmation (Python)
- Réviser ou apprendre les notions mathématiques associées aux outils d'analyse (cf. le dossier « Formulaire de mathématiques » sur GitHub)

Les données en géographie

Les **sciences des données** sont appelés *data science*. Les étapes pour traiter les données sont :

1. trouver les données ;
2. nettoyer les données ;
3. explorer les données ;
4. identifier les analyses nécessaires ;
5. produire les sorties finales et les visualisations diffusables.

Pipeline d'analyse de données en recherche




FIGURE 1.4 – Opérations d'analyse de données en recherche

Source : LinkedIn

6 concepts clé de Statistiques à connaître pour tous les data analysts




FIGURE 1.5 – Six concepts statistiques clés à connaître lorsqu'on veut apprendre l'analyse des données

Source : LinkedIn

La géographie à l'ère des humanités numériques

Il existe un grand mouvement de digitalisation de toutes les données, parmi elles les données géographiques. Ce mouvement est appelé les **humanités numériques**. Les spécialistes des données sont très recherchés de nos jours. si vous n'apprenez pas à coder, ce seront les autres sciences qui analyseront les données géographiques.

La géographie et les mathématiques, entre rapprochement et éloignement

Géographie et mathématiques ont un lien très fort. La géographie est l'origine de la géométrie par exemple. Avec la mathématisation de la cartographie aux XVII^e-XVIII^e siècles, les mathématiques et la géographie se sont peu à peu éloigné l'une de l'autre. À partir du milieu du XX^e siècle, les statistiques ont peu à peu réintégré la géographie sous la forme des analyses spatiales (géostatistique, géotraitement, *etc.*). Cela a été accompagné par un développement des outils informatiques qui remplacent peu à peu les méthodes traditionnelles de cartographie. Pour faire des analyses de données géographiques, il faut maîtriser deux éléments : 1. l'informatique ; 2. les statistiques. Les données massives ¹ ne font que renforcer les liens entre ces outils et la géographie grâce à la géomatique.

L'objectif n'est pas de faire de vous des experts absolus dans ces deux outils, mais de vous faire acquérir un **niveau intermédiaire**, c'est-à-dire autonome.

Je vous informe que, dans le cadre dans ce cours, nous ferons des **mathématiques appliquées**. L'objectif n'est pas de faire de vous des mathématiciens émérites, mais simplement

1. En anglais : *big data*



FIGURE 1.6 – Programmeur vs développeur

Source : LinkedIn

de vous apprendre à comprendre les enjeux statistiques de tel ou tel jeu de données et d'appliquer les bonnes formules en ayant les bons réflexes d'interprétation. C'est l'ordinateur qui s'occupe des calculs grâce au langage Python. Vous devez juste savoir manipuler du code Python et interpréter les résultats des analyses, et non d'être capable les faire à la main. Bien entendu, si vous êtes curieux, je vous invite fortement à tenter de le faire. Cela vous permettra de comprendre en profondeur les formules. Le contenu de ce livret vous y aidera.



FIGURE 1.7 – De la géomatique à l’infinité des possibilités avec Python

Source : LinkedIn

Problème classique. Les données collectées sont mal organisées et compliquées, c’est-à-dire qu’elles ont des formats différents, une architecture inexistante, *etc.* Python servira à résoudre ce problème.

1.1.5 Aperçu des métiers

Data Analyst vs Data Scientist vs Data Engineer





FIGURE 1.8 – Les métiers autour de l'analyse de données

Source : LinkedIn

Data Analyst	Data Scientist	Business Analyst	ML Engineer	GenAI Engineer
				
Analyze existing data to generate insights and support data-driven decision-making	Develop and implement statistical models and machine learning algorithms to derive insights and make data driven predictions	Analyze and document business processes to identify opportunities, requirements, and recommendsl for improvement	Design, develop, and deploy machine learning systems to ensure scalability, performance, and reliability in production	Develop and deploy generative AI models and applications for content generation, automation, and personalized experiences
Skills:	Skills:	Skills:	Skills:	Tools:
SQL Excel Statistics Data Visallization Python	Python / R Machine Learning Statistics and Probability Data Wrangling and Feature Eng Data Visaulization	Business Process Modeling Communication & Requirements Gathering Data Analysis Problem-Solving Basic SQL & Excel	Machine Learning Data Engineering (ETL, Pipelines) Python / Java SQL Big Data Tools	Python (Transformers PyTorch, TensorFlow) HuggingFace LangChain
Tools:	Tools	Tools	Software Engineering	Tools
SQL Excel Tableau Jira	Excel Tableau	Microsoff-Office Suite	Tools Spark, Hadoop	LangGAPIs LLAMs

FIGURE 1.9 – Les métiers autour de l'analyse de données

Source : LinkedIn



FIGURE 1.10 – Comment devenir un spécialiste des données avec Python ?

Source : LinkedIn



FIGURE 1.11 – Comparaison entre les outils utilisés en 2016 et les outils utilisés en 2026

Source : LinkedIn

Annonce GeoTamTam : <https://georezo.net/forum/viewtopic.php?id=136053>

Nous recherchons un.e **développeur.euse Géomatique confirmé.e** avec de l'expérience afin de venir en appui d'une équipe en place chez l'un de nos clients Genevois.

L'équipe que vous rejoindrez en tant que consultant externe a comme mission de

- Proposer et mettre à disposition des services mutualisés en support des SI métiers.
- Maintenir et faire évoluer nos services mutualisés pour répondre aux futurs besoins des SI métiers en respect de la sécurité et de la qualité.
- Créer et maintenir du patrimoine métier sur la plateforme du territoire numérique.
- Amener de l'expertise et du conseil autour pour l'usage de nos services mutualisés.
- Proposition de support et formations à l'usage des services mutualisés.

Vos rôles et activités

- Réaliser et documenter la conception technique des solutions à mettre en place,
- Estimer les charges de développement ou les besoins en ressources techniques,
- Développer les solutions complexes dans les délais impartis et avec le niveau de qualité requis, assurer la mise en place et l'exécution des plans de tests
- Effectuer un reporting précis et régulier au chef de projet ou au gestionnaire de service sur l'avancée des travaux, le reste à faire, remonter les risques techniques

Formation: Bac + 3.

Compétences primordiales (3 années d'expérience et plus dans la fonction)

- **Maîtrise technique et fonctionnelle des progiciels de géomatique, de l'éditeur ESRI**
- Développement de flux temps réel avec le produit GeoEvent d'ESRI
- Expérience confirmée de travail sur des bases de données Oracle et MySQL,
- **Maîtrise des principes de conception orientée objet,**
- **Maîtrise des langages Python, Java, SQL, HTML et JavaScript**
- **Maîtrise d'environnement de développement et d'intégration continue : IDE courants, GIT, GitCI, GoCD**
- Maîtrise des principes de qualité logiciel et notamment la mise en œuvre de tests, des revues de code,
- Expérience confirmée de travail dans un environnement d'intégration continue (préférentiellement GitCI et SonarQube/SonarLint)

Le français est la langue de travail

Compétences importantes

- Connaissance des outils DevOps, Ansible
- Expérience des méthodes Agiles,
- Maîtrise des processus d'ingénierie de développement (phases et livrables associés)
- **Formation aux bases de la conteneurisation (Docker)**

Qualités requises

- Savoir travailler en équipe
- Autonomie, adaptabilité, dynamisme
- Sens des responsabilités
- Savoir prendre des initiatives
- Capacité à gérer plusieurs projets/activités en parallèle

Informations supplémentaires

Taux d'occupation : 80 %

Début : ASAP

Contactez-moi sur LinkedIn : <https://www.linkedin.com/in/jean-kelly-seguin/>

Dernière modification par jkseguin (Mon 08 September 2025 14:27)

Annonces prises au hasard le 10 octobre 2025 sur le site indeed.com

Géomaticien H/F - job post

[Gouvernement Monaco](#)

3.03.0/5 étoiles

98000 Monaco

À partir de 3 754 € par mois - Temps plein, CDD

Description du poste

Description du poste

La Direction des Ressources Humaines est à la recherche d'un **Géomaticien** H/F à la Compagnie des Sapeurs-Pompiers , pour une durée déterminée renouvelable (pouvant déboucher sur un CDI), la période d'essai étant de six mois.

Les missions du poste consistent principalement à :

- participer à l'administration du Système d'Information Géographique (SIG) du Corps des Sapeurs-Pompiers ;
- structurer, collecter et analyser des données géographiques ;
- restituer et mettre en forme des données géographiques pour faciliter leur intégration dans les outils de planification ;
- concevoir et mettre à disposition des outils de cartographie web d'aide à la décision pour le commandement et le personnel du Corps ;
- assurer un support technique des outils SIG déployés ;
- assurer la fiabilité et la qualité des données sensibles et garantir leur sécurité ;
- produire des documents opérationnels (PRO-PRA-Plans de secours) ;
- réaliser des plans d'intervention 2D/3D à l'aide d'outils de CAO (Conception Assistée par Ordinateur)/DAO (Dessin Assisté par Ordinateur) et BIM (Building Information Modeling) ;
- rédiger des procédures d'administration, des expressions de besoin, des notices utilisateur et des présentations ;
- assurer une veille technologique des outils informatiques et savoir identifier les besoins opérationnels ;
- savoir établir un cahier des charges technique et analyser une réponse à appel d'offres.

Les conditions de diplôme et d'expérience exigées sont :

- être titulaire, dans le domaine géomatique ou de la géographie ou des Systèmes d'Information Géographique, d'un diplôme sanctionnant cinq années d'études supérieures ou d'un diplôme reconnu équivalent par une autorité compétente dans le pays d'obtention et posséder une expérience professionnelle d'au moins quatre années dans les domaines précités ;
- ou être titulaire, dans le domaine géomatique ou de la géographie ou des Systèmes d'Information Géographique, d'un diplôme sanctionnant quatre années d'études supérieures ou d'un diplôme reconnu équivalent par une autorité compétente dans le pays d'obtention et posséder une expérience professionnelle d'au moins six années dans les domaines précités ;
- ou être titulaire, dans le domaine géomatique ou de la géographie ou des Systèmes d'Information Géographique, d'un diplôme sanctionnant trois années d'études supérieures ou d'un diplôme reconnu équivalent par une autorité compétente dans le pays d'obtention et posséder une expérience professionnelle d'au moins huit années dans les domaines précités.

Les aptitudes professionnelles requises sont :

- maîtriser la langue française (lu, écrit, parlé) ;
- être de bonne moralité ;
- posséder une bonne connaissance de la langue anglaise (lu, écrit, parlé), notamment du langage technique ;
- **maîtriser les outils ESRI (ArcGIS PRO, Arc GIS Enterprise) ;**
- **maîtriser la modélisation et la gestion de bases de données ;**
- maîtriser les ETL spatiaux FME ;
- maîtriser les logiciels de CAO/DAO AutoCAD Map 3D ;
- disposer de connaissances en BIM (REVIT) et en modélisation 3D (Sketchup) ;
- **avoir des connaissances en langage de programmation (Arcade-ESRI, SQL) ;**
- avoir des connaissances dans le domaine des risques naturels et technologiques.

Une bonne connaissance du fonctionnement des administrations et établissements publics serait souhaitée.

Des compétences dans le domaine des systèmes opérationnels d'alerte (type secours) seraient souhaitées.

Les savoir-être demandés sont :

- savoir faire preuve d'autonomie, de fiabilité et d'esprit d'analyse ;

- disposer de capacités au travail en équipe et de négociation ;
- posséder les qualités relationnelles et pédagogiques permettant d'accompagner le changement au sein du Corps des Sapeurs-Pompiers ;
- démontrer des aptitudes à promouvoir la transformation numérique au sein du Corps des Sapeurs-Pompiers ;
- posséder le sens du Service Public ;
- savoir faire preuve d'adaptabilité dans le domaine des évolutions technologiques ;
- faire preuve de réserve et de discrétion professionnelle ;
- être sensible aux valeurs écologiques de la Principauté et prêt(e) à participer à la démarche d'écoresponsabilité du Gouvernement.

Salaire net annuel : **49,1K€**

IMPORTANT : pour répondre à cette offre d'emploi, merci de vous rendre sur l'avis de recrutement original ci-dessous et de suivre les formalités indiquées pour postuler :

<https://journalde Monaco.gouv.mc/Journaux/2025/Journal-8767/Avis-de-recrutement-n-2025-291-d-un-Geomaticien-au-sein-du-Corps-des-Sapeurs-Pompiers>

Les dossiers de candidature déposés uniquement sur Indeed ne seront pas pris en compte.

Type d'emploi : Temps plein, CDD

Durée du contrat : 12 mois

Rémunération : à partir de 3 754,00€ par mois

Lieu du poste : En présentiel

Un(e) géomaticien (ne) / cartographe (H/F) - job post

[Service départemental d'incendie et de secours du Loiret](#)

45400 Semoy•Télétravail partiel

À partir de 2 200 € par mois - Temps plein

[Service départemental d'incendie et de secours du Loiret](#)

45400 Semoy•Télétravail partiel

À partir de 2 200 € par mois

Profil souhaité :

- Être titulaire d'un diplôme de niveau 6 (bac+3) ou niveau 7 (bac+5) dans le domaine des SIG (conduite de projet et gestion) et/ou être doté(e) d'une expérience professionnelle confirmée sur un poste similaire ;

- Maîtrise des outils SIG (Géoconcept, QGIS et ArcGIS) et DAO (Adobe Illustrator) ;

- Bonne connaissance du langage SQL et des SGBD Oracle et PostgreSQL/PostGIS ;

- Connaissances appréciées en ArcGis Server, FME, Lizmap, Python ;

- Connaissance de l'environnement professionnel (fonction publique territoriale et SDIS) ;

- Savoir travailler en équipe ;

- Être rigoureux et force de proposition ;

- Avoir le sens de l'organisation et respecter des procédures.

Caractéristiques du poste :

- Recrutement : voie statutaire ou à défaut voie contractuelle ;

- Statut : filière technique : cadre d'emplois des agents de maîtrise (grades d'agent de maîtrise et d'agent de maîtrise principal) et cadre d'emplois des techniciens (grade de technicien) ;

- Lieu de travail : 195 rue de la Gourdonnerie à Semoy, à proximité d'Orléans ainsi que des grands axes routiers et autoroutiers ;

- Rémunération : selon la grille indiciaire du cadre d'emplois et le régime indemnitaire en vigueur ;

- Temps de travail :

o 39 heures avec RTT réglementaires ;

o Horaires variables, du lundi au vendredi ;

- Avantages : titres restaurant, chèques vacances, prestations sociales, prévoyance santé.

Les candidatures, accompagnées d'une lettre de motivation et d'un curriculum vitae, devront être adressées pour **le 30 octobre 2025 dernier délai**, le cachet de la poste faisant foi à :

Monsieur le Président du Conseil d'Administration

du Service Départemental d'Incendie et de Secours du Loiret 195 Rue de la Gourdonnerie

45404 FLEURY-LES-AUBRAIS CEDEX

Ou par courriel à l'adresse **emploi@sdis45.fr**

Type d'emploi : Temps plein

Rémunération : à partir de 2 200,00€ par mois

Avantages :

- Flexitime

Lieu du poste : Télétravail hybride (45400 Semoy)

Cartographe Géomaticien en production cartographique - H/F - job post

[GEOFIT](#)

3.23.2/5 étoiles

34920 Le Crès

CDI, Temps plein

[GEOFIT](#)

34920 Le Crès

Description du poste

Envie d'intégrer un groupe collaboratif et engagé ?

Depuis sa création en 1968, GEOFIT est inscrit à l'Ordre des Géomètres-Experts. Les engagements de cette profession ont formé les racines du Groupe et permis de développer un large panel de compétences métier autour de valeurs communes.

Acteur clé du développement des territoires et de la ville, nous comptons plus de 1500 collaborateurs en France et à l'international. Le Groupe dispose de plus d'une vingtaine d'établissements sur l'ensemble du territoire français.

Dans le respect de nos valeurs d'inclusion et de diversité, le Groupe GEOFIT accueille toutes les candidatures, sans distinction, avec bienveillance. De plus, l'ensemble de nos postes sont ouverts et adaptés aux personnes en situation de handicap.

Rejoignez l'équipe production cartographique de Montpellier

L'écoute, la collaboration et la bienveillance constituent le socle de notre management de proximité. **Anthony** saura vous intégrer au sein de son équipe composée de 47 collaborateurs.

Votre parcours professionnel avec le groupe GEOFIT, c'est :

- ➡ Prendre une place stratégique dans une structure en évolution constante.
- ➡ Participer à des projets stimulants.
- ➡ Rejoindre une équipe chaleureuse et bienveillante.
- ➡ Évoluer au sein d'une entreprise qui vous fera confiance.

Mission

Notre **agence de Montpellier** recherche un **Cartographe Géomaticien** (H/F) pour renforcer l'équipe spécialisée en production cartographique.

Vous serez responsable de la production de cartes raster prêtes à l'impression ou à la diffusion numérique, à partir de données géographiques structurées. Vous interviendrez sur l'ensemble de la chaîne de production cartographique, de la préparation des données à la composition finale, en respectant des standards de qualité élevés.

Vous serez amenés à :

- Produire des cartes thématiques, topographiques ou opérationnelles à partir de bases de données vecteur, raster ou hybrides.
- Déployer et exploiter des chaînes de production cartographique automatisées ou semi-automatisées, telles que :
 - Chaîne Lorient
 - ESRI Production Mapping
 - Geoconcept
- Concevoir ou adapter des gabarits cartographiques : mise en page, cartouches, grilles, échelles, annotations, habillages, logos.
- Appliquer une symbologie adaptée selon les normes en vigueur.
- Réaliser des travaux de généralisation cartographique et d'ajustement des contenus à différentes échelles.
- Participer à la génération de séries cartographiques (atlas, tuilage, feuilles d'opérations, cartes par secteur).
- Exporter les productions finales en formats multiples : GeoTIFF, PDF, EPS, Illustrator, PNG, etc.
- Travailler en étroite collaboration avec les équipes SIG, data, et les experts métier.
- Participer à l'amélioration continue des outils et processus cartographiques.

Environnement technique & compétences attendues :

Outils & logiciels :

- **ArcGIS Desktop / Pro avec extensions *Production Mapping***
- Chaîne Lorient
- Geoconcept (édition et publication)
- Adobe Illustrator (post-traitement cartographique ou finition)
- QGIS, FME : en appui à la préparation des données
- **Connaissance en scripting utile (Python, ArcPy) pour automatisation**
- Connaissances des normes cartographiques serait un plus : OTAN, OGC, ISO

Compétences techniques :

- Maîtrise de la mise en page cartographique professionnelle.
- Connaissance des principes de sémiologie graphique appliquée à la cartographie.
- Capacité à produire des cartes lisibles, précises et esthétiques, sous contraintes de délais.
- Bonne compréhension des enjeux géographiques opérationnels (zones d'intérêt, théâtre d'opérations, corridors, zones sensibles...).

Profil

- Vous êtes diplômé(e) d'un **Bac +5 en géomatique, cartographie, SIG** ou équivalent.

- Vous justifiez d'une **expérience confirmée de 5 à 10 ans en production cartographique raster professionnelle**.
- Vous avez idéalement évolué dans un contexte **Défense, Sécurité ou institutionnel sensible**.
- **Compétences et qualités attendues :**
- Vous êtes reconnu(e) pour votre **rigueur**, votre **sens du détail** et votre souci de la **lisibilité**.
- Vous savez respecter des **standards exigeants** et vous adapter à des **cahiers des charges complexes**.
- Vous faites preuve d'**analyse**, de **synthèse** et d'**autonomie** dans la gestion de séries cartographiques.
- Vous disposez d'une bonne **aisance relationnelle** et appréciez le travail en **équipe pluridisciplinaire**.
- Langues : Vous maîtrisez le **français courant**. Vous avez un **anglais professionnel** vous permettant de lire de la documentation technique et d'échanger avec des partenaires.
- **Atouts supplémentaires :**
- Vous connaissez les **formats cartographiques spécifiques Défense** (DVG, MGCP, VMAP, etc.).
- Vous avez une sensibilité ou une expérience dans un environnement nécessitant une **habilitation de sécurité**.
- Vous possédez une expérience en **workflows de production à grande échelle** (atlas, cartographie en série).

Avantages

Temps de travail et horaires flexibles

- RTT
- Accord de télétravail

Accord de Qualité de Vie au Travail (QVCT)

- Management de proximité
- Environnement moderne et confortable
- Suivi du plan de carrière
- Parcours de formation

Primes et avantages divers

- Prime d'intéressement
- Prime vacances
- Prime de fin d'année
- Participation aux frais de transports en commun (50%)
- Charte de mobilité douce
- Pack de déplacement (véhicule de service, téléphone professionnel, forfait repas et déplacement, carte carburant, prime découchage)

Activité sociale et culturelle (CSE)

- Organisation de sorties et évènements conviviaux
- Site CSE-billetterie avec des tarifs préférentiels
- Carte cadeau / coffret gourmand
- Jeux concours

Mutuelle d'entreprise

Le processus de recrutement

Après avoir postulé, notre recruteuse **Jessy** prendra connaissance de votre candidature.

- Échange téléphonique
- Entretien avec le responsable concerné
- Testing / vérification des références
- Retour sur la candidature
- Lancement du programme d'intégration

Tenté(e) par l'expérience ? Postulez !

Type d'emploi : Temps plein, CDI

Lieu du poste : En présentiel

Géomaticien H/F - job post

[AMEG GROUP](#)

4.34.3/5 étoiles

73000 Chambéry

[AMEG GROUP](#)

73000 Chambéry

Description du poste

Rejoignez AMEG GROUP : L'Esprit d'un groupe à taille humaine au service de grands projets !

Depuis plus de **40 ans**, AMEG GROUP s'est distinguée comme une société d'ingénierie de premier plan, tout en conservant la proximité avec ses clients.

Avec plus de **250 collaborateurs** répartis sur plus de 10 agences en France, nous offrons des services de sous-traitance aux **PME, ETI, et grands comptes dans des secteurs variés de l'Industrie.**

Pourquoi choisir AMEG GROUP ?

Proximité et Accessibilité : Bénéficiez de la flexibilité et de la réactivité d'un groupe à taille humaine, avec des agences locales proches de vous et des Managers à votre écoute.

Projets Ambitieux : Participez à des projets innovants, tout en bénéficiant de l'accompagnement personnalisé.

Développement et Évolution : Profitez d'une culture d'entreprise qui favorise l'échange, la reconnaissance, le développement et la mise en valeur continus des compétences.

Rejoignez-nous pour une carrière enrichissante, où votre talent et votre engagement feront la différence !

Poste:

En tant que **Géomaticien**, vous participerez activement à la gestion, l'analyse et la valorisation des données géographiques afin de répondre aux enjeux de nos projets.

Acquisition et structuration des données géographiques

- Développer et mettre à jour les bases de données géographiques (cartes, statistiques géolocalisées, images aériennes et satellites...).
- Identifier et collecter les données nécessaires auprès de fournisseurs externes.
- Transformer des données brutes en informations exploitables pour le SIG de l'entreprise.

Traitement et production cartographique

- Analyser les données spatiales en fonction des besoins (analyse de territoires, maillage territorial, etc.).
- Construire des outils de modélisation et de simulation (risques naturels, aménagement urbain...).
- Produire des cartes et des analyses spatiales à partir des données SIG.
- Assurer la mise à jour du référentiel de données et des cartographies internes (sinistres, risques...).

Diffusion de l'information géographique

- Rédiger des synthèses claires pour accompagner la prise de décision des équipes métiers.
- Diffuser les données géographiques et cartographiques via des réseaux internes et externes.

Profil:

✓ **Formation** : BAC+5 – Master en Géomatique, SIG, Géographie, Urbanisme, Statistiques ou Informatique avec une spécialisation SIG.

✓ **Compétences techniques** :

- **Maîtrise des SIG (QGIS, ArcGIS, PostGIS...).**
- **Analyse statistique (croisement de données, modélisation, programmation – Python, R...).**
- **Structuration et gestion de bases de données géographiques (FME)**

✓ **Qualités personnelles** :

- Rigueur dans le traitement des données.
- Esprit d'analyse et de synthèse.
- Curiosité et capacité d'écoute des besoins métiers.

Autres informations:

Salaire selon profil et expérience.

Avantages :

- Télétravail possible après 1 mois de présentiel
- Carte ticket restaurant
- Mutuelle à 50%
- Prime vacance
- Carte cadeaux en fin d'année

1.1.6 Évaluation

- <https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees/tree/main/Evaluation>

Toutes les séances sont notées sous la forme d'un portfolio à déposer sur votre compte GitHub.

Attention ! Toute absence est rarement rattrapable.

Attention ! Soyez à l'heure à chaque séance. Plus vous êtes en retard, moins vous aurez de temps pour faire l'analyse du jour.

Il vous est demandé de me rendre l'ensemble de vos travaux pour le **16 décembre 2026 23 :59 :59 au plus tard**.

La procédure sera la suivante.

- Dans l'onglet d'évaluation du Discord ou sur mon courriel professionnel alternatif : `mforriez.sorbonne.universite@gmail.com` (pour l'instant), vous m'envoyez le lien de votre portfolio.

Attention ! Le dépôt sur GitHub fait partie de l'exercice. Je n'évaluerai aucun autre type d'envoi. Si vous n'utilisez pas GitHub, votre note sera 00/20.

- À réception de votre message, je considère que toutes les modifications ultérieures à la date maximale du rendu (jour et heure exacts) sont caduques.

Règles générales

- À l'exception de la séance 1, toutes les séances fonctionnent pédagogiquement selon une classe inversée. Si vous ne me posez pas vos questions techniques au moment des séances, vous perdrez votre temps.
- Je ne possède pas la capacité de me dédoubler. Lorsque je suis occupé avec un étudiant ou un groupe d'étudiants, patientez, ou mieux demandez autour de vous si quelqu'un peut vous expliquer !
- La classe inversée est éprouvante pour votre enseignant. Je vous remercie d'être compréhensif sur mon niveau de fatigue après 2-3 heures de cours.
- Vous êtes vivement encouragés à travailler en groupe, mais le rapport est personnel, et si vous rendez des codes littéralement copiés-collés, merci de me l'indiquer dans vos fichiers que je ne perde pas mon temps à corriger plusieurs fois les mêmes choses.
- En dehors du cours, je ne communique avec vous qu'avec le serveur Discord. **Je ne répondrai à aucun de vos courriels.**
- Vous pouvez solliciter M. Cyprien Deloget `cyprien.deloget@sorbonne-universite.fr`, membre du serveur Discord, Bureau SE04 (entresol), rue Serpente à Paris. Contrairement à votre enseignant, il est toujours présent sur Paris. Merci d'être courtois avec lui. N'hésitez pas à le contacter concernant Python ou Git. Il pourra vous recevoir pour vous réexpliquer, mais n'attendez pas la fin de semestre pour le faire, Cyprien a un planning assez chargé.

Règles concernant le serveur Discord

Vous devez utiliser le serveur `Discord` pour communiquer avec votre enseignant, Cyprien Deloget et vos camarades.

- Respectez les flux.
- Comprenez bien que votre enseignant ne vous surveille pas 24h sur 24. Tant que le propos est courtois et respectueux du *Code pénal*, vous pouvez y parler librement. Ne créez pas un flux parallèle, S.V.P.
- Comprenez que, si vous avez un problème technique, d'autres l'ont peut-être également. Si vous voulez avancer, n'hésitez pas à partager vos réussites et vos échecs.

Codes Python

40 % de la note du module.

Vous serez évalué sur :

- la qualité de l'écriture de votre code :

- respect des principes du *clean code* ;
- respect des normes `Python`.

N.B. Il ne s'agit pas d'un strict respect de toutes les règles. Il y en a beaucoup trop, mais votre code devra être structuré et facile à lire.

- le test d'exécution de votre code. Il ne doit pas me renvoyer d'erreur ;
- le fait que votre code soit le plus court possible ;
- l'architecture de vos fichiers. Cela doit être propre c'est-à-dire rangé par séance avec le bon numéro. Niveau 2, je vous rappelle que vous commencez à la séance 4.

Attention ! L'utilisation régulière de `GitHub` n'est pas une option. Si vous ne l'utilisez que pour me rendre votre travail final, vous serez sanctionné de -1 point sur votre moyenne globale.

Rapport d'activité

60 % de la note du module

La forme

- Je veux un rapport sous un format P.D.F. (-10 points dans le cas contraire).
- Plus d'une faute par page rendue (-2 points)

Le fond

- Tous les exercices se décomposent en deux.
 1. Quelques questions de cours pour vous guider dans la lecture des documents
 2. Un exercice de code

Votre rapport doit apporter la réponse aux questions posées de manière structurée, c'est-à-dire sous la forme d'un texte de synthèse répondant à l'ensemble des éléments à expliciter avec vos propres mots.

- Le code va produire des résultats en fonction des séances vous indiquerez dans votre rapport :
 - vos résultats sous la forme d'un tableau ;
 - vos graphiques.
- Vous commenterez librement sous la forme d'un court paragraphe les résultats obtenus. Le commentaire peut être technique ou scientifique.
- Votre rapport doit être structuré par séance d'activités. Il doit contenir des phrases complètes.
- Votre rapport doit se conclure par une réflexion personnelle sur les sciences des données et les humanités numériques en fonction des exercices de votre parcours.
- Options :
 1. Indications des problèmes que vous avez rencontrés et comment vous les avez résolus (ou pas)
 2. Indications de vos difficultés d'apprentissage

N.B. 1. L'objectif du point 1 est de constituer une F.A.Q. pour vos successeurs.

N.B. 2. L'objectif du point 2 est d'améliorer les méthodes d'apprentissage pour vos successeurs.

Points bonus

- Des points bonus seront attribués pour votre participation au `Discord`.
 - Aide à vos camarades si vous en avez la capacité
 - Jeu de questions-réponses avec vous et moi-même
 - *etc.*
- Des points bonus seront attribués par rapport aux indications optionnelles contenues dans votre rapport.
- Des points bonus seront attribués si vous me faites une annexe mathématique de toutes les équations calculées par `Python` que vous avez comprises.

Résumé des barèmes

Chaque séance est notée sur 20 que ce soient les questions de cours ou les résultats à produire. Un coefficient y sera appliqué (Tab. 1.1 ; Tab. 1.2). Quelques séances ont des questions bonus au niveau du code. En fonction de votre niveau, des points en plus sur la moyenne globale seront appliqués (Tab. 1.3).

Séance	Niveau 1	Niveau 2
2	10	–
3	10	–
4	20	10
5	20	10
6	15	15
7	15	25
8	–	20
9	–	20
Contenu hors exercices	10	10
Total	100	100

TABLE 1.1 – Coefficient en pourcent des questions de cours

Séance	Niveau 1	Niveau 2
2	10	–
3	10	–
4	25	10
5	25	10
6	15	15
7	15	15
8	–	25
9	–	25
Total	100	100

TABLE 1.2 – Coefficient en pourcent du code rendu

Il existe une séance bonus pour **tout le monde** consistant à apprendre comment télécharger des données massives grâce à un A.P.I.

Remarque

- Vous êtes des littéraires de formation pour bon nombre d’entre vous. C’est pour cela que je dispropotionne légèrement les coefficients. Les deux parties sont notées sur 20.
- En tant qu’enseignant, pour moi, les notes vont de 0 à 20. Si votre rendu est très mauvais, je n’hésiterai pas à vous mettre 0 ; si vous atteignez tous les objectifs demandés par rapport à votre parcours, vous aurez 20.

Séance	Niveau 1	Niveau 2
2	7	
3	0	
4	3	
5	10	2
6	5	10
7	15	4
8		10
9		8
10		6
Total	30	40

TABLE 1.3 – Bonus (en points)

1.2 Prise en main de GitHub

1.2.1 Remarques générales

GitHub est une plateforme collaborative de versionnage. Le dossier du cours se localise à l'adresse suivante : <https://github.com/MaximeForrieux/Sorbonne-M1-Analyse-de-donnees>.

Nous utiliserons GitHub simplement pour son dépôt. Nous ne l'utiliserons pas à son plein potentiel. Si vous êtes intéressé par les métiers de l'analyse de données, je ne saurais que trop vous conseiller d'apprendre à l'utiliser.

Vous devez vous rendre sur <https://www.github.com> pour créer un compte en cliquant sur Sign up (Fig. 1.12).




FIGURE 1.12 – Créer un compte GitHub – Écran 1

Create your free account

Explore GitHub's core features for individuals and organizations.

See what's included ^

- ✓ **Access to GitHub Copilot**
Increase your productivity and accelerate software development.
- ✓ **Unlimited repositories**
Collaborate securely on public and private projects.
- ✓ **Integrated code reviews**
Boost code quality with built-in review tools.
- ✓ **Automated workflows**
Save time with CI/CD integrations and GitHub Actions.
- ✓ **Community support**
Connect with developers worldwide for instant feedback and insights.

Sign up for GitHub

Continue with Google

Continue with Apple

or

Email*
Email **Courriel personnel**

Password*
Password **Mot de passe choisi**
Password should be at least 15 characters OR at least 8 characters including a number and a lowercase letter.

Username*
Username **Nom d'utilisateur**
Username may only contain alphanumeric characters or single hyphens, and cannot begin or end with a hyphen.

Your Country/Region*
France

Email preferences
☐ Receive occasional product updates and announcements

Create account >

By creating an account, you agree to the [Terms of Service](#). For more information about GitHub's privacy practices, see the [GitHub Privacy Statement](#). We'll occasionally send you account-related emails.

**Nom sans espace, sans caractères accentués
Exemple : MaximeForriez
Vous pouvez distinguer votre prénom et votre nom en utilisant des majuscules**

Cliquer pour créer le compte

FIGURE 1.13 – Créer un compte GitHub – Écran 2

Vous devez ouvrir un compte sur GitHub. C'est dans votre dépôt que vous déposerez les éléments qui seront évalués à la fin du semestre. Votre utilisation de la plateforme fait partie intégrante de votre notation.

- Courriel :
- Nom d'utilisateur :
- Mot de passe :

Si vous perdez votre mot de passe, il n'existe aucun moyen de le récupérer. Notez le bien.

Une explication du fonctionnement basique de Git est disponible au lien suivant :

<https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees/Git/Git.md>.

Si vous souhaitez approfondir la question, vous pouvez le faire au lien suivant :

<https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees/Git/Git-Avance.md>.

Il existe de nombreux tutoriels sur GitHub sur YouTube.



FIGURE 1.14 – Git Cheat Sheet

Source : LinkedIn

1.2.2 Prise en main pas à pas

1. Ouvrir votre compte à partir de la page d'accueil en cliquant sur Sign in (Fig. 1.15)




FIGURE 1.15 – Ouvrir son compte GitHub

2. Sur la plateforme en ligne (machine distante), cliquer sur le bouton en haut à droite. Sélectionner dans le menu Repositories (Fig. 1.16).




FIGURE 1.16 – Créer un repository – Écran 1

3. Sur la plateforme en ligne, créer un Repositories en cliquant sur News (Fig. 1.17) que vous nommerez Analyse-de-donnees-Prenom-Nom (Fig. 1.18 ; Fig. 1.19). Une indication vous confirme si le nom du dépôt est disponible.

Attention ! Pas d'espace, utilisez des tirets ; pas d'accents ou autres caractères spéciaux.




FIGURE 1.17 – Créer un repository – Écran 2

github.com/new

Importer les marque... Cartographie numériq... MapCruzin Data Rese... Free GIS Datasets - Ca... Atlas Caralbe World Imagery Wayba... Editions Ménéstrel > ... Save Video Me

New repository

Search Type / to search

Create a new repository

Repositories contain a project's files and version history. Have a project elsewhere? [Import a repository](#).
Required fields are marked with an asterisk (*).

1 General

Owner * Repository name *

MaximeForriez /

Great repository names are short and memorable. How about [super-duper-funicular?](#)

Description

0 / 350 characters

2 Configuration

Choose visibility *
Choose who can see and commit to this repository **Public**

Start with a template
Templates pre-configure your repository with files. **No template**

Add README
READMEs can be used as longer descriptions. [About READMEs](#) **Off**

Add .gitignore
.gitignore tells git which files not to track. [About ignoring files](#) **No .gitignore**

Add license
Licenses explain how others can use your code. [About licenses](#) **No license**

Create repository

© 2026 GitHub, Inc. Terms Privacy Security Status Community Docs Contact Manage cookies Do not share my personal information

FIGURE 1.18 – Créer un repository – Écran 3a




FIGURE 1.19 – Créer un repository – Écran 3b

4. En validant votre dépôt, la liste des lignes de commandes à taper apparaissent (Fig. 1.20).
5. Sur votre ordinateur (machine locale), créer dans le lecteur C : \ un dossier à votre nom (dossier racine), puis un sous-dossier Exercices dans lequel vous mettrez votre architecture décrite après (Fig. 1.21).

N.B. Le dossier racine est le dossier de référence entre votre ordinateur et votre dépôt distant.

6. Vérifier que les dossiers et les fichiers cachés, ainsi les extensions des fichiers s'affichent bien sur votre ordinateur (cf. explication plus moins dans ce livret p. 87)
7. Dans le dossier Exercices, ouvrir un terminal Bash grâce au clic droit de la souris (Fig. 1.21)
8. Le terminal Bash est un terminal Linux avec lequel vous allez pouvoir envoyer vos fichiers locaux vers votre dépôt (Fig. 1.22).
9. Il faut configurer votre Git en utilisant votre nom d'utilisateur sur GitHub en respectant les majuscules et les minuscules (la casse) et le courriel rattaché à votre compte :

```
git config --global user.name "MaximeForriez"
git config --global user.name "maxime.forriez@trucmuche.fr"
```




FIGURE 1.20 – Créer un repository – Écran 4

Cette étape n'est à faire qu'une seule fois sur votre PC, mais doit être répétée sur les ordinateurs dans les salles informatique de l'université.

10. Il faut commencer par initialiser votre dépôt en tapant :

```
git init
```

Cette étape n'est à faire qu'une seule fois. Dans votre dossier `Exercices`, la commande crée un dossier caché nommé `.git` (Fig. 1.23). Vous ne devez jamais ouvrir ce dossier. Sachez juste qu'il existe. Sauf si vous apprenez très rapidement des notions avancées de Git, laissez-le vivre sa vie.

11. Créer un fichier `test.txt` dans le dossier `Exercices`. Il n'a pas besoin de contenir quelque chose (Fig. 1.24).
12. Retourner sur le terminal et taper (Fig. 1.25) :

```
git add .
```




FIGURE 1.21 – Créer un dépôt local – Écran 1




FIGURE 1.22 – Créer un dépôt local – Écran 2

Cette commande permet d'initialiser l'envoi vers le dépôt distant. `git` vérifie si, en fonction du dernier envoi, des fichiers ont changé ou ont été supprimés sur votre machine locale. `.` signifie que vous envoyez tous les fichiers modifiés. La commande `add` constitue la première étape de l'envoi. Pour l'instant, vous venez d'initialiser le proces-




FIGURE 1.23 – Créer un dépôt local – Écran 3




FIGURE 1.24 – Créer un dépôt local – Écran 4

sus.

13. Sur le terminal, taper (Fig. 1.25) :

```
git commit -m "first commit"
```

Cette commande permet de nommer votre envoi. `Git` est une sorte d'arbre. Il est composé de nœuds appelés `commit`. C'est le cœur d'un système de versionnage. La commande constitue la deuxième étape de l'envoi. Vos données sont prêtes à être déposées, mais ne le sont toujours pas.

14. Pour l'instant, la branche d'accueil n'existe pas. Il faut la créer en tapant (Fig. 1.25) :

```
git branch -M main
```

Cette étape n'est à faire qu'une seule fois sur votre PC, mais doit être répétée sur les ordinateurs dans les salles informatique de l'université.

15. La branche est créée, mais, pour l'instant, le lien entre votre dossier en local et votre dépôt distant n'existe pas. Il faut le créer. Sur votre dépôt, récupérer son adresse HTTPS (et non SSH). Toute adresse finit par `.git` (Fig. 1.25).

```
git remote add origin https://*.git
```

Cette étape n'est à faire qu'une seule fois sur votre PC, mais doit être répétée sur les ordinateurs dans les salles informatique de l'université.

16. Il faut pousser votre envoi vers votre dépôt en tapant (Fig. 1.25) :

```
git push -u origin main
```

Littéralement, la commande signifie « pousser vers la branche `main` le `commit` en attente ».

N.B. `-u` est ce que l'on appelle dans une ligne de commande un drapeau. Il est possible qu'une erreur entre le local et le distant vous empêche de déposer. Dans quelques cas, changer de drapeau en utilisant `-f` permet de rétablir la connexion. Littéralement, cela signifie que « l'on force le dépôt ».

17. En cas de première connexion, `Git` demande d'ouvrir votre navigateur par défaut, afin de confirmer votre identité. Vous devez valider toutes les permissions demandées. Cette étape n'est à faire qu'une seule fois sur votre PC, mais doit être répétée sur les ordinateurs dans les salles informatique de l'université.
18. Rafraîchissez la page de votre dépôt distant en cliquant sur la touche `F5`. Si tout va bien, le fichier `test.txt` apparaît dans votre dépôt (Fig. ??).

En résumé, mis à part `git init`, toutes les commandes sont à répéter pour déposer votre travail en ligne sur un ordinateur de la salle informatique de l'université. Sur votre PC, les choses sont plus simples. Toutes les commandes sont à n'écrire qu'une fois, sauf :

```
git add .
git commit -m "nom du commit"
git push -u origin main
```

Pour tout le monde, les trois étapes doivent toujours être réalisées dans cet ordre, et uniquement dans cet ordre.




FIGURE 1.25 – Créer une connexion entre un dépôt local et un dépôt distant– Écran 4




FIGURE 1.26 – Vérification du dépôt

1.2.3 Copier et maintenir un dépôt distant qui ne vous appartient pas

Dans le dossier racine que vous avez créé, ici C : \FORRIEZ, ouvrir un autre terminal Bash (toujours grâce à un clic droit). Y taper :

```
git clone https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees.git
```

Cette commande permet de copier l'intégralité du dossier du cours sur votre machine personnelle. Il suffit d'écrire le nom du dépôt que vous voulez récupérer.

Une fois récupéré, le dépôt peut être mis à jour par son administrateur. Vous n'allez pas effectuer de nouveau cette commande. Vous allez vous contenter de récupérer les fichiers modifiés en tapant :

```
git pull
```

Automatiquement, toute mise à jour sera désormais disponible dans votre dépôt local.

1.2.4 Avertissements

1. `Git` n'accepte ni les gros fichiers, une cinquantaine de mégaoctets peut faire planter le programme –, ni les flux, c'est-à-dire le volume total des fichiers envoyés, trop volumineux. Vous ne pouvez envoyer que 1 gigaoctet au maximum par flux.
2. Toute erreur sur `Git` peut être lourde de conséquences dans un contexte professionnel. Ne faites pas n'importe quoi ! Entraînez-vous !
3. Si vous utilisez votre dépôt avec deux machines, université ou votre PC, n'oubliez pas de commencer par une commande `git pull` afin de bien mettre à jour les changements opérés. Je m'explique vous travailler sur la machine de l'université. Vous faites des modifications pendant le cours, puis vous les déposez sur votre dépôt. En travaillant par la suite chez vous avec votre PC, il existera une différence entre le dépôt en local de votre machine et le dépôt distant. Il faut commencer par mettre à jour vos modifications. Soyez très rigoureux et disciplinés dans vos manipulations ! Le moindre écart, et c'est l'erreur assurée.

1.3 Prise en main de Docker

Vous devez ouvrir un compte sur Docker.

1. Aller sur le site <https://www.docker.com>
2. Sur la page d'accueil, cliquer sur le bouton `Sign In` (Fig. 1.27)




FIGURE 1.27 – Docker – Écran 1

3. Une page d'identification s'ouvre. Comme vous n'avez pas de compte, aller en bas de la page, et cliquer sur le lien `Sign Up` (Fig. 1.28)
4. Une page de création de compte s'ouvre. Par défaut, elle s'ouvre sur un compte professionnel `Work`. Cliquer sur l'onglet `Personal` (Fig. 1.29)
5. Saisissez votre courriel, votre nom d'utilisateur et votre mot de passe (Fig. 1.29)
 - Courriel :
 - Nom d'utilisateur :
 - Mot de passe :

Si vous perdez votre mot de passe, il n'y a aucun moyen de le récupérer. Notez-le bien.

Normalement, un logiciel appelé `Docker Desktop` est installé sur votre machine. Pour vérifier sa présence, ouvrez un terminal de type `Invite de commande`.

1. Cliquer sur le bouton `Windows` dans votre barre de menu.
2. Laisser le menu affiché tout en tapant `cmd`
3. L'`Invite de commande` est disponible. Cliquer dessus pour l'ouvrir ou faites `Entrée`
4. Une fenêtre noire s'affiche. Pour ceux qui n'ont pas l'habitude, pas de panique !
5. Taper (le contenu après le symbole `>`) :




FIGURE 1.28 – Docker – Écran 2




FIGURE 1.29 – Docker – Écran 3

```
C:\...> docker -v
```

Si un numéro de version avec trois nombres séparés par un point apparaît,
Docker Engine est bien installé sur votre machine

```
Docker version 26.0.0, build 2ae903e
```

Si vous avez une erreur, vous m'appellez immédiatement.

Ouvrez le logiciel Docker Engine en le cherchant de la même manière que

l'Invite de commande. Nous allons utiliser Docker pour installer la même version de Python sur toutes les machines, mais, pour cela, il faut créer un pont entre votre machine locale et le serveur Docker Hub.

1. Cliquer sur l'onglet Hub
2. Enregistrer les identifiants que vous avez créés précédemment avec le bouton Sign In (Fig. 1.30)




FIGURE 1.30 – Docker – Écran 4

3. Votre navigateur par défaut s'ouvrira et vous pourrez entrer vos données (Fig. 1.31 ; Fig. 1.32).
4. Validez toutes les permissions (Fig. 1.33)
5. Si la connexion est établie, la première lettre de votre nom d'utilisateur apparaît à la place de Sign In (Fig. 1.34)

N.B. À la fin de chaque séance, il vous faudra :

1. Fermer votre compte personnel pour la personne suivante en cliquant sur Sign out, sinon elle aura accès à toutes vos données personnelles (Fig. 1.35)
2. Éteindre le Docker Engine. En bas, à gauche, un onglet vert indique l'exécution du programme. Pour l'éteindre, il suffit de cliquer sur le bouton d'arrêt Quit Docker Desktop (Fig. 1.36). C'est très important sinon le Docker Engine s'ouvre à chaque ouverture de l'ordinateur, ce qui le ralentira considérablement. Pensez à vos camarades !
3. Sauvegarder votre travail sur une clé U.S.B. et sur votre dépôt GitHub




FIGURE 1.31 – Docker – Écran 5




FIGURE 1.32 – Docker – Écran 6

Attention ! Vous ne pouvez pas utiliser GitHub à partir d'une clé U.S.B. Il vous faut un disque SSD.

4. Même s'il y a un groupe après vous, éteignez votre P.C. Cela permet de vider la mémoire vive et de donner un ordinateur propre à l'étudiant suivant.

Désormais, vous êtes attaché à un numéro de poste. Vous ne pourrez plus en changer.

— Numéro de poste en salle _____ :

Courage ! C'est presque fini.




FIGURE 1.33 – Docker – Écran 7




FIGURE 1.34 – Docker – Écran 8

1.4 Établissement d'une architecture propre

Sur votre machine, créer un dossier avec votre nom, l'année universitaire et le titre du cours dans le lecteur C : \.




FIGURE 1.35 – Docker – Écran 9




FIGURE 1.36 – Docker – Écran 10

Forriez-2025-2026-Analyse-de-donnees

N.B. Mettez bien les –.

Dans ce dossier, créer autant de sous-dossiers que de séances. Pour le niveau 1 :

Seance-01

Seance-02
 Seance-03
 Seance-04
 Seance-05
 Seance-06
 Seance-07

Pour le niveau 2 :

Seance-01
 Seance-04
 Seance-05
 Seance-06
 Seance-07
 Seance-08
 Seance-09

N.B. N'oubliez pas de sauvegarder votre travail sur une clé U.S.B. et sur votre dépôt GitHub en fin de cours.

1.5 Prise en main de Python avec Visual Studio Code et Docker

Ouvrir Visual Studio Code (Fig. 1.37). Par défaut, il n'existe aucun terminal Windows accessible.




FIGURE 1.37 – Visual Studio Code – Écran 1

Faire apparaître le terminal Windows en tapant simultanément sur la touche `Ctrl` et `ù` de votre clavier (Fig. 1.38).




FIGURE 1.38 – Visual Studio Code – Écran 2

Ouvrir Docker et ouvrir son compte Docker comme vu précédemment (Fig. 1.39)




FIGURE 1.39 – Docker – Écran 1

Pour exécuter Python, sous Docker, il faut que vous alliez récupérer sur GitHub trois fichiers :

1. Dockerfile

Attention ! Le téléchargement peut ajouter une extension `*.txt` au fichier `Dockerfile`. Il faut supprimer cet ajout en affichant les extensions de vos fichiers (cf. p. 87).

2. `docker-compose.yml`3. `requirements.txt`

Chaque fichier doit être téléchargé et placé dans le dossier de la séance du jour (Fig. 1.40).




FIGURE 1.40 – Dossier de la séance du jour

Attention ! Il est strictement interdit de renommer ces fichiers. Si vous opérez plusieurs téléchargements, et qu'un nombre se glisse dans le nom du fichier, il faut le retirer en renommant le fichier.

Ces trois fichiers sont des fichiers de configuration. Ils sont conçus pour que vous puissiez réaliser toutes les séances. En principe, sauf si, entre temps, vous devenez des experts de Docker, **vous n'écrirez rien dans ces trois fichiers**.

Vous devez également récupérer le contenu du dossier `src` (source), le fichier `main.py`.

Attention ! Vous devez reconstituer l'architecture `src\main.py` dans le dossier de chacune des séances, sinon ça ne marchera pas.

Placez-vous dans le dossier `Seance-01`, et non dans `Seance-01\src`, c'est super important (Fig. 1.41).

1. Dans votre terminal VS Code, taper l'adresse où se situe les trois fichiers de configuration de Docker en utilisant la commande `cd "adresse"` (Fig. 1.41)

N.B. Vous pouvez copier-coller l'adresse à partir de votre dossier contenant la séance du jour.




FIGURE 1.41 – Visual Studio Code – Écran 3

2. Taper la commande en respectant la casse (minuscules et majuscules) (Fig. 1.42) :

```
C:\Forriez-2025-2026-Analyse-de-donnees\Seance-01 > docker-
compose up -d
```

Félicitations ! Vous venez de créer et de lancer une image Docker. Elle est configurée par les fichiers `Dockerfile` et `docker-compose.yml`

N.B. Si vous avez déjà créé un conteneur Docker, et que vous en modifiez les paramètres initiaux, c'est-à-dire que vous modifiez les trois fichiers de configuration, il faudra taper :

```
C:\Forriez-2025-2026-Analyse-de-donnees\Seance-01 > docker-
compose up -d --build
```

ce qui lancera un nouveau conteneur qui prendra en compte vos modifications.

3. Un téléchargement démarre. La première installation peut durer quelques minutes.

Dans le dossier `src`, ouvrez le fichier `main.py` de la séance (Fig. 1.43), ici ce sont les fichiers de démonstration qui sont utilisés. Il contient le code « très utile » :

```
print('Bienvenue au cours d'analyse de données en géographie !')
```

Chaque programme Python s'exécute en ligne de commande. Avec Docker, il faut taper la commande suivante pour exécuter votre code (Fig. 1.43) :

```
C:\Forriez-2025-2026-Analyse-de-donnees\Seance-01 > docker-compose
run python
```

À chaque modification de votre code, il faudra enregistrer votre fichier `main.py` et effectuer cette commande. Vous finirez par la connaître par cœur.




FIGURE 1.42 – Visual Studio Code – Écran 4

Pour commenter des lignes que vous ne souhaitez plus exécuter, il suffit de taper simultanément sur les touches `Ctrl` et `/` de votre clavier.

N.B. Sans Docker, placer dans le dossier contenant les fichiers, il suffirait de taper : `python nom du fichier à exécuter`. Cela suppose une installation manuelle de Python qui prend beaucoup de temps, mais vous pouvez vous reporter aux tutoriels en ligne proposés sur GitHub dans le dossier consacré à Python.

Attention! Sauf exception clairement précisée dans l'exercice du jour, le point d'entrée de tous les exercices sera toujours un fichier `main.py`, même si plusieurs fichiers Python existent.

Attention! Vous ne devez jamais fermer sauvagement la fenêtre de l'Invite de commande. Vous devez d'abord éteindre le programme Docker Compose avec la commande (Fig. 1.45) :

```
C:\Forriez-2025-2026-Analyse-de-donnees\Seance-01 > docker-compose
down
```

Attention! Si vous ne le faites pas, vous créerez des conteneurs orphelins dans le système qu'il faudra nettoyer.




FIGURE 1.43 – Visual Studio Code – Écran 5




FIGURE 1.44 – Visual Studio Code – Écran 6

Une fois Python arrêté, vous pourrez fermer la fenêtre. Il ne restera plus qu'à éteindre Docker Desktop.




FIGURE 1.45 – Visual Studio Code – Écran 7




FIGURE 1.46 – Principales commandes de Docker

Source : LinkedIn

1.6 Découverte de Python

« Tout le monde devrait apprendre à programmer un ordinateur, car il vous apprend à penser. » (Steve Job)

Docker peut apparaître superflu, mais cette couche supplémentaire va permettre de gérer beaucoup plus simplement Python, surtout si vous n’avez jamais codé de votre vie.

Python fonctionne avec un système de paquets². Lorsque vous avez besoin d’un outil spécifique, il faut systématiquement le télécharger, ce qui peut être fastidieux, notamment parce qu’il faut régulièrement mettre les paquets à jour manuellement. Grâce à Docker, tous les paquets sont regroupés dans un fichier unique : `requirements.txt`, pris en charge par les deux autres fichiers de configuration.

Sur le GitHub, un dossier documentaire regroupant l’essentiel de ce qu’il faut connaître du langage est mis à votre disposition. Bien entendu, cela ne doit pas vous empêcher de lire les documentations officielles en ligne.

Parmi les paquets, vous pouvez télécharger des **bibliothèques**. Pour faire vos analyses de données, vous allez utiliser principalement :

- Pandas
- NumPy
- Matplotlib
- *etc.*

Il faudra utiliser des paquets pour lire des données Excel, C.S.V., S.Q.L., JSON, *etc.*

N.B. En principe, la totalité des paquets utile pour ce cours est contenu dans le fichier `requirements.txt`. Toutefois, il se peut que vous en ayez besoin d’autres. Dans ce cas, il faudra l’ajouter dans la liste des paquets contenus dans ce fichier, puis arrêter `docker-compose`, et le relancer avec la commande `--build` pour télécharger le nouveau paquet dans votre conteneur Docker.

```
C:\Forriez-2025-2026-Analyse-de-donnees\Seance-01 > docker-compose
down
C:\Forriez-2025-2026-Analyse-de-donnees\Seance-01 > docker-compose
up -d --build
```

Pourquoi apprendre le Python ? R n’est-il pas suffisant ?

2. En anglais : *package*




FIGURE 1.47 – Comparaison des temps de calcul entre le Python et d’autres langages de programmation avec différents algorithmes classiques

Source : <https://julialang.org/benchmarks>

Mettez la liste des bibliothèques complémentaires que vous identifierez tout le semestre :

Important Python Libraries and Frameworks




FIGURE 1.48 – Les principales bibliothèques de Python 1

Source : LinkedIn



FIGURE 1.49 – Les principales bibliothèques de Python 2

Source : LinkedIn



FIGURE 1.50 – Les principales bibliothèques de Python 3

Source : LinkedIn




FIGURE 1.51 – Les principales bibliothèques de Python 4

Source : LinkedIn

1.6.1 Objectifs à atteindre

- Comprendre les bases de la programmation avec un outil de plus en plus utilisé, y compris dans les logiciels de géomatique comme ArcGIS ou Q-GIS
- Pouvoir utiliser ces bases dans des routines permettant des analyses statistiques univa-

riées, bivariées et multivariées

- Se familiariser avec la programmation afin d’obtenir une culture minimale de ce que c’est pour vos recherches, mais également votre citoyenneté

1.6.2 Syntaxe de base

1.6.3 Éléments d’algorithmique

Les variables

Les opérateurs

Les instructions

Les conditions

Les boucles

Les boucles conditionnelles

Les fonctions et les procédures

Les objets

ALGORITHMIQUE & PYTHON (Première spé)

1. Variables et types

Python est un langage de haut niveau.
Une variable est une "boîte" qui contient une valeur.

Types de base :

- **int** : entiers (...,-2,-1,0,1,2,...)
- **float** : nombres décimaux (...,-1.5,0,2.7...)
- **str** : chaînes de caractères (texte)
- **bool** : booléens (True ou False)

Type	Exemple
int	7 -3 125
float	3.14 -0.5 2.0
str	"bonjour" "maths" "42"
bool	True False

2. Affectation

Le symbole d'affectation est `=`.
Il permet de stocker une valeur dans une variable.

```
a = 5
b = 2.5
c = "Python"
d = True
```

On peut réaffecter une nouvelle valeur :

```
a = a + 1      # a devient 6
c = c + " !"    # c devient "Python !"
```

3. Entrées / sorties

Entrée clavier : `input()` renvoie une chaîne de caractères.

```
nom = input("Votre nom : ")
```

Sortie écran : `print()` affiche.

```
print("Bonjour", nom)
print(2 + 3)
print("La valeur de x est", 7)
```

4. Conditions

Exécution conditionnelle avec `if`, `elif`, `else`.

```
x = 3
if x > 0 :
    print("positif")
elif x == 0 :
    print("nul")
else :
    print("négatif")
```

Opérateurs utiles :

- `==` : égal
- `!=` : différent
- `<` : strict. inférieur
- `>` : strict. supérieur
- `<=` : inférieur ou égal
- `>=` : supérieur ou égal

5. Boucle for

Permet de répéter un bloc un nombre connu de fois.

```
for i in range(5):
    print(i)      # 0 1 2 3 4
```

`range(a)` → 0 à a-1
`range(a, b)` → a à b-1
`range(a, b, k)` → a à b-1 avec pas k

Exemple : somme des n premiers entiers


```
n = 5
s = 0
for i in range(1, n+1):
    s = s + i
print(s)      # affiche 15
```

6. Boucle while

Répète un bloc tant qu'une condition est vraie.

```
i = 0
s = 0
while i < 5:
    s = s + i
    i = i + 1
print(s)      # affiche 10
```

Schéma de principe :



7. Fonctions Python

Définir une fonction avec `def`.

```
def carre(x):
    return x*x
```

Une fonction peut avoir plusieurs paramètres.

Utilisation :

```
a = carre(5)
print(a)      # 25
```

L'instruction `return` renvoie un résultat.

8. Listes

Une liste est une collection ordonnée d'éléments.

```
L = [2, 5, 8, 1]
print(L[0])      # 2
print(L[2])      # 8
```

Opérations utiles :

- `len(L)` → longueur de la liste
- `L.append(x)` → ajoute x à la fin
- `L.remove(x)` → supprime x (la 1^{re} occurrence)
- `L[i]` → i^{ème} élément (i commence à 0)

9. Algorithmes classiques

a) Somme d'une liste

```
s = 0
for x in L:
    s = s + x
```

b) Maximum d'une liste

```
m = L[0]
for x in L:
    if x > m:
        m = x
```

c) Moyenne d'une liste

```
s = 0
for x in L:
    s = s + x
moy = s / len(L)
```

d) Recherche d'un élément

```
x = 5
trouve = False
for y in L:
    if y == x:
        trouve = True
```

10. Exemples corrigés

1. Factorielle

Calculer n! (n entier naturel).

```
def factorielle(n):
    f = 1
    for i in range(1, n+1):
        f = f * i
    return f
```

factorielle(5) → 120

2. FizzBuzz

Afficher les nombres de 1 à n.
Pour les multiples de 3, afficher "Fizz", de 5, "Buzz", de 3 et 5, "FizzBuzz".

```
n = 15
for i in range(1, n+1):
    if i % 3 == 0 and i % 5 == 0:
        print("FizzBuzz")
    elif i % 3 == 0:
        print("Fizz")
    elif i % 5 == 0:
        print("Buzz")
    else:
        print(i)
```

3. Nombres premiers

Tester si n est premier.

```
def premier(n):
    if n < 2:
        return False
    for d in range(2, int(n**0.5)+1):
        if n % d == 0:
            return False
    return True
```

premier(17) → True
 premier(12) → False

11. À retenir

Indentation	L'indentation (4 espaces) est obligatoire en Python.
Commentaires	# commentaire sur une ligne
Conversion	<code>int(x)</code> , <code>float(x)</code> , <code>str(x)</code>
Booléens	True et False
Opérateurs	+, -, *, /, //, %, ** et comparaisons
Incrémentation	<code>i = i + 1</code> (pas <code>++i</code>)
Affichage	<code>print()</code> peut prendre plusieurs arguments séparés par des virgules.
Chaînes	On peut concaténer avec <code>+</code> ou répéter avec <code>*</code> : <code>"ha"*3</code>

RÉSUMÉ EXPRESS	Affectation	Condition	Boucle for	Boucle while	Fonction	Liste	Entrée / Sortie
	<code>a = 5</code>	<code>if condition:</code> ...	<code>for i in range(n):</code> ...	<code>while condition:</code> ...	<code>def f(x):</code> ... <code>return ...</code>	<code>L = []</code> <code>L.append(x)</code> <code>L[i]</code>	<code>input()</code> <code>print()</code>

HYJ

FIGURE 1.52 – Algorithmique en Python

Source : LinkedIn



GeoPandas

Your Essential Cheat Sheet for GeoPandas


GeoPandas

Simplify geospatial analysis in Python.

Powerful. Efficient. Built on Pandas.

GeoPandas extends the power of pandas to work with geospatial data—making it easy to analyze, visualize, and understand the world around you.





• Key Methods. Real Impact. •

1 What is GeoPandas?

An open-source Python library that extends pandas for geospatial data.

- Built on Pandas
- Works with vector data
- Supports spatial operations
- Integrates with Shapely, Fiona, PyProj and Matplotlib

2 GeoPandas Workflow



1. Load Data
Read spatial data into a GeoDataFrame



2. Explore Data
Check data, CRS, bounds, and geometry



3. Process Data
Filter, select, transform and perform spatial operations



4. Visualize
Plot data on maps for better understanding



5. Save / Export
Export the results in various formats

3 Data Input / Output

Read Data


```
gpd.read_file('data.shp')
gpd.read_file('data.geojson')
gpd.read_file('data.gpkg')
gpd.read_postgis(sql, con)
gpd.read_parquet('data.parquet')
```

Write / Export Data

```
gdf.to_file('output.shp')
gdf.to_file('output.geojson', driver='GeoJSON')
gdf.to_postgis('table_name', con, if_exists='replace')
gdf.to_parquet('output.parquet')
```

4 Explore & Inspect Data

<code>gdf.head()</code>	View first few rows
<code>gdf.info()</code>	Summary of GeoDataFrame
<code>gdf.crs</code>	Check Coordinate Reference System
<code>gdf.to_crs(eps=4326)</code>	Reproject to another CRS
<code>gdf.geometry</code>	Access the geometry column
<code>gdf.total_bounds</code>	Get dataset bounds [minx, miny, maxx, maxy]
<code>gdf.plot()</code>	Quick plot of the data
<code>gdf.describe(include='all')</code>	Statistical summary



5 Data Selection & Filtering

<code>gdf['column']</code>	Select column(s)
<code>gdf[['col1', 'col2']]</code>	Select multiple columns
<code>gdf.loc[condition]</code>	Filter rows by condition
<code>gdf.iloc[:]</code>	Select rows by index position
<code>gdf.query('pop > 1000')</code>	Query the data
<code>gdf.isna().sum()</code>	Count missing values
<code>gdf.dropna()</code>	Drop missing values

6 Spatial Operations

<code>gdf.buffer(distance)</code>	Buffer geometries
<code>gdf.overlay(gdf2, how='intersect')</code>	Overlay / intersection
<code>gdf.sjoin(gdf2, how='inner')</code>	Spatial Join
<code>gdf.clip(mask)</code>	Clip with mask layer
<code>gdf.dissolve(by='column')</code>	Dissolve geometries
<code>gdf.unary_union</code>	Union of all geometries
<code>gdf.distance(other_geom)</code>	Distance to other geometry
<code>gdf.centroid</code>	Get centroids


7 Useful Methods & Attributes

<code>gdf.area</code>	Calculate area
<code>gdf.length</code>	Calculate length
<code>gdf.boundary</code>	Get boundary
<code>gdf.explode()</code>	Explode multi-part geometries
<code>gdf.sort_values('column')</code>	Sort values
<code>gdf.reset_index(drop=True)</code>	Reset index
<code>gdf.rename(columns={})</code>	Rename columns

8 Visualization

```
gdf.plot()
gdf.plot(column='pop', cmap='OrRd', legend=True)
gdf.plot(edgecolor='black', facecolor='none')
gdf.explore()
```

Interactive map (requires folium)



9 Common Workflow Example

```
import geopandas as gpd
gdf = gpd.read_file('data.shp')
gdf = gdf.to_crs(eps=4326)
gdf = gdf[gdf['pop'] > 1000]
gdf_buffer = gdf.buffer(1000)
gdf_result = gpd.overlay(gdf, gdf_buffer, how='intersect')
gdf_result.plot(column='pop', cmap='YlGnBu', legend=True)
gdf_result.to_file('result.gpkg', driver='GPKG')
```

- Import library
- Load data
- Reproject
- Filter data
- Buffer
- Spatial overlay
- Visualize
- Export



Key Takeaway

GeoPandas provides a simple yet powerful set of tools for spatial data analysis. Combine it with Shapely for geometry operations and Matplotlib for visualization—and you have everything you need for any GIS workflow in Python.


+

+


Learn more at geopandas.org

FIGURE 1.53 – Présentation rapide de GeoPandas

Source : LinkedIn

Conclusion

Si vous maîtrisez la manière d'utiliser ces éléments **presque** universels à chaque langage de programmation, vous pourrez apprendre n'importe quel autre langage.

PYTHON CHEAT SHEET

Basic Commands:

- `print("Hello, World!")`: Display output
- `type(x)`: Get data type of x
- `id(x)`: Get memory address of x
- `help()`: Show documentation
- `dir(obj)`: List object attributes and methods

Conditional Statements

- `for`: Iterates over a sequence.
- `while`: Runs while a condition is true.
- `break`: Exits the loop.
- `continue`: Skips to the next iteration.
- `pass`: Does nothing (placeholder).

File Handling

- `open("file.txt", "r")`: Read file
- `open("file.txt", "w")`: Write file
- `open("file.txt", "a")`: Append file
- `file.read()`: Read file content
- `file.readline()`: Read one line
- `file.write("text")`: Write to file
- `file.close()`: Close file
- Use `with open("file.txt", "w") as f:` for safe handling

List Methods

- `append(x)`: Add element to end
- `insert(i, x)`: Insert at index i
- `remove(x)`: Remove first occurrence of x

Variables & Data Types:

- `int`: Whole numbers.
- `float`: Decimal numbers.
- `str`: Text values.
- `bool`: True or False values.
- `list`: Ordered, changeable collection.
- `tuple`: Ordered, unchangeable collection.
- `set`: Unordered, unique collection.
- `dict`: Key-value pair collection.

Functions

- `def`: Define a new function
- `return`: Return value from a function
- `lambda`: Create a anonymous function

Built-in Functions

- `len(x)`: Length of x
- `max(x)`: Maximum value in x
- `min(x)`: Minimum value in x
- `sum(x)`: Sum of elements
- `sorted(x)`: Sorted list
- `range(start, stop, step)`: Generate sequence
- `map(func, iterable)`: Apply function to elements
- `filter(func, iterable)`: Filter elements
- `zip(iter1, iter2)`: Combine iterables
- `pop(i)`: Remove element at index i
- `reverse()`: Reverse list order
- `sort()`: Sort list

FIGURE 1.54 – Python Cheat Sheet

Source : LinkedIn

Conseils pour bien apprendre : la méthode des 4C (Nathan Dupin, développeur)

1. Comprendre, la base avant tout
 - Comprendre les concepts clés
 - Créer une architecture sans copier-coller

- Partir sur 80 % de compréhension, 20 % d'exécution
- 2. Créer, le code comme un jeu
 - Petits projets et défis
 - Ludification du code
 - Apprentissage par l'erreur
- 3. Collaborer, la force de l'union
 - *Pair programming*
 - *Code review* et *feedback*
 - Progresser ensemble
- 4. Consolider, la répétition intelligente
 - Projets complexes
 - *Refactoring* et optimisation
 - Expertise par une pratique régulière

Personne n'apprendra de la même manière

Personne n'apprendra de la même manière. En fonction de plusieurs paramètres qui vous sont propres, vous n'apprendrez ni à la même vitesse que vos camarades, ni de la même manière (Fig. 1.55), d'où la pédagogie de la classe inversée.




FIGURE 1.55 – Les quatre profils d'apprentissage en informatique

Source : LinkedIn




FIGURE 1.56 – Courbe de naturalisation des technologies : comment apprend-t-on à s'en servir ?

Source : LinkedIn



FIGURE 1.57 – Six erreurs à éviter lorsqu'on veut apprendre l'analyse des données

Source : LinkedIn





FIGURE 1.58 – Comment apprendre efficacement ?

Source : LinkedIn

**L'ÉCHEC, CE N'EST PAS TOMBER,
MAIS REFUSER DE SE REMETTRE EN SELLE**



2024 ©marialuisaengels.com

FIGURE 1.59 – Comment appréhender l'échec ?
Source : LinkedIn

Conseils pour bien travailler chez vous

Vous **devez** travailler 42h00 chez vous sur ce module, soit 3h30 par semaine.

Liens des logiciels Git et Docker (Windows)


Pour télécharger Git en local, il faut aller au lien : <https://git-scm.com/downloads>.

Pour télécharger Docker, il faut aller au lien :

<https://docs.docker.com/desktop/setup/install/windows-install>. Télécharger l'exécutable Docker Desktop for Windows - x_-_64.

Rendre visible les dossiers cachés et les extensions de fichier (Windows)

1. Dans un dossier, cliquer sur l'onglet « Affichage ».
2. Sur l'icône « Options », cliquer sur la petite flèche pour afficher « Modifier les options des dossiers et de recherche »
3. Dans la fenêtre, faire ce qui est indiqué sur la figure 1.60



Dans n'importe quel dossier, vous avez un onglet appelé "Options"

Sélectionnez "Afficher les fichiers cachés"

Décocher "Masquer les extensions des fichiers dont le type est connu"

FIGURE 1.60 – Fenêtre permettant de rendre visible les dossiers cachés et les extensions de fichier sous Windows

Installer Python sous Windows sans passer par Docker (Windows)

Certains systèmes Windows 10 (versions avant 2022) ne supportent pas Docker. Vous pouvez installer Python dans votre système à partir du lien suivant :

<https://www.python.org/downloads/windows>, de préférence une version 3.6

1. Télécharger l'exécutable 64 bits
2. Exécuter le fichier téléchargé
3. Sur la première fenêtre, cocher la case indiquant d'installer en PATH (c'est-à-dire en variable d'environnement système)
4. Lancer un terminal et lancer une console Python

```
C:\...> python
```

5. Cliquer sur le bouton qui s'affiche pour finir l'installation
6. Vérifier l'installation en tapant :

```
C:\...> python --version
```

ou

```
C:\...> python
```

Pour quitter la console Python, taper la commande `exit()`.

7. Installer l'installateur de paquets :

```
C:\...> python -m pip --upgrade pip
```

8. Télécharger le fichier `requirements.txt`
9. Ouvrir un terminal dans le dossier contenant le fichier `requirements.txt` et y taper :

```
C:\...> pip install -r requirements.txt
```

Cela installe toutes les bibliothèques pour exécuter les fichiers `main.py` des différents exercices. Pour exécuter un fichier `main.py`, la procédure est la même qu'avec Docker. Vous devez ouvrir le terminal dans le dossier contenant le fichier `main.py`. Y taper la commande (Fig. 1.61) :

```
C:\...> python main.py
```

pour exécuter le code. À chaque modification, vous devez lancer cette commande.

Quelles sont les différences pratiques entre Docker/Python et Python ?

1. À la différence du conteneur Docker où les mises à jour sont automatiques, il faudra régulièrement mettre à jour les paquets contenus dans le fichier `requirements.txt`.
2. À la différence du conteneur Docker, il sera plus difficile de désinstaller Python une fois votre semestre terminé. Il restera toujours des reliquats dans votre système.
3. À la différence du conteneur Docker, vous n'aurez peut-être pas tous la même version du Python.
4. À la différence du conteneur Docker, ce que je viens d'expliquer est à adapter pour les systèmes MAC sur lesquels cela ne fonctionne pas.

Attention ! Ne jamais mettre vos fichiers dans le fichier OneDrive - Personal.




FIGURE 1.61 – Visual Studio Code – Écran 8

Installer Python sous UNIX sans passer par Docker (Mac O/S ou Linux)

En principe, l'interpréteur Python est installé par défaut dans les systèmes UNIX (Mac O/S et distributions Linux).

Pour l'exécuter, dans le dossier `src` là où est votre fichier `main.py`, ouvrez un terminal et taper :

```
C:\...> python main.py
```

ou

```
C:\...> python3 main.py
```

Il est impossible de savoir quelle commande va fonctionner à l'avance. Testez les deux, et voyez celle qui marche.

Nettoyer Docker

Lorsque vous avez fini votre séance, il faut nettoyer les Images Docker (Fig. 1.62).

Deux cas sont possibles soit votre image est `In use`, soit elle est `Unused`. Si elle est `Unused`, il suffit de cocher l'image que vous voulez supprimer, et de cliquer sur le bouton rouge en haut à droite `Delete`. Dans le cas contraire, il faut cliquer sur `In use` (Fig. 1.62). La fenêtre de la figure 1.63 s'ouvre. Cliquez sur tout, puis cliquer sur le bouton `Delete`. Une fenêtre s'ouvre (Fig. 1.64). Cliquez sur `Delete forever`.

Vous devez revenir à la liste de toutes vos images. Si l'image est `Unused`, alors cliquer sur l'image à supprimer (Fig. 1.65) et cliquer sur `Delete`.




FIGURE 1.62 – Nettoyage de Docker – Écran 1




FIGURE 1.63 – Nettoyage de Docker – Écran 2

Il faut nettoyer les Builds en sélectionnant les Builds à supprimer (Fig. 1.66), puis en cliquant sur `Delete forever` (Fig. 1.67).

Il faut nettoyer les Volumes en sélectionnant les Volumes à supprimer (Fig. 1.68), puis en cliquant sur `Delete forever` (Fig. 1.69).




FIGURE 1.64 – Nettoyage de Docker – Écran 3




FIGURE 1.65 – Nettoyage de Docker – Écran 4




FIGURE 1.66 – Nettoyage de Docker – Écran 5




FIGURE 1.67 – Nettoyage de Docker – Écran 5




FIGURE 1.68 – Nettoyage de Docker – Écran 6




FIGURE 1.69 – Nettoyage de Docker – Écran 7

Méthodologie générale de chaque séance

Le cours est un mélange subtil entre analyse de données en géographie, apprentissage de Python et connaissances statistiques. Il est **progressif**. Si vous loupez une séance sans la rattraper, vous prenez le risque de ne rien comprendre à la séance suivante.

Vous êtes autonome dans votre apprentissage. C'est l'unique manière d'acquérir un savoir-faire. Je ne répéterais pas en boucle ce qui a déjà été vu, surtout pour les absents.

Que faire en arrivant en cours ? (environ 10 min)

1. Allumer votre poste attribué
2. Aller sur GitHub télécharger l'exercice du jour dans le bon dossier de l'architecture
3. Ouvrir le Docker Desktop
4. Se connecter à son compte Docker
5. Lancer Python avec la commande `docker-compose up -d(--build)`
6. Poser des questions si des points dans le topo n'ont pas été compris

Que faire pendant le cours ? (environ 1h45min)

- Faire l'exercice du jour en n'oubliant pas de rédiger le rendu de la séance
- Poser des questions à l'enseignant sans le monopoliser (merci de penser à vos camarades)
- Même si le rendu est individuel, ne pas hésiter à travailler en groupe, à vous poser des questions entre vous, la séance, sans être un bazar total, doit être animée pour rendre les statistiques joyeuses

Que faire en quittant le cours ? (environ 5 min)

1. Éteindre le Docker Compose avec la commande `docker-compose down`
2. Se déconnecter de son compte Docker
3. Éteindre le Docker Engine
4. Éteindre votre poste attribué

Que faire entre les séances de cours ?

1. Lire la documentation du cours suivant
2. Faire les exercices de compréhension
3. Ne pas hésiter à se documenter
4. Ne pas hésiter à contacter, dans la limite du raisonnable, l'enseignant pour qu'il puisse vous aider en cas de blocage dans votre apprentissage

5. Prendre en main le langage de programmation `Python` en codant régulièrement de petits programmes en fonction de vos besoins pour vos mémoires
6. Pour les matheux, lire le contenu du formulaire mathématique régulièrement




FIGURE 1.70 – La différence de sommeil entre un non programmeur et un programmeur

Source : LinkedIn

Peut-on utiliser l'intelligence artificielle ?

La réponse est affirmative à condition que vous vous en serviez comme un outil d'apprentissage. Très vite, si vous refusez d'apprendre, l'intelligence artificielle pourra vous faire faire n'importe quoi.




FIGURE 1.71 – Coder avec l'intelligence artificielle

Source : LinkedIn



FIGURE 1.72 – Contre-exemple de l'utilisation de l'intelligence artificielle

Source : LinkedIn




FIGURE 1.73 – Points négatifs de l'usage de l'intelligence artificielle

Source : LinkedIn




FIGURE 1.74 – Apprentissage et intelligence artificielle

Source : LinkedIn

Carte de l'exploration scientifique

Sur ce graphique, chaque point est une découverte scientifique
(échantillon de 10 000 points sur 41 millions d'articles analysés)

- En rouge : les recherches utilisant l'IA
- En bleu: les recherches n'utilisant pas d'IA



Les **recherches sans IA** explorent un **territoire plus vaste**
que les **recherches utilisant l'IA**

FIGURE 1.75 – Recherche et intelligence artificielle

Source : LinkedIn

Séance 2

Principes généraux de la statistique et paramètres statistiques élémentaires

C'est la séance qui vous demandera le plus d'investissement.

Objectifs de la séance

- Comprendre la différence entre statistique et statistiques
- Comprendre ce qu'est le hasard
- Comprendre d'où viennent les données en géographie
- Comprendre la notion de probabilités et son lien avec les statistiques
- Connaître les types de statistique
- Bien apprendre ou réviser le vocabulaire statistique
- Bien distinguer les deux grands types de variable
- Comprendre ce qu'est une amplitude, une densité, une classe, un effectif et une fréquence
- Connaître et comprendre les paramètres de position : espérance, moyenne, médiane, mode, médiale
- Connaître et comprendre les paramètres de dispersion : écart type, variance, coefficient de variation, étendue, écart interquantile, écart moyen, boîte de dispersion
- Connaître et comprendre les paramètres de forme : moments, coefficients β_1 et β_2 de Pearson et de Fisher

Ressources GitHub à lire avant la séance

Afin de limiter la consommation de papier, il faut vous rendre à la page suivante :
<https://github.com/MaximeForrieux/Sorbonne-M1-Analyse-de-donnees/tree/main/Seance-02>.

Exercice du jour

Il s'agit d'apprendre à utiliser les bibliothèques NumPy et Pandas afin de calculer : une amplitude, une densité, une classe, un effectif et une fréquence.



Data Cleaning in Python (Pandas)

[import pandas as pd](#)

Step 1: Load the Data

```
df = pd.read_csv('your_file.csv') # For CSV files
df = pd.read_excel('your_file.xlsx') # For Excel files
df = pd.read_json('your_file.json') # For JSON files
```

Step 3: Check Missing Values (Numerically + Visually)

```
df.isnull().sum() # Count of m. values in each column
import missingno as msno # This shows a bar chart of missing values.
msno.bar(df)
```

Step 5: Remove Duplicates

```
df.drop_duplicates(inplace=True)
# Delete duplicate rows
```

Step 7: Strip Whitespace from Column N.

```
df.columns = df.columns.str.strip()
# Remove leading/trailing spaces in column names
```

Step 9: Fix Inconsistent Labels (Spelling or Format Issues)

```
df['Payment_method'] =
df['Payment_method'].replace({
    'cc': 'Credit Card',
    'cash': 'Cash'})
```

Step 11: Drop Unnecessary Columns

```
df.drop(columns=['Unnecessary_column'],
inplace=True)
# Remove columns you don't need
```

Step 13: Split Date into Year and Month

```
df['year'] = df['date'].dt.year # Extract year
df['month'] = df['date'].dt.month # Extract month
```

Step 14: Save the Cleaned Data

```
df.to_csv('cleaned_data.csv', index=False) # Save to a new CSV file without row numbers
from google.colab import files # Download the cleaned CSV file to your computer
files.download('cleaned_data.csv')
```

Step 2: Understand the Dataset

```
df.info() # Show column, n, non-null count & data.type
df.describe() # Summary statistics for numerical columns
df.head() # Displays the first 5 rows of the dataset
df.shape # Shows the number of (rows, cols)
df.columns # Lists all column names
```

Step 4: Handle Missing Values

```
df['col'] = df['col'].fillna(df['col'].mean())
# Fill missing values with the mean, median, mode.
df.dropna(inplace=True)
# Remove rows with missing values.
```

Step 6: Fix Data Types

```
df['date'] = pd.to_datetime(df['date'])
# Convert to datetime format
df['amount'] = df['amount'].astype(float)
# Convert to float
```

Step 8: Rename Columns for Consistency

```
df.columns = df.columns.str.lower().str.replace(' ', '_')
# Make all column names simple
'Customer Name' becomes 'Customer_name'
df.rename(columns={'Cust_id': 'Customer_id'},
inplace=True) # Rename Specific Columns Only
```

Step 10: Remove Outliers

```
Q1 = df['amount'].quantile(0.25)
Q3 = df['amount'].quantile(0.75)
IQR = Q3 - Q1
df = df[(df['amount'] >= Q1 - 1.5 * IQR) & (df['amount'] <=
Q3 + 1.5 * IQR)]
If most sales are around ₹500, and one row says ₹50,000
```

Step 12: Create New Columns

```
df['Total_price'] = df['quantity'] * df['Unit_price']
# Add a new useful column
```



Pranav Borge





IF YOU FOUND THIS USEFUL, FOLLOW ME



FIGURE 2.1 – Python : Pandas, les commandes de base

Source : LinkedIn

Python Commands for Statistical Analysis Cheatsheet

by Gina Acosta

1. Data Import and Manipulation

```
# Reads CSV file into pandas DataFrame
df = pd.read_csv('file.csv')
# Generates basic statistical summary of numerical columns
df.describe()
# Groups data and calculates multiple statistics
df.groupby('column').agg(['mean', 'std'])
# Calculates percentage distribution of values
df['column'].value_counts(normalize=True)
```

2. Statistical Functions

```
# Calculates mean along specified axis
np.mean(data, axis=0)
# Computes median, robust to outliers
np.median(data, axis=0)
# Computes quartiles of dataset
np.percentile(data, [25, 50, 75])
# Computes standard deviation with N-1 denominator
np.std(data, ddof=1)
# Returns correlation coefficient matrix
np.corrcoef(x, y)
# Computes covariance matrix
np.cov(x, y)
# Calculates correlation and p-value
stats.pearsonr(x, y)
# Chi-square goodness of fit test
stats.chisquare(obs, exp)
# Standardize multiple columns at once
stats.zscore(df[['col1', 'col2']])
```

3. Essential Data Visualization

```
# Sets figure size for better visualization
plt.figure(figsize=(10, 6))
# Advanced histogram with grouping
sns.histplot(data=df, x='col', hue='group')
# Box plot comparing groups
sns.boxplot(x='group', y='value', data=df)
# Scatter with color grouping
sns.scatterplot(data=df, x='x', y='y', hue='group')
# Correlation matrix with values
sns.heatmap(corr, annot=True, cmap='coolwarm')
# Matrix of scatter plots for all variables
sns.pairplot(df, hue='group')
# Shows distribution shape by group
sns.violinplot(x='group', y='value', data=df)
```

FIGURE 2.2 – Python : Commandes statistiques de base

Source : LinkedIn

9 Must-Know Python-Pandas Operations for Working with Data

By Brij Kishore Pandey

Data Import

```
pd.read_csv('file.csv')
pd.read_excel('file.xlsx', sheet_name='Sheet1')
pd.read_sql(query, connection)
pd.read_json('file.json')
pd.read_parquet('file.parquet')
```

Data Selection

```
df['column'] # Single column
df.loc['row', 'col'] # Label based
df.iloc[0:5, 0:2] # Integer based
df.query('col > 5') # SQL-like filtering
df[df['col'].isin(['A', 'B'])] # Multiple values
```

Data Manipulation

```
df.groupby('col').agg({'col2': ['mean', 'sum']})
df.merge(df2, on='key', how='left')
df.pivot_table(values='val', index='idx')
df.sort_values(['col1', 'col2'])
df.melt(id_vars='id', value_vars=['A', 'B'])
df.apply(lambda x: x*2) # Apply function
```

Statistics

```
df.describe() # Summary statistics
df['col'].agg(['mean', 'median', 'std'])
df['col'].value_counts(normalize=True)
df.corr(method='pearson')
df.cov() # Covariance matrix
df.quantile([0.25, 0.5, 0.75])
```

Data Cleaning

```
df.dropna(subset=['col'], how='any')
df.fillna(method='ffill') # Forward fill
df.drop_duplicates(subset=['col'])
df['col'].replace({'old': 'new'})
df['col'].astype('category')
df.interpolate(method='linear')
```

Time Series

```
df.resample('M').mean() # Monthly average
df.rolling(window=7).mean()
df.shift(periods=1) # Shift values
pd.date_range('2024', periods=12, freq='M')
df.asfreq('D', method='ffill')
df['date'].dt.strftime('%Y-%m-%d')
```

String Operations

```
df['col'].str.contains('pattern')
df['col'].str.extract('(\d+)')
df['col'].str.split('_').str[0]
df['col'].str.lower()
df['col'].str.strip()
df['col'].str.replace(r'\s+', ' ')
```

Advanced Features

```
df.pipe(func) # Method chaining
pd.eval('df1 + df2') # Expression eval
df.memory_usage(deep=True)
df.select_dtypes(include='number')
df.nlargest(5, 'col') # Top N values
df.explode('col') # Expand list column
```

Data Export

```
df.to_csv('output.csv', index=False)
df.to_excel('output.xlsx', sheet_name='Sheet1')
df.to_parquet('output.parquet')
df.to_json('output.json', orient='records')
```

Tips & Best Practices

- Use `.copy()` when creating DataFrame views
- Chain operations with method chaining
- Set `dtype='category'` for categorical columns
- Use `inplace=True` carefully, prefer reassignment

FIGURE 2.3 – Python : Pandas, la gestion des fichiers

Source : LinkedIn

Data Storytelling


Chart	Types of Chart	When to Use it	Example of Use Case
	Bar Chart	Compare sales across categories	Displays growth of different products
	Line Chart	Show trends over time	Display the growth of website traffic over a budget
	Pie Chart	Highlight proportions percentages	Display the growth of expenses in budget
	Scatter plot	Represent relationships between variables	Identify correlations between marketing spend and ROI
	Histogram	Visualize the distribution of data	Analyze aggregate distribution of survey respondents
	Map	Visualize geospatial data	Display regional sales performance on a map
	Heatmap	Visualize data density and patterns in large datasets	Identify hotspots of customer activity in a shopping mall

FIGURE 2.4 – Les principales manières de visualiser les données avec Python

Source : LinkedIn

Questions de cours

Les réponses comptent pour 10 % de la note finale du niveau 1.

1. Quel est le positionnement de la géographie par rapport aux statistiques ?
2. Le hasard existe-t-il en géographie ?
3. Quels sont les types d'information géographique .
4. Quels sont les besoins de la géographie au niveau de l'analyse de données ?
5. Quelles sont les différences entre la statistique descriptive et la statistique explicative ?
6. Quelles sont les types de visualisation de données en géographie ? Comment choisir celles-ci ?
7. Quelles sont les méthodes d'analyse de données possibles ?
8. Comment définiriez-vous : (a) population statistique ? (b) individu statistique ? (c) caractères statistiques ? (d) modalités statistiques ? Quels sont les types de caractères ? Existe-t-il une hiérarchie entre eux ?
9. Comment mesurer une amplitude et une densité ?
10. À quoi servent les formules de Sturges et de Yule ?
11. Comment définir un effectif ? Comment calculer une fréquence et une fréquence cumulée ? Qu'est-ce qu'une distribution statistique ?
12. Quel caractère est le plus général : le caractère quantitatif ou le caractère qualitatif ? Justifier pourquoi.
13. Que sont les caractères quantitatifs discrets et caractères quantitatifs continus ? Pourquoi les distinguer ?
14. **Paramètres de position**
 - Pourquoi existe-t-il plusieurs types de moyenne ?
 - Pourquoi calculer une médiane ?
 - Quand est-il possible de calculer un mode ?
15. **Paramètres de concentration**
 - Quel est l'intérêt de la médiale et de l'indice de C. Gini ?
16. **Paramètres de dispersion**
 - Pourquoi calculer une variance à la place de l'écart à la moyenne ? Pourquoi la remplacer par l'écart type ?
 - Pourquoi calculer l'étendue ?
 - À quoi sert-il de créer un quantile ? Quel(s) est (sont) le(s) quantile(s) le(s) plus utilisé(s) ?
 - Pourquoi construire une boîte de dispersion ? Comment l'interpréter ?
17. **Paramètres de forme**
 - Quelle différence faites-vous entre les moments centrés et les moments absolus ? Pourquoi les utiliser ?
 - Pourquoi vérifier la symétrie d'une distribution et comment faire ?

Mise en œuvre avec Python

Il faut vous reporter au livret spécifique à votre spécialité (ACA, GeoSUDS et SCT).

Approfondissement

- Connaître les propriétés de l'espérance, de la variance et de l'écart type
- Comprendre l'indice de concentration
- Apprendre ou réviser les notions élémentaires sur les probabilités :
 - le dénombrement ;
 - les axiomes de Kolmogorov ;
 - les variables aléatoires ;
 - les lois de probabilité.

Deuxième partie

Statistique univariée

Séance 3

Distributions statistiques

Objectifs de la séance

- Connaître, et surtout reconnaître, les distributions statistiques des variables discrètes
- Connaître, et surtout reconnaître, les distributions statistiques des variables continues
- Bien comprendre le lien entre probabilités et distributions statistiques

Ressources GitHub à lire avant la séance

<https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees/tree/main/Seance-03>

Exercice du jour

Questions de cours

Les réponses comptent pour 10 % de la note finale du niveau 1.

1. Quels critères mettriez-vous en avant pour choisir entre une distribution statistique avec des variables discrètes et une distribution statistique avec des variables continues ?
2. Expliquez selon vous quelles sont les lois les plus utilisées en géographie ?




FIGURE 3.1 – Comment choisir la bonne distribution statistique ?

Source : LinkedIn

LES LOIS DE PROBABILITÉ USUELLES

LOI	Définition	Formule / Densité	Esperance $E[X]$	Variance $V(X)$
Uniforme Discrète	Tous les résultats ont la même probabilité	$p(x=k) = \frac{1}{n}$ pour $k \in \{1, \dots, n\}$	$\frac{n+1}{2}$	$\frac{n^2-1}{12}$
Bernoulli	2 résultats possibles : succès $\rightarrow 1$ ou échec $\rightarrow 0$	$P(X=1) = p$ $P(X=0) = 1-p$	p	$p(1-p)$
Binomiale	Somme de n essais indépendants de Bernoulli	$p(x=k) = \binom{n}{k} p^k (1-p)^{n-k}$ avec $\binom{n}{k} = \frac{n!}{k!(n-k)!}$ coeff binomiale	np	$np(1-p)$
Géométrique	Nombre d'essais nécessaires pour obtenir le 1 ^{er} succès	$p(x=k) = (1-p)^{k-1} p$ $k \geq 1$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
Poisson	Nombre d'événements rares survenant dans un intervalle fixe	$P(X=k) = \frac{\lambda^k e^{-\lambda}}{k!}$ $k \geq 0$	λ	λ
Uniforme Continue	Tous les intervalles de même longueur ont la même probabilité	$f(x) = \frac{1}{b-a}$ $x \in [a, b]$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
Exponentielle	Temps d'attente entre 2 événements dans un processus de poisson	$f(x) = \lambda e^{-\lambda x}$ $x \geq 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Normale (Gaussienne)	Modélise de nombreux phénomènes naturels, avec une courbe en cloche	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2

- Lois discrètes
- Lois continues



FIGURE 3.2 – Lois de probabilité usuelles

Source : LinkedIn




FIGURE 3.3 – Liens entre les lois de probabilité usuelles

Source : LinkedIn

Mise en œuvre avec Python

Il faut vous reporter au livret spécifique à votre spécialité (ACA, GeoSUDS et SCT).

Approfondissement

- Réviser les applications dans le plan
- Réviser les règles de calcul élémentaire (ou l'algèbre des nombres réels)
- Réviser la géométrie descriptive
- Réviser la trigonométrie
- Comprendre la loi des grands nombres
- Comprendre le théorème central limite
- Apprendre la définition d'une variable aléatoire
- Comprendre ce qu'est une fonction caractéristique

Séance 4

Statistiques inférentielles

Objectifs de la séance

- Comprendre la notion d'échantillonnage et ses principales méthodes
- Comprendre les notions d'estimateur et d'estimation
- Comprendre la notion de statistique exhaustive
- Comprendre comment choisir un estimateur
- Comprendre comment estimer un paramètre par intervalle de confiance
- Comprendre les différentes méthodes d'estimation d'un paramètre
- Comprendre ce qu'est un test statistique

Ressources GitHub à lire avant la séance

<https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees/tree/main/Seance-04>

Exercice du jour

Questions de cours

Les réponses comptent pour 20 % de la note finale du niveau 1.

Les réponses comptent pour 10 % de la note finale du niveau 2.

1. Comment définir l'échantillonnage. Pourquoi ne pas utiliser la population en entier ?
Quelles sont les méthodes d'échantillonnage ? Comment les choisir ?
2. Comment définir un estimateur et une estimation ?
3. Comment distingueriez-vous l'intervalle de fluctuation et l'intervalle de confiance ?
4. Qu'est-ce qu'un biais dans la théorie de l'estimation ?

5. Comment appelle-t-on une statistique travaillant sur la population totale ? Faites le lien avec la notion de données massives ¹ ?
6. Quels sont les enjeux autour du choix d'un estimateur ?
7. Quelles sont les méthodes d'estimation d'un paramètre ? Comment en sélectionner une ?
8. Quels sont les tests statistiques existants ? À quoi servent-ils ? Comment créer un test ?
9. Que pensez-vous des critiques de la statistique inférentielle ?

1. En anglais : *big data*

TECHNIQUES D'ÉCHANTILLONNAGE en Statistique



FIGURE 4.1 – Techniques d'échantillonnage en statistique

Source : LinkedIn





FIGURE 4.2 – Comprendre les types d'erreur

Source : LinkedIn

FIGURE 4.3 – *p-value* et taille d'effet

Source : LinkedIn

FIGURE 4.4 – *p-value* expliquée

Source : LinkedIn




FIGURE 4.5 – Comment choisir le bon test statistique ?

Source : LinkedIn

LES TESTS DE NORMALITÉ

Pour vérifier si vos données suivent une loi normale, on utilise des tests de normalité.

Ils sont indispensables avant d'appliquer de nombreuses méthodes statistiques (régression, tests paramétriques, etc.).

✓ LES PRINCIPAUX TESTS DE NORMALITÉ À CONNAÎTRE

1 Test de Shapiro–Wilk (le plus populaire)

- Adapté aux petits et moyens échantillons ($n < 5000$)
- Très puissant pour détecter la non-normalité
- Hypothèse nulle (H_0) : les données suivent une loi normale
- Si $p < 0,05 \rightarrow$ données non normales

2 Test de Kolmogorov-Smirnov (KS)

- Compare la distribution des données à une loi normale théorique
- Moins sensible que Shapiro–Wilk
- Très utilisé dans les logiciels statistiques
- $p < 0,05 \rightarrow$ non-normalité

3 Test d'Anderson–Darling


- Accorde plus d'importance aux queues de distribution
- Très efficace pour détecter l'asymétrie et les queues épaisses

4 Test de Lilliefors

- Version améliorée du test KS
- Tient compte de l'estimation de la moyenne et de l'écart-type

5 Test de Jarque–Bera

- Basé sur l'asymétrie (skewness) et la kurtosis
- Très utilisé en économétrie
- Adapté aux grands échantillons ($n > 200$)



✓ Méthodes graphiques

- Histogramme
- Q-Q plot
- Boxplot
- Courbe de densité



Utile ? Like | Commente | Partage



@SMSSC

FIGURE 4.6 – Comment choisir son test de normalité ?

Source : LinkedIn



FIGURE 4.7 – Test paramétriques vs. tests non paramétriques

Source : LinkedIn




FIGURE 4.8 – Comment choisir son test non paramétrique ?

Source : LinkedIn

Mise en œuvre avec Python

Il faut vous reporter au livret spécifique à votre spécialité (ACA, EnviTERR, GeoINT, GeoSUDS et SCT).

Approfondissement

- Les vecteurs
- Équations cartésiennes
- Calcul vectoriel dans le plan
- Calcul vectoriel dans un espace à trois dimensions
- Courbes paramétrées
- Barycentre dans le plan et dans l'espace à trois dimensions

Séance 5

Statistique d'ordre des variables qualitatives

Objectifs de la séance

- Savoir définir une statistique d'ordre
- Comprendre ce qu'est la corrélation des rangs

Ressources GitHub à lire avant la séance

<https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees/tree/main/Seance-05>

Exercice du jour

Questions de cours

Les réponses comptent pour 20 % de la note finale du niveau 1.

Les réponses comptent pour 10 % de la note finale du niveau 2.

1. Qu'est-ce qu'une statistique ordinale ? À quel autre statistique catégorielle s'oppose-t-elle ? Quel type de variables utilise-t-elle ? En quoi cela peut matérialiser une hiérarchie spatiale ?
2. Quel ordre est à privilégier dans les classifications ?
3. Quelle est la différence entre une corrélation des rangs et une concordance de classements ?
4. Quelle est la différence entre les tests de Spearman et de Kendal ?
5. À quoi servent les coefficients de Goodman-Kruskal et de Yule ?

Mise en œuvre avec Python

Il faut vous reporter au livret spécifique à votre spécialité (ACA, EnviTERR, GeoINT, GeoSUDS et SCT).

Approfondissement

- Réviser les fonctions mathématiques
- Réviser les fonctions numériques d'une variable réelle
- Comprendre les fonctions numériques de deux variables réelles
- Comprendre les fonctions numériques de plusieurs variables réelles
- Comprendre les approximations de fonction
- Réviser les courbes et les tracés de fonction
- Comprendre les intégrales gaussiennes
- Comprendre la théorie des erreurs
- Comprendre la convergence des suites de variables aléatoires
- Comprendre le produit de convolution de deux variables aléatoires

Troisième partie

Statistique bivariée

Séance 6

Régression et corrélation statistique

Objectifs de la séance

- Comprendre comment choisir deux variables quantitatives
- Comprendre ce qu'est l'indépendance statistique
- Comprendre à quoi sert la covariance
- Comprendre la différence de traitement entre variables quantitatives et qualitatives

Ressources GitHub à lire avant la séance

<https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees/tree/main/Seance-06>

Exercice du jour

Questions de cours

Les réponses comptent pour 15 % de la note finale du niveau 1.

Les réponses comptent pour 15 % de la note finale du niveau 2.

1. Quel est l'intérêt de passer des statistiques univariées aux statistiques bivariées ?
2. Quelles différences opérez-vous entre corrélation et correspondances ? Qu'est-ce qu'un rapport de corrélation ?
3. Quelles différences faites-vous entre les valeurs marginales et les valeurs conditionnelles ? Pourquoi distinguer les deux ?
4. Quelles différences faites-vous entre variance et covariance ?
5. Pourquoi mesurer la corrélation ou l'indépendance ?
6. Quel est le principe de la méthode des moindres carrés ? À quoi sert-elle ?
7. Expliquez en un court paragraphe ce qu'est la théorie de la corrélation (simple) ?

8. En quoi consiste le piège de l'autocorrélation ?
9. Expliquez en un court paragraphe ce qu'est une régression linéaire ?
10. Quelle est la différence entre coefficient de corrélation et coefficient de détermination ?
11. Pourquoi faut-il tester les deux droites de régression ?




FIGURE 6.1 – Régression linéaire

Source : LinkedIn




FIGURE 6.2 – Pourquoi utiliser la méthode des moindres carrés ?

Source : LinkedIn

Mise en œuvre avec Python

Il faut vous reporter au livret spécifique à votre spécialité (ACA, EnviTERR, GeoINT, GeoSUDS et SCT).

Approfondissement

- Comprendre la notation indicielle
- Réviser les suites numériques
- Réviser les séries numériques
- Réviser les nombres complexes
- Réviser les équations différentielles

Séance 7

Relations entre deux variables

Objectifs de la séance

- Comprendre la méthode des moindres carrées
- Comprendre ce qu'est une corrélation simple
- Comprendre ce qu'est une régression linéaire
- Comprendre ce qu'est un intervalle de confiance pour une droite de régression

Ressources GitHub à lire avant la séance

<https://github.com/MaximeForrieux/Sorbonne-M1-Analyse-de-donnees/tree/main/Seance-07>

Exercice du jour

Questions de cours

Les réponses comptent pour 15 % de la note finale du niveau 1.
Les réponses comptent pour 15 % de la note finale du niveau 2.

1. La corrélation entre deux variables qualitatives a-t-elle un sens ? Expliquez votre réponse.
2. Pourquoi pratiquer le test d'indépendance du χ^2 ?
3. Expliquez dans un court paragraphe ce qu'est l'analyse de la variance à simple entrée.
4. Qu'est-ce qu'un rapport de corrélation ? Quelles différences avec la correspondance ?
5. Qu'est-ce qu'une analyse factorielle ?
6. Expliquez en un court paragraphe ce qu'est l'analyse factorielle des correspondances.

Mise en œuvre avec Python

Il faut vous reporter au livret spécifique à votre spécialité (ACA, EnviTERR, GeoINT, GeoSUDS et SCT).

Approfondissement

- Comprendre l'analyse de la variance à simple entrée
- Comprendre l'analyse factorielle de correspondance (A.F.C.)
- Comprendre ce qu'est un rapport de corrélation

Quatrième partie

Statistique multivariée

Séance 8

Analyses multivariées : les méthodes descriptives

Objectifs de la séance

- Comprendre ce qu'est une analyse factorielle en composantes principales (A.C.P.)
- Comprendre ce qu'est une analyse factorielle des correspondances multiples (A.C.M.)
- Comprendre ce qu'est une classification ascendante hiérarchique (C.A.H.)
- Comprendre ce qu'est une analyse factorielle discriminante (A.F.D.)
- Comprendre ce qu'est une analyse factorielle multiple (A.F.M.)

Ressources GitHub à lire avant la séance

<https://github.com/MaximeForrieux/Sorbonne-M1-Analyse-de-donnees/tree/main/Seance-08>

Exercice du jour

Questions de cours

Les réponses comptent pour 20 % de la note finale du niveau 2.

1. Pourquoi la géographie a-t-elle si souvent recours à la statistique multivariée ?
2. Expliquez ce que vous avez compris des enjeux scientifiques des méthodes descriptives (un paragraphe par méthode).
3. Pour chaque méthode, résumez les éléments que vous devez calculer et mesurer.
Attention ! Je vous demande une explication textuelle, et non mathématique, mais vous devez respecter les étapes de calcul.
4. Existe-t-il des points communs entre les différentes méthodes factorielles ? ou sont-elles mathématiquement indépendantes ?

5. Pour l'ensemble des méthodes, quels sont les tableaux de données existant ? Définissez-les et expliquez quelles méthodes les utilisant ?
6. Quel est le lien entre le choix de la méthode factorielle et le type de variables ? Selon vous, quelle est l'analyse factorielle la plus générale ? Justifier votre réponse.
7. Quelles différences existe-t-il entre une régression par les moindres carrés et une régression orthogonale ?
8. En analyse factorielle, que signifient les valeurs propres d'un axe d'un point de vue statistique ?
9. Qu'est-ce et à quoi sert la distance du χ^2 ?
10. Quelles différences entre analyse factorielle des correspondances et analyse des correspondances multiples, et entre analyse en composantes principales et analyse des correspondances multiples ?
11. À quoi servent les profils lignes et les profils colonnes
12. Quels sont les types de *mapping* ? Comment les interpréter ?
13. Comment expliqueriez-vous la généralisation de l'A.F.C. en A.C.M. ?
14. Comment distinguer classification et classement ? Expliquez les statistiques de regroupements ? Trouvez les situations d'utilisation de l'une ou de l'autre.
15. Construisez une explication de l'intérêt de faire une A.F.M. ? Pourquoi existe-t-il autant de modèle en A.F.M. ? Quelle est sa particularité par rapport à l'ensemble des méthodes factorielles précédentes ? Existe-t-il des objets `Python` permettant de les calculer ?
16. À quelle branche mathématique appartiennent les méthodes factorielles ?

Mise en œuvre avec Python

Il faut vous reporter au livret spécifique à votre spécialité (EnviTERR et GeoINT).

Approfondissement

- Comprendre l'analyse canonique
- Comprendre la généralisation de la notion de vecteurs
- Comprendre le calcul matriciel
- Comprendre les bases de l'algèbre linéaire
- Comprendre ce qu'est un produit scalaire et les liens entre produit scalaire et statistiques multivariées
- Comprendre ce que sont les valeurs propres et vecteurs propres

Analyse en Composantes Principales (ACP) en Résumé



1 Préparer les données

x1	x2	x3	x3
8,74	1,83	-2,56	0,56
10,7	3,22	0,58	0,88
9,59	0,41	-1,11	0,11
8,31	-1,52	6,11	

2 Appliquer l'ACP


Vecteurs propres

$$\begin{pmatrix} v_{11} & v_{12} & \dots & v_{1n} \\ v_{21} & v_{22} & \dots & v_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ v_{n1} & v_{n2} & \dots & v_{nn} \end{pmatrix} \begin{pmatrix} e_{11} & e_{21} & e_{n1} \\ e_{12} & e_{22} & e_{n2} \\ \vdots & \vdots & \vdots \\ e_{1n} & e_{2n} & e_{nn} \end{pmatrix}$$

Valeurs propres


$\lambda_1, \lambda_2, \dots, \lambda_n$

3 Sélectionner les composantes



4 Analyser les charges de composantes

Individus - ACP



Un like et un partage ?

@SMSSC

FIGURE 8.1 – Résumé de la méthode d'analyse en composantes principales (A.C.P.)

Source : LinkedIn

Cheatsheet Machine Learning Algorithms

Algorithm	Type	Best Use Case	Key Formula / Logic	Assumptions	Pros	Cons	When NOT to Use	Real-World Example
Linear Regression	Supervised	Predicting continuous values	$Y = b_0 + b_1X + b_2X^2 + \dots$	Linearity, independence	Simple, interpretable, fast	Sensitive to outliers, non-linear limits	Data with strong non-linearity	House price prediction
Logistic Regression	Supervised	Binary classification	$P = 1 / (1 + e^{-(b_0 + b_1X + \dots)})$	Log-odds linearity	Probabilistic, interpretable	Weak with non-linear boundaries	Data is highly non-linear	Spam detection
Decision Tree	Supervised	Classification / Regression	Recursive binary split	None	Easy to interpret	Overfitting, unstable	Noisy or complex datasets	Loan default prediction
Random Forest	Supervised	Ensemble accuracy	Bagging + averaging trees	Tree independence	High accuracy, robust	Slower, less interpretable	Need real-time results	Fraud detection
Gradient Boosting	Supervised	High-performance modeling	Additive trees minimizing loss	Sequential dependency	State-of-the-art accuracy	Overfitting, needs tuning	When interpretability matters	Credit scoring
SVM	Supervised	Max-margin classification	Maximize margin using kernel trick	Separability, scaling	Works in high dimensions	Slow on large data	Large noisy datasets	Facial recognition
KNN	Supervised	Few-shot classification	Distance-based majority vote	Feature scaling	Simple, no training phase	Slow, noisy sensitive	High-dimensional noisy data	Recommender systems
Naive Bayes	Supervised	Text classification	Bayes theorem + feature independence	Independent features	Fast, good with text data	Fails with correlated features	Feature dependency present	Sentiment analysis
K-Means	Unsupervised	Customer segmentation	Minimize intra-cluster distance	Spherical, equal clusters	Fast, easy to implement	Needs K, sensitive to scale	Non-spherical data	Customer segmentation
Hierarchical Clust.	Unsupervised	Data structure understanding	Nested dendrogram	Distance metric	No need for K, visual	Memory and compute intensive	Very large datasets	Gene expression analysis
PCA	Dim. Reduction	Reducing feature dimensionality	Eigenvectors of covariance matrix	Large variance important	Noise reduction, speed-up	Hard to interpret	All features are important	Image compression
Neural Networks (MLP)	Supervised	Complex pattern modeling	Weighted sums + activation functions	Enough data, scaling	Non-linear learning power	Needs large data & tuning	Small data, low compute	Image classification
CNN	Supervised	Image/video/spatial data	Convolution + pooling layers	Grid-like spatial data	Excellent for images	High resource demand	Sequence/text data	Self-driving vision
RNN	Supervised	Sequence modeling	Feedback loops over time	Sequential structure	Time-series & text ready	Vanishing gradient	Long sequences	Stock prediction
Transformer (BERT, GPT)	Supervised/Self-supervised	NLP tasks, chat, translation	Attention mechanism + position encoding	Large training data	Long context, fast	Heavy compute, large model	Small projects	ChatGPT, Translation tools
Autoencoders	Unsupervised	Compression & anomaly detection	Encoder-decoder + reconstruction loss	Symmetric network	Effective denoising	Can overfit, black-box	When no compression needed	Fraud detection
DBSCAN	Unsupervised	Arbitrary shape clustering	Density-based region growing	Cluster density	Noise tolerant, shape-flexible	Fails on varying density	Sparse high-dim data	Geo-spatial clustering



Created by Shoaib Shah @BEGINNERSBLOG
 JOIN: <https://t.me/openailearning>

FIGURE 8.2 – Algorithmes des méthodes d'analyse de données multivariées

Source : LinkedIn

Machine Learning Algorithms

(Every data scientist must know)




FIGURE 8.3 – Algorithmes des méthodes d'analyse de données multivariées

Source : LinkedIn

Séance 9

Analyses multivariées : les méthodes explicatives

Objectifs de la séance

- Comprendre l'usage des méthodes de régression multivariées et le sens des corrélations multiple et partielle

Ressources GitHub à lire avant la séance

<https://github.com/MaximeForriez/Sorbonne-M1-Analyse-de-donnees/tree/main/Seance-09>

Exercice du jour

Courage, c'est presque fini !

Questions de cours

Les réponses comptent pour 20 % de la note finale du niveau 2.

1. Essayez d'expliquer la généralisation de la corrélation dans un espace à n dimensions ?
2. Comment expliqueriez-vous ce qu'est une régression multiple ?
3. À quoi sert l'analyse de la variance à double entrée ?
4. Pourquoi malgré le fait que l'analyse canonique soit la plus générale, ne sert-elle à rien en analyse de données ?
5. À quoi les méthodes explicatives peuvent-elles être utiles dans des analyses de données géographiques ?




FIGURE 9.1 – Modèle linéaire généralisée

Source : LinkedIn

Mise en œuvre avec Python

Il faut vous reporter au livret spécifique à votre spécialité (EnviTERR et GeoINT).

Approfondissement

- Comprendre l'usage de l'analyse de la variance à double entrée
- Comprendre l'analyse de la variance orthogonale à entrées multiples
- Comprendre l'analyse canonique
- Comprendre l'indice de Rand
- Comprendre l'indice de Jaccard

Cinquième partie

Bonus

Séance 10

Séance Bonus : télécharger des données à partir d'un A.P.I.

Objectifs de la séance

- Gérer un A.P.I.
- Télécharger automatiquement des données mises à disposition sur un A.P.I.

Ressources GitHub à lire avant la séance

<https://github.com/MaximeForrieux/Sorbonne-M1-Analyse-de-donnees/tree/main/Seance-Bonus>

Manipulations

L'exercice est relativement simple. Il s'agit juste de télécharger automatiquement des données à partir d'un *Application Programming Interface* (A.P.I.).

Les A.P.I. sont très nombreuses. Il suffit de consulter <https://www.data-gouv.fr/dataservices/search> pour s'en convaincre.

Ici, vous allez utiliser l'A.P.I. de <https://www.infoclimat.fr>.

1. Aller à l'adresse : <https://www.infoclimat.fr/opendata>
 - Créer votre compte.
 - À partir de l'adresse précédente, générer une clé (ou un jeton, ou un *token*).
N.B. N'oubliez pas de préciser la **non** utilisation commerciale.
 - Zoomer sur Paris. Dans le cinquième arrondissement, cliquer sur la station [MAE]
LATMOS-PARIS
 - Générer un lien de téléchargement comprenant votre clé.
 - Essayer de comprendre la logique des mots clés de l'adresse U.R.L. générée, ici vous avez :

```

■ start=
■ end=
■ format=
■ stations[]=
■ method=
■ token=

```

N.B. 1. Pour plus d'information sur les A.P.I. Rest : <https://www.data-bird.co/blog/api-rest>.

N.B. 2. Toutes les A.P.I. n'ont pas obligatoirement de *token*.

2. Pour télécharger automatiquement les données, il faut utiliser la bibliothèque `requests` et se référer à la documentation : https://rtavenar.github.io/poly_python/content/api.html

- Avec la fonction fournie `geturl()` et avec la liste des variables demandées, créer une variable `url`. Vous devez télécharger les données entre le 1^{er} octobre et le 30 octobre de cette année.
- Avec la méthode `requests.get(...)` et la fonction `testConnexion()`, télécharger les données de l'A.P.I. dans une variable `data`.

N.B. Si la réponse est égale à 200, alors la fonction utilise l'attribut `.text` pour lire et télécharger les données en format C.S.V.

- Les données récupérées sont textuelles et mélangées. Il faut isoler les données, les titres des colonnes et les métadonnées en créant trois listes `data2`, `titre` et `metadata`. Créer une boucle avec des conditions permettant isoler les lignes 0, 1, 2, 3, 4, 6 pour les métadonnées.; la ligne 5 pour les titres, et le reste du tableau pour les données.

3. Convertir les listes `data2` et `metadata` en objet `Pandas`

- Créer un objet `Pandas`, en réaffectant la variable `data`, à partir de `data2`. Ajouter à cet objet le titre des colonnes en utilisant l'attribut `columns`
- Créer un objet `Pandas` à partir de `metadata`.
- Enregistrer l'objet `data` avec la méthode `to_excel()`
- Enregistrer l'objet `metadata` avec la méthode `to_csv()`. Il faudra préciser le paramètre `encoding="utf-8"`

Si tout s'est bien passé vous avez récupéré 28 champs :

1. `station_id`;
2. `dh_utc`;
3. `temperature`;
4. `pression`;
5. `pression_variation_3h`;

```
6. humidite;  
7. point_de_rose;  
8. visibilite;  
9. vent_moyen;  
10. vent_rafales;  
11. vent_rafales_10min;  
12. vent_direction;  
13. temperature_min;  
14. temperature_max;  
15. pluie_1h;  
16. pluie_3h;  
17. pluie_6h;  
18. pluie_12h;  
19. pluie_24h;  
20. pluie_cumul_0h;  
21. pluie_intensite;  
22. pluie_intensite_max_1h;  
23. uv;  
24. uv_index;  
25. ensoleillement;  
26. temperature_sol;  
27. temps_omm;  
28. complements;source.
```

Bonus

Refaire l'exercice en téléchargement les données à partir du format J.S.O.N.

Approfondissement

- Comprendre les spécificités des séries temporelles
- Comprendre les spécificités des séries spatiales
- Comprendre les chaînes de Markov
- Comprendre l'analyse multicritère
- Comprendre la théorie des ensembles
- Comprendre les structures algébriques

Bibliographie

- [Abdessemed et Escofier, 1996] ABDESSEMED, L. et ESCOFIER, B. (1996). Analyse factorielle multiple de tableaux de fréquences. comparaison avec l'analyse canonique des correspondances. Journal de la société statistique de Paris, 137(2):3–18.
- [Abitoul et Hachez-Leroy, 2015] ABITOUL, S. et HACHEZ-LEROY, F. (2015). Humanités numériques, pages 43–57.
- [Bardos, 2001] BARDOS, M. (2001). Analyse discriminante. Application au risque et scoring financier. Dunod, Paris.
- [Bécue-Bertaut et Pagès, 2001] BÉCUE-BERTAUT, M. et PAGÈS, J. (2001). Analyse simultanée de questions ouvertes et de questions fermées. méthodologie, exemple. Journal de la société française de statistique, 142(4):91–104.
- [Béguin, 1979] BÉGUIN, H. (1979). Méthodes d'analyse géographique quantitative. Litec, Paris.
- [Béguin et Pumain, 1994a] BÉGUIN, M. et PUMAIN, D. (1994a). La représentation des données géographiques. Statistique et cartographie. Cours. Armand Colin, Paris. réédition de 2007.
- [Béguin et Pumain, 1994b] BÉGUIN, M. et PUMAIN, D. (1994b). La représentation des données géographiques. Statistique et cartographie. Cours. Armand Colin, Paris.
- [Benali et Escofier, 1987] BENALI, H. et ESCOFIER, B. (1987). Stabilité de l'analyse factorielle des correspondances multiples en cas de données manquantes et de modalités à faibles effectifs. Revue de statistique appliquée, 35(1):41–51.
- [Benali et Escofier, 1990] BENALI, H. et ESCOFIER, B. (1990). Analyse factorielle lissée et analyse factorielle des différences locales. Revue de statistique appliquée, 38(2):55–76.
- [Benammou et al., 2007] BENAMMOU, S., SAPORTA, G. et SOUISSI, B. (2007). Une procédure de réduction du nombre de paires en analyse conjointe. Journal de la société française de statistique, 148(4).
- [Benzécri, 1960] BENZÉCRI, J.-P. (1960). Sur les variétés localement affines et localement projectives. Bulletin de la société mathématique de France, 88:229–332.
- [Benzécri, 1973a] BENZÉCRI, J.-P. (1973a). L'analyse de données, t. 1, La taxinomie. Dunod, Paris.
- [Benzécri, 1973b] BENZÉCRI, J.-P. (1973b). L'analyse de données, t. 2, L'analyse de correspondances. Dunod, Paris.

- [Benzécri, 1980] BENZÉCRI, J.-P. (1980). Pratique de l'analyse des données. Dunod, Paris.
- [Benzécri, 1982a] BENZÉCRI, J.-P. (1982a). L'analyse des données. Leçons sur l'analyse factorielle et la reconnaissance des formes et travaux. Dunod, Paris.
- [Benzécri, 1982b] BENZÉCRI, J.-P. (1982b). Sur la généralisation du tableau de burt et son analyse par bandes. Les cahiers de l'analyse des données, 7(1):33–43.
- [Bernard et al., 1989] BERNARD, J.-M., LE ROUX, B., ROUANET, H. et SCHILTZ, M.-A. (1989). L'analyse des données multidimensionnelles par le langage d'interrogation des données (l.i.d.). au-delà de l'analyse des correspondances. Bulletin de méthodologie sociologique, (23):3–46.
- [Berry, 2011] BERRY, D. M. (2011). The computational turn : Thinking about the digital humanities. Culture Machine, 12:1–22.
- [Bobee, 1978] BOBEE, B. (1978). Éléments de statistiques. Université du Québec, Montreal.
- [Bonnet et al., 1996] BONNET, P., LE ROUX, B. et LEMAINÉ, G. (1996). Analyse géométrique des données : une enquête sur le racisme. Mathématiques et sciences humaines, (136):5–28.
- [Bouroche et Saporta, 2002] BOUROCHE, J.-M. et SAPORTA, G. (2002). L'analyse de données. Que sais-je ? P.U.F., Paris.
- [Bouroche et Tenenhaus, 1970] BOUROCHE, J.-M. et TENENHAUS, M. (1970). Quelques méthodes de segmentation. Revue française d'informatique et de recherche opérationnelle, (4):29–42.
- [Brown, 1962] BROWN, R. G. (1962). Smoothing forecasting and prediction of discrete time series. Quantitative Methods Series. Prentice-Hall, London.
- [Celeux et Nakache, 1994] CELEUX, G. et NAKACHE, J.-P. (1994). Analyse discriminante sur variables qualitatives. Polytechnica, Paris.
- [Chadule, 1997] CHADULE, G. (1997). Initiation aux pratiques statistiques en géographie. Masson, Paris.
- [Charre, 1995] CHARRE, J. (1995). Statistique et territoire. Espaces modes d'emploi. G.I.P. RECLUS, Montpellier.
- [Cibois, 1991] CIBOIS, P. (1991). L'analyse factorielle. Analyse en composantes principales et analyse factorielle des correspondances. Que sais-je ? PUF, Paris.
- [Cibois, 2000] CIBOIS, P. (2000). L'analyse factorielle. Analyse en composantes principales et analyse factorielle des correspondances. Que sais-je ? P.U.F., Paris.
- [Cicéri et al., 1977] CICÉRI, M.-F., MARCHAND, B. et RIMBERT, S. (1977). Introduction à l'analyse spatiale. U. Armand Colin, Paris.
- [Cloux et al., 2016] CLOUX, P.-Y., GARLOT, T. et KOHLER, J. (2016). Docker. Pratique des architectures à base de conteneurs. Études, développement & intégration. Dunod, Paris.
- [Cloux et al., 2022] CLOUX, P.-Y., GARLOT, T. et KOHLER, J. (2022). Docker et conteneurs. Architectures, développement, usages et outils. Études, développement, intégration. Dunod, Malakoff. 3e édition.

- [Cottet-Emard, 2020] COTTET-EMARD, F. (2020). Probabilités et tests d'hypothèse. Sup en poche - Maths L1/L2. DeBoeck Supérieur, Louvain-la-Neuve.
- [Couty et al., 2007] COUTY, F., DEBORD, J. et FREDON, D. (2007). Mini-manuel de probabilités et statistique. Dunod, Paris.
- [Dacos, 2011] DACOS, M. (2011). Manifeste des Digital Humanities.
- [Dacos et Mounier, 2015] DACOS, M. et MOUNIER, P. (2015). Humanité numérique. État des lieux et positionnement de la recherche française dans le contexte international.
- [Dagnelie, 1975] DAGNELIE, P. (1975). Analyse statistique à plusieurs variables. Les presses agronomiques de Gembloux, Paris.
- [Daudin et al., 1999] DAUDIN, J.-J., ROBIN, S. et VUILLET, C. (1999). Statistique inférentielle. Idées, démarches, exemples. Pratique de la statistique. Presses universitaires de Rennes, Rennes.
- [Deheuvels, 2021] DEHEUVELS, P. (2021). La probabilité, le hasard et la certitude. Que sais-je ? PUF, Paris.
- [Delsart et Vaneecloo, 2010] DELSART, V. et VANEECLOO, N. (2010). Probabilités, variables aléatoires, lois classiques, tome 1. Guides pratiques. Presses universitaires du Septentrion, Villeneuve-d'Ascq.
- [Dervin, 1992] DERVIN, C. (1992). Comment interpréter les résultats d'une analyse factorielle des correspondances ? STAT - ITCF. Institut technique des céréales et des fourrages (I.C.T.F.), Paris.
- [Diday, 1971] DIDAY, E. (1971). Une nouvelle méthode en classification automatique et reconnaissance des formes la méthode des nuées dynamiques. Revue de statistique appliquée, 19(2):19–33.
- [Dozo, 2011] DOZO, B.-O. (2011). Mesures de l'écrivain. Profil socio-littérature et capital relationnel dans l'entre-deux-guerres en Belgique francophone. Presses universitaires de Liège, Liège.
- [Dumolard, 2011] DUMOLARD, P. (2011). Données géographiques. Analyse statistique multivariée. Lavoisier - Hermès, Paris.
- [Dumolard et al.,] DUMOLARD, P., ALLIGNOL, F., PAUL, E. et QUESSEVEUR, E. L'outil informatique en géographie. En ligne : https://dspace.msh-alpes.prd.fr/bitstream/1801/19/2/book_geoinfo.pdf.
- [Dumolard et al., 2003] DUMOLARD, P., DUBUS, N. et CHARLEUX, L. (2003). Les statistiques en géographie. Atout géographie. Belin, Paris.
- [Durand, 1998] DURAND, J.-L. (1998). Taux de dispersion des valeurs propres en a.c.p., a.c. et a.c.m. Mathématiques et sciences humaines, (144):15–28.
- [Escofier, 1979] ESCOFIER, B. (1979). Une représentation des variables dans l'analyse des correspondances multiples. Revue de statistique appliquée, 27(4):37–47.
- [Escofier, 1981] ESCOFIER, B. (1981). Quelques indices pour comparer des tableaux de contingence. Statistique et analyse de données, 6(1):39–51.

- [Escofier, 1984] ESCOFIER, B. (1984). Analyse factorielle en référence à un modèle. application à l'analyse de tableaux d'échanges. Revue de statistique appliquée, 32(4):25–36.
- [Escofier et al., 1990] ESCOFIER, B., BENALI, H. et BACHAR, K. (1990). Comment introduire la contiguïté en analyse des correspondances ? application en segmentation d'image. Statistique et analyse de données, 15(3):61–92.
- [Escofier et Pagès, 2016a] ESCOFIER, B. et PAGÈS, J. (2016a). Analyses factorielles simples et multiples. Cours et études de cas. Sciences sup. Dunod, Paris.
- [Escofier et Pagès, 2016b] ESCOFIER, B. et PAGÈS, J. (2016b). Analyses factorielles simples et multiples. Cours et études de cas. Sciences sup. Dunod, Paris.
- [Escofier-Cordier, 1969] ESCOFIER-CORDIER, B. (1969). L'analyse factorielle des correspondances. Cahiers du Bureau universitaire de recherche opérationnelle. Série Recherche, (13):25–59.
- [Flechy, 2001] FLECHY, P. (2001). L'imaginaire d'internet. La Découverte, Paris.
- [Fleurant et Fleurant, 2015] FLEURANT, S. et FLEURANT, C. (2015). Bases de mathématiques pour la géologie et la géographie. Cours. Dunod, Paris.
- [Foucart, 1984] FOUCART, T. (1984). Analyse factorielle de tableaux multiples. Méthode + Programmes. Masson, Paris.
- [Foucart, 1997] FOUCART, T. (1997). L'analyse de données. Mode d'emploi. Méthodes et études de cas. Didact Statistique. Presses universitaires de Rennes, Rennes.
- [Gassara, 2022] GASSARA, E. (2022). Docker / Kubernetes. Pour optimiser et accélérer les développements d'applications conteneurisées. Eyrolles, Paris.
- [Girschig, 1969] GIRSCHIG, M. (1969). Analyse statistique.
- [Gold, 2012] GOLD, M., éditeur (2012). Debates in the Digit Humanities, pages 1–532. University of Minnesota Press, Minneapolis.
- [Goldfarb et Pardoux, 2011] GOLDFARB, B. et PARDOUX, C. (2011). Introduction à la méthode statistique. Manuel et exercices corrigés. Éco sup. Dunod, Paris.
- [Gouigoux, 2015] GOUIGOUX, J.-P. (2015). Docker. Prise en main et mise en pratique sur une architecture micro-services. Collection Epsilon. Éditions ENI, Paris.
- [Grandjacquot, 1999] GRANDJACQUOT, M.-P. (1999). Outils statistiques. Théorie et pratique du management - Méthodes quantitatives. Eska, Paris.
- [Guillaud, 2010] GUILLAUD, H. (2010). Qu'apportent les digital humanities ? La Feuille.
- [Hamon et Jégou, 2008] HAMON, A. et JÉGOU, N. (2008). Statistique descriptive. Cours et exercices corrigés. Pratique de la statistique. Presses universitaires de Rennes, Rennes.
- [Hotelling, 1936] HOTELLING, H. (1936). Relation between two sets of variates. Biometrika, 28(3/4):321–377.
- [Howell, 2024] HOWELL, D. C. (2024). Méthodes statistiques en sciences humaines. Ouvertures psychologiques. DeBoeck Supérieur, Louvain-la-Neuve. 3e édition corrigée.
- [Husson et Pagès, 2006] HUSSON, F. et PAGÈS, J. (2006). Aspects méthodologiques du modèle indscal. Revue de statistique appliquée, 54(2):83–100.

- [Husson et Pagès, 2013] HUSSON, F. et PAGÈS, J. (2013). Statistiques générales pour utilisateurs. 2. Exercices et corrigés. Pratique de la statistique. Presses universitaires de Rennes, Rennes.
- [Jacquard, 2000] JACQUARD, A. (2000). Les probabilités. Que sais-je ? n°1571. PUF, Paris. réédition de 1974.
- [Jelensperger et Moreau, 1997] JELENSPERGER, C. et MOREAU, Y. (1997). Nouveau mémento de mathématiques. Algèbre. Analyse. Probabilités. Statistiques. Informatique. Série "Usuels". Vuibert, Paris.
- [Josse et al., 2009] JOSSE, J., HUSSON, F. et PAGÈS, J. (2009). Gestion des données manquantes en analyse en composantes principales. Journal de la société française de statistique, 150(2):28–51.
- [Kohonen, 1982] KOHONEN, T. (1982). Self-organized formation of topologically correct feature maps. Biological Cybernetics, 43:59–69.
- [Lahousse et Piedanna, 1998a] LAHOUSSE, P. et PIEDANNA, V. (1998a). L'outil statistique en géographie, t. 1, Les distributions spatiales. Synthèse 43. Armand Colin, Paris.
- [Lahousse et Piedanna, 1998b] LAHOUSSE, P. et PIEDANNA, V. (1998b). L'outil statistique en géographie, t. 2, L'analyse bivariable. Synthèse 96. Armand Colin, Paris.
- [Le Dien et Pagès, 2003] LE DIEN, S. et PAGÈS, J. (2003). Analyse factorielle multiple hiérarchique. Revue de statistique appliquée, 51(2):47–73.
- [Le Roux, 1991] LE ROUX, B. (1991). Sur la construction d'un protocole additif. Mathématiques et sciences humaines, (114):57–62.
- [Le Roux, 1998] LE ROUX, B. (1998). Inférence combinatoire en analyse géométrique des données. Mathématiques et sciences humaines, (144):5–14.
- [Le Roux, 1999] LE ROUX, B. (1999). Analyse spécifique d'un nuage euclidien : application à l'étude des questionnaires. Mathématiques et sciences humaines, (146):65–83.
- [Le Roux, 2014] LE ROUX, B. (2014). Analyse géométrique des données multidimensionnelles. Dunod, Paris.
- [Le Roux et Rouanet, 1984] LE ROUX, B. et ROUANET, H. (1984). L'analyse multidimensionnelle des données structurées. Mathématiques et sciences humaines, (85):5–18.
- [Lebart et al., 2006] LEBART, L., PIRON, M. et MORINEAU, A. (2006). Statistique exploratoire multidimensionnelle. Visualisation et inférence en fouilles de données. Sciences sup. Dunod, Paris. 4e édition augmentée.
- [Lecoutre, 2008] LECOUTRE, J.-P. (2008). Statistique et probabilités. T.D. Dunod, Paris.
- [Lerman, 1966] LERMAN, I. C. (1966). Essai sur l'analyse hiérarchique. Mathématiques et sciences humaines, (17):37–46.
- [Lerman, 1970] LERMAN, I. C. (1970). Sur l'analyse des données préalable à une classification automatique (proposition d'une nouvelle mesure de similarité). Mathématiques et sciences humaines, (32):5–15.

- [Lerman, 1973] LERMAN, I. C. (1973). Introduction à une méthode de classification automatique illustrée par la recherche d'une typologie des personnages enfants à travers la littérature enfantine. *Revue de statistique appliquée*, 21(3):23–49.
- [Lerman, 1981] LERMAN, I. C. (1981). La classification : concepts et caractéristiques d'une méthodologie d'analyse des données. *Journal de la société statistique de Paris*, 122(2):70–90.
- [Lerman, 1982] LERMAN, I. C. (1982). Programmes d'analyse des résultats d'une classification automatique.
- [Lerman, 2008] LERMAN, I. C. (2008). Analyse logique, combinatoire et statistique de la construction d'une hiérarchie binaire implicative. niveaux et nœuds significatifs. *Mathematics and Social Sciences*, (184):47–107.
- [Lethielleux, 2010] LETHIELLEUX, M. (2010). *Statistique descriptive en 27 fiches*. Express sup. Dunod, Paris.
- [Lipschutz, 1986] LIPSCHUTZ, S. (1986). *Les structures de données*. Série Schaum. McGraw-Hill, Paris.
- [Lipschutz, 1987] LIPSCHUTZ, S. (1987). *Probabilités*. Série Schaum. McGraw-Hill, Paris.
- [Marchand, 1972] MARCHAND, B. (1972). L'usage des statistiques en géographie. *L'espace géographique*, 1(2):79–100.
- [Martin, 2020] MARTIN, O. (2020). *L'analyse quantitative des données*. 128. Armand Colin, Paris.
- [McCarty, 2002] MCCARTY, W. (2002). Humanities computing : Essential problems, experimental practice. *Literary and Linguistic Computing*, 17(1):103–125.
- [McCarty, 2005] MCCARTY, W. (2005). *Humanities Computing*. Palgrave-Macmillan, London.
- [Minvielle et Souiah, 2003] MINVIELLE, E. et SOUIAH, S.-A. (2003). *L'analyse statistique et spatiale. Statistiques, cartographie, télédétection, S.I.G. Outils et méthodes en géographie*. Éditions du temps, Nantes.
- [Monino et al., 2010] MONINO, J.-L., KOSIANSKI, J.-M. et LE CORNU, F. (2010). *Statistique descriptive*. Dunod, Paris.
- [Morand et Pagès, 2007] MORAND, E. et PAGÈS, J. (2007). Analyse factorielle multiple pro-custéenne. *Journal de la société française de statistique*, 148(2):65–97.
- [Moreau et al., 2000] MOREAU, J., DOUDIN, P.-A. et CAZES, P. (2000). *L'analyse des correspondances et les techniques connexes. Approches nouvelles pour l'analyse statistique des données*. Mathématiques & applications n°32. Springer, Paris.
- [Morgenthaler, 2007] MORGENTHALER, S. (2007). *Introduction à la statistique*. Enseignement des mathématiques. Presses polytechniques et universitaires romandes, Lausanne. 3e édition augmentée.
- [Nakache et Confais, 2000] NAKACHE, J.-P. et CONFAIS, J. (2000). *Méthodes de classification avec illustrations SPAD et SAS*. Centre international de statistique et d'informatique appliquées (C.I.S.I.A.), Montreuil.

- [Pagès, 2010] PAGÈS, J. (2010). Statistique générale pour utilisateurs. 1. Méthodologie. Pratique de la statistique. Presses universitaires de Rennes, Rennes.
- [Pagès et Périnel, 2007] PAGÈS, J. et PÉRINEL, E. (2007). Blocs incomplets équilibrés versus plans optimaux. Journal de la société française de statistique, 148(2):100–112.
- [Pagès et Tenenhaus, 2002] PAGÈS, J. et TENENHAUS, M. (2002). Analyse factorielle multiple et approche p.l.s. Revue de statistique appliquée, 50(1):5–33.
- [Paquienséguy et Péliissier, 2021] PAQUIENSÉGUY, F. et PÉLISSIER, N., éditeurs (2021). Questionner les humanités numériques, pages 1–298. Société française des sciences de l’information et de la communication & Conférence permanente des directeurs de laboratoires en sciences de l’information et de la communication, Paris.
- [Petit, 2018] PETIT, T. (2018). Tous les algorithmes. Programmation. Python. Prépa scientifique 1ère et 2e années. Ellipses, Paris.
- [Philippeau, 1992] PHILIPPEAU, G. (1992). Comment interpréter les résultats d’une analyse en composantes principales ? STAT - ITCF. Institut technique des céréales et des fourrages (I.C.T.F.), Paris.
- [Poinsot, 2004] POINSOT, D. (2004). Statistiques pour statophobes. Une introduction au monde des tests statistiques à l’intention des étudiants qui n’y entravent que pouic et qui détestent les maths par-dessus le marché. <https://perso.univ-rennes1.fr/denis.poinsot>.
- [Pontier et Normand, 1992] PONTIER, J. et NORMAND, M. (1992). À propos de généralisation de l’analyse canonique. Revue de statistique appliquée, 40(1):57–75.
- [Preda et Saporta, 2002] PREDAS, C. et SAPORTA, G. (2002). Régression p.l.s. sur un processus stochastique. Revue de statistique appliquée, 50(2):27–45.
- [Randriamihamison, 2021] RANDRIAMIHAMISON, N. (2021). Classification ascendante hiérarchique sous contrainte de contiguïté pour l’analyse de données Hi-C. Thèse de doctorat, Université Paul Sabatier - Toulouse III, Toulouse.
- [Rateau, 2001] RATEAU, P. (2001). Méthode et statistiques expérimentales en sciences humaines. Université. Ellipses, Paris.
- [Réau et Chauvat, 1988] RÉAU, J.-P. et CHAUVAT, G. (1988). Probabilités & statistiques. Résumé des cours. Exercices et problèmes corrigés. Q.C.M. Cours. Armand Colin, Paris.
- [Rodriguez Herrera et Salles-Le Gac, 2002] RODRIGUEZ HERRERA, R. et SALLES-LE GAC, D. (2002). Initiation à l’analyse factorielle des données. Fondements mathématiques et interprétations. Ellipses, Paris.
- [Rouanet et Le Roux, 1993] ROUANET, H. et LE ROUX, B. (1993). Analyse des données multidimensionnelles. Statistiques en sciences humaines. Dunod, Paris.
- [Rouanet et Le Roux, 1997] ROUANET, H. et LE ROUX, B. (1997). Analyse des données multidimensionnelles. Dunod, Paris.
- [Rousselet, 2020] ROUSSELET, M. (2020). Python. Introduction au calcul numérique. Ressources informatiques. Éditions ENI, Paris.
- [Sanders, 1989] SANDERS, L. (1989). L’analyse des données appliquées à la géographie. Alidade. GIP-Reclus, Montpellier.

- [Saporta, 1975a] SAPORTA, G. (1975a). Dépendance et codages de deux variables aléatoires. Revue de statistique appliquée, 23(1):43–63.
- [Saporta, 1975b] SAPORTA, G. (1975b). Liaisons entre plusieurs ensembles de variables et codage de données qualitatives. Thèse de doctorat, Université Pierre et Marie Curie - Paris VI, Paris.
- [Saporta, 1976] SAPORTA, G. (1976). Quelques applications des opérateurs d'escoufier au traitement des variables qualitatives. Quelques applications des opérateurs d'Escoufier au traitement des variables qualitatives, 1(1):38–46.
- [Saporta, 1979] SAPORTA, G. (1979). Ponderation optimale de variables qualitatives en analyse des données. pages 19–31.
- [Saporta, 1981a] SAPORTA, G. (1981a). Méthodes exploratoires d'analyse de données temporelles. Thèse de doctorat, Université Pierre et Marie Curie - Paris VI, Paris.
- [Saporta, 1981b] SAPORTA, G. (1981b). Méthodes exploratoires d'analyse de données temporelles. Cahiers du bureau universitaire de recherche opérationnelle, (37-38):7–194.
- [Saporta, 2001] SAPORTA, G. (2001). Discussions et commentaires. data mining et statistique. Journal de la société française de statistique, 142(1):81–84.
- [Scheid, 1986] SCHEID, F. (1986). Analyse numérique. Série Schaum. McGraw-Hill, Paris.
- [Schultz et Bussonnier, 2020] SCHULTZ, E. et BUSSONNIER, M. (2020). Python pour les SHS. Introduction à la programmation pour le traitement de données. Pratique de la statistique. Presses universitaires de Rennes, Rennes.
- [Spiegel, 1974] SPIEGEL, M. R. (1974). Formules et tables de mathématiques. Série Schaum. McGraw-Hill, Paris.
- [Spiegel, 1981] SPIEGEL, M. R. (1981). Probabilités et statistique. Série Schaum. McGraw-Hill, Paris.
- [Spiegel, 1984] SPIEGEL, M. R. (1984). Théorie et applications de la statistique. Série Schaum. McGraw-Hill, Paris. réédition de 1972.
- [Stiegler, 2014] STIEGLER, B. (2014). Digital Studies : organologie des services et technologies de la connaissance. FYP, Limoges.
- [Svensson, 2012] SVENSSON, P. (2012). Envisionning the digital humanities. Digital Humanities Quarterly, 6(1).
- [Tenenhaus, 1977] TENENHAUS, M. (1977). Analyse en composantes principales d'un ensemble de variables nominales ou numériques. Revue de statistique appliquée, 25(2):39–56.
- [Tenenhaus, 1979] TENENHAUS, M. (1979). La régression qualitative. Revue de statistique appliquée, 27(2):5–21.
- [Tenenhaus, 2007] TENENHAUS, M. (2007). Statistique. Méthodes pour décrire, expliquer et prévoir. Dunod, Paris.
- [Tenenhaus et Priouret, 1974] TENENHAUS, M. et PRIEURET, B. (1974). Analyse des séries chronologiques multidimensionnelles. Revue française d'automatique, informatique, recherche opérationnelle. Recherche opérationnelle, 8(V2):5–16.

- [Terras, 2011] TERRAS, M. (2011). Peering inside the big tent : Digital humanities and the crisis of inclusion. Melissa Terras' Blog. <https://melissaterras.blogspot.com/2011/07/peering-inside-big-tent-digital.html>.
- [Thabut, 2018] THABUT, G. (2018). Les statistiques : pour quoi faire ?
- [Turner, 2012] TURNER, F. (2012). Aux sources de l'utopie numérique de la contre-culture à la cyberculture : Steward Brand, un homme d'influence. C. & F., Caen.
- [Van Hooland et al., 2016] VAN HOOLAND, S., GILLET, F., HENGCHEN, S. et DE WILDE, M. (2016). Introduction aux humanités numériques : méthodes et pratiques. Méthodes en sciences humaines. De Boeck, Louvain-la-Neuve.
- [Veyseyre, 2004] VEYSSEYRE, R. (2004). Aide-mémoire. Statistique et probabilités pour l'ingénieur. L'usine nouvelle. Dunod, Paris.
- [Vigieron, 1997] VIGNERON, E. (1997). Géographie et statistique. Que sais-je ? PUF, Paris.
- [Ward, 1963] WARD, J. H. (1963). Hierarchical grouping to optimize an objective function. Journal of American Statistical Association, 58:236–244.
- [Wonnacott et Wonnacott, 1995] WONNACOTT, T. H. et WONNACOTT, R. J. (1995). Statistique. Économie – Gestion – Sciences – Médecine. Économica, Paris.
- [Youness et Saporta, 2001] YOUNESS, G. et SAPORTA, G. (2001). Une méthodologie pour la comparaison de partitions. Revue de statistique appliquée, 52(1):97–120.

Table des figures

1.1	Enseignement traditionnel vs. enseignement actif	8
1.2	Synthèse du planning 2026-2027	11
1.3	Positionnement du cours	12
1.4	Opérations d'analyse de données en recherche	14
1.5	Six concepts statistiques clés à connaître lorsqu'on veut apprendre l'analyse des données	15
1.6	Programmeur vs développeur	17
1.7	De la géomatique à l'infinité des possibilités avec Python	18
1.8	Les métiers autour de l'analyse de données	19
1.9	Les métiers autour de l'analyse de données	20
1.10	Comment devenir un spécialiste des données avec Python ?	21
1.11	Comparaison entre les outils utilisés en 2016 et les outils utilisés en 2026 . .	22
1.12	Créer un compte GitHub – Écran 1	41
1.13	Créer un compte GitHub – Écran 2	42
1.14	Git <i>Cheat Sheet</i>	43
1.15	Ouvrir son compte GitHub	44
1.16	Créer un repository – Écran 1	44
1.17	Créer un repository – Écran 2	45
1.18	Créer un repository – Écran 3a	46
1.19	Créer un repository – Écran 3b	47
1.20	Créer un repository – Écran 4	48
1.21	Créer un dépôt local – Écran 1	49
1.22	Créer un dépôt local – Écran 2	49
1.23	Créer un dépôt local – Écran 3	50
1.24	Créer un dépôt local – Écran 4	50
1.25	Créer une connexion entre un dépôt local et un dépôt distant– Écran 4	52
1.26	Vérification du dépôt	52
1.27	Docker – Écran 1	54
1.28	Docker – Écran 2	55
1.29	Docker – Écran 3	55
1.30	Docker – Écran 4	56
1.31	Docker – Écran 5	57
1.32	Docker – Écran 6	57
1.33	Docker – Écran 7	58

1.34 Docker – Écran 8	58
1.35 Docker – Écran 9	59
1.36 Docker – Écran 10	59
1.37 Visual Studio Code – Écran 1	60
1.38 Visual Studio Code – Écran 2	61
1.39 Docker – Écran 1	61
1.40 Dossier de la séance du jour	62
1.41 Visual Studio Code – Écran 3	63
1.42 Visual Studio Code – Écran 4	64
1.43 Visual Studio Code – Écran 5	65
1.44 Visual Studio Code – Écran 6	65
1.45 Visual Studio Code – Écran 7	66
1.46 Principales commandes de Docker	67
1.47 Comparaison des temps de calcul entre le Python et d’autres langages de programmation avec différents algorithmes classiques	69
1.48 Les principales bibliothèques de Python 1	70
1.49 Les principales bibliothèques de Python 2	71
1.50 Les principales bibliothèques de Python 3	72
1.51 Les principales bibliothèques de Python 4	73
1.52 Algorithmique en Python	79
1.53 Présentation rapide de GeoPandas	80
1.54 Python <i>Cheat Sheet</i>	81
1.55 Les quatre profils d’apprentissage en informatique	83
1.56 Courbe de naturalisation des technologies : comment apprend-t-on à s’en servir ?	84
1.57 Six erreurs à éviter lorsqu’on veut apprendre l’analyse des données	84
1.58 Comment apprendre efficacement ?	85
1.59 Comment appréhender l’échec ?	86
1.60 Fenêtre permettant de rendre visible les dossiers cachés et les extensions de fichier sous Windows	87
1.61 Visual Studio Code – Écran 8	89
1.62 Nettoyage de Docker – Écran 1	90
1.63 Nettoyage de Docker – Écran 2	90
1.64 Nettoyage de Docker – Écran 3	91
1.65 Nettoyage de Docker – Écran 4	91
1.66 Nettoyage de Docker – Écran 5	92
1.67 Nettoyage de Docker – Écran 5	92
1.68 Nettoyage de Docker – Écran 6	93
1.69 Nettoyage de Docker – Écran 7	93
1.70 La différence de sommeil entre un non programmeur et un programmeur . . .	95
1.71 Coder avec l’intelligence artificielle	96
1.72 Contre-exemple de l’utilisation de l’intelligence artificielle	97
1.73 Points négatifs de l’usage de l’intelligence artificielle	98
1.74 Apprentissage et intelligence artificielle	99
1.75 Recherche et intelligence artificielle	100

2.1	Python : Pandas, les commandes de base	102
2.2	Python : Commandes statistiques de base	103
2.3	Python : Pandas, la gestion des fichiers	104
2.4	Les principales manières de visualiser les données avec Python	105
3.1	Comment choisir la bonne distribution statistique ?	112
3.2	Lois de probabilité usuelles	113
3.3	Liens entre les lois de probabilité usuelles	114
4.1	Techniques d'échantillonnage en statistique	119
4.2	Comprendre les types d'erreur	119
4.3	p -value et taille d'effet	120
4.4	p -value expliquée	121
4.5	Comment choisir le bon test statistique ?	122
4.6	Comment choisir son test de normalité ?	123
4.7	Test paramétriques vs. tests non paramétriques	124
4.8	Comment choisir son test non paramétrique ?	124
6.1	Régression linéaire	132
6.2	Pourquoi utiliser la méthode des moindres carrés ?	133
8.1	Résumé de la méthode d'analyse en composantes principales (A.C.P.)	141
8.2	Algorithmes des méthodes d'analyse de données multivariées	142
8.3	Algorithmes des méthodes d'analyse de données multivariées	143
9.1	Modèle linéaire généralisée	146

Liste des tableaux

1	Pistes pour organiser votre semestre	3
1.1	Coefficient en pourcent des questions de cours	40
1.2	Coefficient en pourcent du code rendu	40
1.3	Bonus (en points)	41

Table des matières

I	Pour commencer avec de bonnes bases...	5
1	Présentation du contenu du cours et mise en route	7
	Objectifs de la séance	7
1.1	Présentation des objectifs pédagogiques	7
1.1.1	Règles générales du fonctionnement du cours	7
1.1.2	Calendriers	9
	SCT – Niveau 1	9
	ACA – Niveau 1	9
	GéoSUDS – Niveau 1	10
	GEOINT – Niveau 2	10
	EnviTERR – Niveau 2	11
1.1.3	Niveaux	11
1.1.4	Introduction générale à l’analyse des données	12
	Objectifs à atteindre	12
	Les données en géographie	13
	La géographie à l’ère des humanités numériques	16
	La géographie et les mathématiques, entre rapprochement et éloignement	16
1.1.5	Aperçu des métiers	19
1.1.6	Évaluation	37
	Règles générales	37
	Règles concernant le serveur Discord	38
	Codes Python	38
	Rapport d’activité	38
	La forme	38
	Le fond	38
	Points bonus	39
	Résumé des barèmes	40
	Remarque	40
1.2	Prise en main de GitHub	41
1.2.1	Remarques générales	41
1.2.2	Prise en main pas à pas	44
1.2.3	Copier et maintenir un dépôt distant qui ne vous appartient pas	52

1.2.4	Avertissements	53
1.3	Prise en main de Docker	54
1.4	Établissement d'une architecture propre	58
1.5	Prise en main de Python avec Visual Studio Code et Docker	60
1.6	Découverte de Python	68
1.6.1	Objectifs à atteindre	73
1.6.2	Syntaxe de base	74
1.6.3	Éléments d'algorithmique	74
	Les variables	74
	Les opérateurs	75
	Les instructions	75
	Les conditions	76
	Les boucles	76
	Les boucles conditionnelles	77
	Les fonctions et les procédures	77
	Les objets	78
	Conclusion	81
	Conseils pour bien apprendre : la méthode des 4C (Nathan Dupin, développeur)	81
	Personne n'apprendra de la même manière	82
	Conseils pour bien travailler chez vous	87
	Liens des logiciels Git et Docker (Windows)	87
	Rendre visible les dossiers cachés et les extensions de fichier (Windows)	87
	Installer Python sous Windows sans passer par Docker (Windows)	88
	Installer Python sous UNIX sans passer par Docker (Mac O/S ou Linux)	89
	Nettoyer Docker	89
	Méthodologie générale de chaque séance	94
	Que faire en arrivant en cours ? (environ 10 min)	94
	Que faire pendant le cours ? (environ 1h45min)	94
	Que faire en quittant le cours ? (environ 5 min)	94
	Que faire entre les séances de cours ?	94
	Peut-on utiliser l'intelligence artificielle ?	95
2	Principes généraux de la statistique et paramètres statistiques élémentaires	101
	Objectifs de la séance	101
	Ressources GitHub à lire avant la séance	101
	Exercice du jour	102
	Questions de cours	106
	Mise en œuvre avec Python	107
	Approfondissement	107

II Statistique univariée 109

3 Distributions statistiques 111

Objectifs de la séance	111
Ressources GitHub à lire avant la séance	111
Exercice du jour	111
Questions de cours	111
Mise en œuvre avec Python	115
Approfondissement	115

4 Statistiques inférentielles 117

Objectifs de la séance	117
Ressources GitHub à lire avant la séance	117
Exercice du jour	117
Questions de cours	117
Mise en œuvre avec Python	125
Approfondissement	125

5 Statistique d'ordre des variables qualitatives 127

Objectifs de la séance	127
Ressources GitHub à lire avant la séance	127
Exercice du jour	127
Questions de cours	127
Mise en œuvre avec Python	128
Approfondissement	128

III Statistique bivariée 129

6 Régression et corrélation statistique 131

Objectifs de la séance	131
Ressources GitHub à lire avant la séance	131
Exercice du jour	131
Questions de cours	131
Mise en œuvre avec Python	133
Approfondissement	133

7 Relations entre deux variables 135

Objectifs de la séance	135
Ressources GitHub à lire avant la séance	135
Exercice du jour	135
Questions de cours	135
Mise en œuvre avec Python	136
Approfondissement	136

IV	Statistique multivariée	137
8	Analyses multivariées : les méthodes descriptives	139
	Objectifs de la séance	139
	Ressources GitHub à lire avant la séance	139
	Exercice du jour	139
	Questions de cours	139
	Mise en œuvre avec Python	140
	Approfondissement	140
9	Analyses multivariées : les méthodes explicatives	145
	Objectifs de la séance	145
	Ressources GitHub à lire avant la séance	145
	Exercice du jour	145
	Questions de cours	145
	Mise en œuvre avec Python	146
	Approfondissement	146
V	Bonus	147
10	Séance Bonus : télécharger des données à partir d'un A.P.I.	149
	Objectifs de la séance	149
	Ressources GitHub à lire avant la séance	149
	Manipulations	149
	Bonus	151
	Approfondissement	151
	Bibliographie	153