

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Exercices SCT – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

22 septembre 2026

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 2. Les principes généraux de la statistique
Les paramètres statistiques élémentaires
Exercices SCT – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

La partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler un fichier C.S.V.
- Faire des sorties graphiques
- Utiliser les bibliothèques `Pandas` (données) et `Matplotlib` (graphiques)
N.B. `pd` et `plt` sont des alias qui remplacent respectivement `pandas` et `matplotlib.pyplot`.
- Calculer des effectifs
- Calculer des fréquences
- Faire des graphiques (diagrammes en bâton et circulaires, et histogrammes)
- Découvrir les méthodes de `Pandas` permettant de calculer les paramètres d'une série statistique
- Tracer une boîte de dispersion

2 Manipulations

1. Dans le dossier `src`, créer un dossier `data` et y introduire le fichier `happycntry.csv` disponible dans la Seance-02 du GitHub
2. Dans le dossier `src`, introduire le fichier `main.py` de la séance disponible dans la Seance-02 du GitHub
3. Ouvrir le fichier `main.py` dans votre éditeur de code (Notepad++ ou VS Code)
4. Repérer l’instruction `with`. Elle permet par l’intermédiaire d’une variable appelée `fichier` de lire le fichier C.S.V. grâce à la méthode `read_csv(...)` de la bibliothèque `Pandas`.
N.B. Bien que `Pandas` puisse lire les fichiers `Excel`, il faut vous habituer à utiliser des formats textuels comme le format C.S.V.
5. Afficher sur le terminal exécutant le conteneur la variable `contenu` avec la méthode de `Pandas DataFrame(...)`
6. Calculer avec la fonction native `len(...)` le nombre de lignes et de colonnes du tableau de données et les afficher sur le terminal
7. Afficher sur le terminal le nom des colonnes, c’est-à-dire la première ligne avec la méthode `Pandas head()`
8. Faire le point sur la nature statistique des variables en utilisant le lien vers les métadonnées fourni en commentaire. Faire une liste sur le type de chaque colonne (`int`, `float`, `str` ou `bool`).
9. À l’aide du nom des colonnes affiché, sélectionner `Extremely unhappy`, 1, 2, 3, 4, 5, 6, 7, 8, 9 et `Extremely happy`
10. En utilisant les méthodes `Pandas sum(...)` et `iloc[...]`, calculer les effectifs de chaque ligne et les placer dans une liste (à l’aide d’une boucle). Afficher le résultat sur le terminal.

Indice. Utiliser la méthode native `append(...)`

11. À l’aide de `Matplotlib` et d’une boucle, créer les graphiques suivants.
 - a. Créer un sous-dossier `img` dans le dossier `src`.
 - b. Faire un diagramme circulaire pour chaque territoire. Sauvegarder les images créées dans le dossier `img`.
 - c. Appliquer la méthode `Pandas transpose()` au tableau de données initial. Vous venez d’échanger les lignes avec les colonnes, et les colonnes avec les lignes. Si vous ne comprenez pas, visualiser le nouveau tableau. Vous venez de créer, ce que l’on appelle en calcul matriciel, la transposée du tableau initial. À partir du tableau transposé, réaliser un diagramme en bâtons pour chaque échelle de bonheur. Sauvegarder les images créées dans le dossier `img`.

Attention ! Le diagramme en bâtons va nécessiter de transformer un peu vos données. Reportez-vous au lien suivant :

<https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.plot.bar.html#pandas.DataFrame.plot.bar>.

N.B. 1. Vous allez créer de nombreux fichiers. Créer un nouveau sous-dossier pour stocker vos images.

N.B. 2. Privilégier le format `*.png`, qui est un format léger non propriétaire

12. Dans le tableau initial **et** dans le tableau transposé, à l'aide de la boucle, calculer sous la forme d'une liste :

- les moyennes de chaque colonne avec la bonne méthode de `Pandas` ;
- les médianes de chaque colonne avec la bonne méthode de `Pandas` ;
- les modes de chaque colonne avec la bonne méthode de `Pandas` ;
- l'écart type de chaque colonne avec la bonne méthode de `Pandas` ;
- l'écart absolu à la moyenne de chaque colonne avec la bonne méthode de `Pandas` ;
- l'étendue de chaque colonne.

N.B. 1. Ne pas faire de calculs avec les colonnes (ou lignes) `"code_ISO"` et `"country"`. Il faut réaliser une condition excluant l'application des calculs demandés.

N.B. 1. Utiliser la méthode de la valeur absolue `abs()` disponible dans `Numpy`

N.B. 2. Utiliser les méthodes `min()` et `max()` disponibles dans `Pandas`

En utilisant la méthode `round()` de `Pandas`, arrondir tous les paramètres à deux décimaux.

13. Afficher la liste des paramètres sur le terminal

14. En utilisant le tableau initial **et** en utilisant le tableau transposé, calculer les distances interquartile et interdécile de chaque colonne quantitative avec la méthode `quantile()` dans `Pandas` ?

N.B. 1 Vous pouvez utiliser la boucle précédente pour calculer les deux distances interquartiles.

N.B. 2 `round()` pourra vous déclencher une erreur. Pour la résoudre, il faudra utiliser la fonction native `round()`, au lieu de la méthode `Pandas round()`. C'est subtil. N'hésitez à poser des questions.

15. En utilisant le tableau transposé, à l'aide de `Matplotlib` et d'une boucle, faire des boîtes à moustache de chaque colonne quantitative. Stocker les résultats dans un dossier `img`.

Attention! Vous devez nommer les fichiers avec d'autres noms que ceux des diagrammes circulaires et en bâtons créés précédemment.

16. En utilisant le tableau initial, pour chaque colonne, écrire un algorithme pour catégoriser et dénombrer le nombre de taux ayant une valeur comprise :

- entre 0 et 5 % ou `]0, 5]` ;
- entre 5 et 10 % ou `]5, 10]` ;
- entre 10 et 15 % ou `]10, 15]` ;

- entre 15 et 20 % ou $]15, 20]$;
- entre 20 et 25 % ou $]20, 25]$;
- entre 25 et 30 % ou $]25, 30]$;
- entre 30 et 35 % ou $]30, 35]$;
- entre 35 et 40 % ou $]35, 40]$;
- entre 40 et 45 % ou $]40, 45]$.

Vous concevrez un organigramme pour expliquer votre solution. L'objectif de cette dernière question est d'apprendre à catégoriser des variables quantitatives.

Je rappelle la différence entre un diagramme en bâtons et un histogramme. Le premier sert à représenter des données, le second, à représenter une distribution statistique. Cela signifie sur la totalité des surfaces des rectangles vaut 1 (cf. cours sur les distributions).

3 Bonus

Dans des dossiers `csv` et `xlsx`, sortir les listes calculées avec la bonne méthode `Pandas` au format `C.S.V.` et `Excel`. N'oubliez pas de titrer les colonnes et les lignes de vos sorties si nécessaire.

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 3. Les distributions statistiques

Exercices SCT – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

13 septembre 2026

1 Objectifs

- Savoir afficher une distribution statistique. Ce savoir est utilisé pour comparer une distribution observée avec une distribution théorique.

1.1 Manipulations

1. Utiliser des méthodes `scipy.stats` ou écrire une fonction (informatique) qui vous permettra de visualiser et d'enregistrer dans un dossier `img` :
 - les distributions statistiques de variables discrètes suivantes :
 - la loi de Dirac ;
 - la loi uniforme discrète ;
 - la loi binomiale ;
 - la loi de Poisson ;
 - la loi de Zipf-Mandelbrot.
 - les distributions statistiques de variables continues suivantes :
 - la loi de Poisson ;
 - la loi normale ;

- la loi log-normale ;
- la loi uniforme ;
- la loi du χ^2 ;
- la loi de Pareto.

2. Faire des fonctions (informatiques) pour calculer la moyenne et l'écart type des distributions précédentes.

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 4. Les statistiques inférentielles

Exercices SCT – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

14 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler harmonieusement les fonctions natives avec les méthodes `Pandas`
- Comprendre les trois théories permettant de valider un résultat en analyse de données

2 Manipulations

N.B. Il est très compliqué de trouver des données « réelles ». La plupart d'entre elles ne sont pas publiées. Il faut vous approprier les trois méthodes pour bien comprendre leur intérêt. De fait, les données utilisées sont obtenues par simulation aléatoire. Comme vous l'avez lu dans le topo de la séance, les méthodes sont quasiment infinies.

1. Théorie de l'échantillonnage

Problème à résoudre. Vous réalisez une enquête d'opinion. On suppose que la population mère est composée de 2 185 individus. Si vous leur posez une question quelconque, nécessitant une opinion tranchant de type : « Pour », « Contre » ou « Sans opinion ». On suppose que, pour la population mère, il existe 852 personnes « Pour », 911 personnes « Contre » et 422 personnes « Sans opinion ».

Exercice simulant une situation réelle. Vous n’avez pas accès à la totalité de l’information précédente. Ici, on parle de 2 185 individus, mais imaginez que votre population soit celle de la France entière ou du monde. Vous n’avez pas accès à ce que pense tout le monde. Il faut de fait l’échantillonner. Avec des outils de simulation, il est facile de générer 100 échantillons. aléatoires.

- Dans le dossier `src`, introduire le dossier `data` le fichier `Echantillonnage-100-Echantillons.csv` disponible dans la Seance-04 du GitHub
- Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l’adresse et le nom du fichier. Le fichier contient le résultat d’un tirage au hasard sans remise dans la population initiale de 100 échantillons. Sur chaque ligne, il est compté le nombre d’individus ayant telle ou telle opinion.
- Pour chaque colonne, calculer la moyenne obtenue. Le nombre de personnes devant être entier, il faut arrondir votre calcul avec aucune décimale en respectant la règle de l’arrondi avec la fonction native `round()`.
- Pour comparer l’échantillon avec sa population mère, il faut calculer les fréquences. Pour ce, calculer la somme des trois moyennes obtenues, puis diviser ce résultat à l’ensemble de vos moyennes. Calculer également suivant le même principe les fréquences de la population mère afin de comparer les deux résultats. Arrondir les fréquences obtenues à deux décimales.
- Vous devez constater un écart entre les valeurs observées en moyennant les échantillons et les valeurs réelles de la population mère. Calculer l’intervalle de fluctuation de chacune des fréquences à un seuil de 95 %, soit $z_C = 1,96$.
- Dans votre rapport, expliquer le lien entre l’intervalle de fluctuation et les valeurs réelles de la population mère. Que pouvez-vous en conclure par rapport aux échantillons utilisés pour le calcul ?

2. Théorie de l’estimation

Problème à résoudre. Dans le cas d’espèce, et c’est un des cas les plus fréquents en sciences humaines et sociales, on ne possède qu’un échantillon de la population mère. Comment avoir confiance en lui ? Ici, la méthode consiste à construire des intervalles de confiance.

- Prendre le premier échantillon de la liste précédente en utilisant la méthode `Pandas.iloc(0)`, le paramètre 0 correspondant à votre première ligne de données. Il faudra utiliser des fonctions natives, donc convertissez l’objet `Pandas` en castant une `list()`.
- Calculer la somme de la ligne, puis comme avec le cas précédent, les fréquences en utilisant l’effectif total de l’échantillon isolé.
- L’intervalle de confiance ne dépend que de la taille de l’échantillon, c’est-à-dire la somme précédente. Calculez cet intervalle pour chaque opinion.

- Dans votre rapport, vous interpréterez le résultat obtenu et vous le comparerez avec le résultat précédent.

N.B. N'hésitez pas à comparer le résultat avec plusieurs lignes de l'échantillon afin de valider votre jugement.

3. Théorie de la décision

Problème à résoudre. Intervalles de fluctuation ou intervalles de confiance peuvent être insuffisants pour valider un résultat. En fonction de la nature des variables (quantitatives ou qualitatives), les statisticiens ont inventé et inventent encore de nombreux tests statistiques. Le test de Shapiro-Wilks permet de tester si une distribution suit la loi normale.

- Vous disposez de deux fichiers `Loi-normale-Test-1.csv` et `Loi-normale-Test-2.csv`. Il s'agit d'une série de nombres aléatoires traduisant une distribution statistique. En utilisant la méthode de `scipy.stats.shapiro()`. Laquelle est une distribution normale ?
- Vous expliquerez dans votre rapport pourquoi.

N.B. Il vous faudra essentiellement connaître les types de tests en fonction des situations.

2.1 Bonus

Lors du test de la décision, l'une des lois n'est pas normale. En vous aidant de la séance précédente, quelle est sa distribution ?

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 5. La statistique d'ordre des variables qualitatives

Exercices SCT – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

22 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Manipuler des fonctions locales et comprendre la nécessité de factoriser son code en une liste de fonctions ou de procédures exécutant une tâche unique
- Créer des fonctions locales spécifiques au traitement d'un problème
- Comprendre l'analyse de variables qualitatives ordinales

2 Manipulations

1. Dans le dossier `src`, introduire le dossier `data` le fichier `Nombre-moyen-d-enfants-par-femme-par-territoire.csv` disponible dans la `Seance-05` du `GitHub`. Le taux de fertilité total représente le nombre d'enfants nés d'une femme si elle vivait jusqu'à la fin de sa période de fécondité et donnait naissance à des enfants conformément aux taux de fertilité actuels propres à chaque tranche d'âge. Les données sont issues de la base de données de la Banque mondiale <https://donnees.banquemondiale.org/indicateur?tab=all> (`SP.DYN.TFRT.IN`).

2. Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l'adresse et le nom du fichier.
3. Isoler la colonne 2024
4. Ordonner la liste obtenue avec la fonction locale `ordreDecroissant()` proposée. Elle prend en paramètre une liste.
5. Visualiser la loi rang-taille en créant une image de sortie.
6. Pour obtenir une droite, il vous faut convertir les axes en logarithme. Pour ce, utiliser la fonction locale `conversionLog()` proposée. Elle prend en paramètre une liste.
7. Est-il possible de faire un test sur les rangs ? (mettre votre réponse sous la forme d'un commentaire dans le fichier)
8. Dans le dossier `src`, introduire le dossier `data` le fichier `Le-Monde-HS-Etats-du-monde-2007-2026.csv` disponible dans la Seance-05 du GitHub
9. Ouvrir le fichier en utilisant la fonction locale `ouvrirUnFichier()`. Elle prend en paramètre une chaîne de caractères matérialisant l'adresse et le nom du fichier.
10. Isoler les colonnes « État », « Pop 2007 », « Pop 2026 », « Densité 2007 » et « Densité 2026 »
11. En utilisant la fonction locale `ordrePopulation()`, ordonner de manière décroissante les listes « Pop 2007 », « Pop 2026 », « Densité 2007 » et « Densité 2026 ». Elle prend en paramètres la liste à ordonner et la liste des États.
12. En utilisant la fonction locale `classementPays()`, préparer la comparaison des listes sur la population et la densité. Elle prend en paramètres les deux classements (pour le nombre d'habitants et pour la densité) obtenus avec `ordrePopulation()`. En classant le résultat avec la méthode `sort()`, vous obtenez une liste avec deux colonnes ordonnées par rapport au classement de 2007.
13. Isoler les deux colonnes sous la forme de liste différents en utilisant une boucle
14. Dans la bibliothèque `scipy.stat`, utiliser les méthodes `spearmanr()` et `kendalltau()` pour calculer le coefficient de corrélation des rangs et la concordance des rangs. Les deux méthodes prennent en paramètres les deux classements que vous avez respectivement calculés pour le nombre d'habitants et pour la densité. Vous commenterez ce résultat dans votre rapport d'activité.

2.1 Bonus

Afin de vous faciliter la vie, car les codes n'étaient pas simples à trouver, vous avez utiliser des fonctions que j'ai créées. C'est l'un des bonus qui peut vous rapporter le plus de points. Vous devrez créer des fonctions locales permettant de calculer rapidement une analyse de rangs.

Pour la fertilité, proposer un algorithme et un code pour comparer le classement obtenu avec le classement des autres années en utilisant le coefficient de corrélation et la concordance des rangs.

Pour la population mondiale, 1. factoriser le code d'analyse des classements sous la forme d'une fonction renvoyant les coefficients de corrélation des rangs et la concordance des rangs ;
2. faire un algorithme et un code permettant d'analyser la concordance des rangs de l'ensemble des classements annuels de 2007 à 2026.

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 6. Régression et corrélation statistique de deux variables

Exercices SCT – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

22 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Apprendre à gérer les données censurées
- Manipulation des outils de la régression et de la corrélation simple

2 Manipulations

Existe-il un lien entre le revenu brut disponible¹ et le pouvoir d'achat² par unité de consommation³ (U.C.) ? L'évolution du pouvoir d'achat est déflatée à l'aide de l'indice du prix de la dépense de consommation finale des ménages. Les données expriment l'évolution des deux indicateurs en pourcentage par rapport à l'année précédente. Cela se lit, pour 2025,

1. revenus dont disposent les ménages pour consommer ou pour investir après les opérations de redistribution

2. volume de biens et de services qu'un revenu permet d'acheter

3. 1 UC équivaut au premier adulte du ménage, $\frac{1}{2}$ UC équivaut aux personnes ayant un âge supérieur ou égal à 14 ans, et $\frac{1}{3}$ UC équivaut à une personne ayant un âge strictement inférieur à 14 ans

« En 2025, le pouvoir d'achat du revenu disponible brut diminue de 0,4 % par rapport à 2024. Ramené à une unité de consommation, il diminue de 0,7 %. ».

Le fichier `Revenu-vs-pouvoir.csv` est extrait de l'Institut national de la statistique et des études économiques (I.N.S.E.E.) ayant pour référence les comptes annuels selon la base de 2020.

— <https://www.insee.fr/fr/statistiques/2830244>

1. Sélectionner en utilisant `Pandas` les colonnes `Pouvoir_d_achat_par_unite_de_consommation` et `Pouvoir_d_achat_du_revenu_disponible_brut` dans le fichier `Revenu-vs-pouvoir.csv`.
2. On considère que la variable explicative est le revenu brut disponible et la variable à expliquer est l'unité de consommation. Calculer une régression linéaire simple entre les deux colonnes avec la méthode `scipy.stats.linregress(x, y)` prenant en arguments `x`, la variable à expliquer, et `y`, la variable explicative. Faire la même opération en inversant les deux variables.
3. Calculer la corrélation simple entre les deux colonnes de chaque régression obtenue. Vous pouvez utiliser indifféremment les bibliothèques `Pandas` ou `Scipy`.
4. Faire deux graphiques de synthèse permettant de visualiser chaque droite de régression obtenue et les enregistrer dans un dossier `img`.
5. Dans votre rapport, vous commenterez votre résultat sous la forme d'un ou deux paragraphes.

3 Bonus

À partir du fichier `Bonus-Revenu.csv`, essayez d'établir les régressions existantes entre les différentes lignes. L'unité est l'évolution par rapport à l'année précédente en pourcentage.

Cours d'analyse de données en géographie

Niveau Master 1 - GEANDO

Séance 7. Étude de deux variables qualitatives

Exercices SCT – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

15 septembre 2026

1 Objectifs

- Manipuler des variables qualitatives avec `Python`
- Calculer les principaux indicateurs de liaison avec la bibliothèque `scipy.stats`

2 Manipulations

Vous allez utiliser les données 2024 de l'Institut national de la statistique et des études économiques (I.N.S.E.E.) concernant la relation entre catégorie socioprofessionnelles et le sexe biologique https://www.insee.fr/fr/statistiques/2381478#figure1_radio2. J'ai simplifié le tableau initial. Si vous avez compris le cours, vous avez compris qu'il s'agit d'un tableau de contingence avec deux variables qualitatives. Normalement, vous le calculerez un tableau croisé dynamique avec la méthode de la bibliothèque `Pandas`, `crosstab()`. Toutefois, il arrive souvent, comme dans le cas présent, que le tableau de contingence n'ait pas à être calculé. De fait, on ne peut pas utiliser les méthodes de `Pandas` directement, notamment pour calculer les marges.

Après avoir chargé les données contenues dans le fichier `Socioprofessionnelle-vs-sexe.csv`, appliquer la fonction locale `tableauDeContingence(..., ...)` qui prend deux paramètres : la colonne de référence, ici, celle des régions, et un dictionnaire contenant le nom des autres colonnes et leurs données.

1. Calculer les marges des lignes et des colonnes en vous servant des fonctions locales `sommeDesColonnes()` et `sommeDesLignes()`.
2. Faire une condition vérifiant si le total des marges des lignes et le total des marges des colonnes est identique.
3. Faire un test d'indépendance du χ^2 à partir de la bibliothèque `scipy.stats` et de sa méthode `chi2_contingency()`. Existe-t-il une liaison?
4. Calculer l'intensité de liaison ϕ^2 de Pearson à partir des résultats précédents.
5. Dans votre rapport, faire un court paragraphe expliquant vos résultats.

3 Bonus

Les points bonus sont attribués par rapport aux chapitres d'approfondissement.

Avec le fichier `Echantillonnage-100-Echantillons.csv`, faire une analyse ANOVA.

Avec le tableau de données, calculer une A.F.C. et faisant le commentaire.