

Cours d'analyse de données en géographie
Niveau Master 1 - GEANDO
Séance 8. Les méthodes statistiques multivariées
descriptives
Exercices GéoINT – Python

Maxime Forriez^{1,2,a,b}

¹ Sorbonne université, 2, rue Francis de Croisset, 75 018 Paris

² Institut de géographie, 191, rue Saint-Jacques, Bureau 105, 75 005 Paris,

^amaxime.forriez@sorbonne-universite.fr

^bmforriez.sorbonne.universite@gmail.com

29 septembre 2026

La sous-partie « Bonus » vous permet d'obtenir des points supplémentaires.

1 Objectifs

- Apprendre à utiliser la bibliothèque `Scikit-learn`
- Apprendre à utiliser la bibliothèque `Prince`

2 Manipulations

1. Faire une A.C.P. avec le fichier `SIPRI-1949-2025.csv`. Il regroupe toutes les dépenses militaires de 173 États de 1949 à 2025.
 - a. Récupérer les données.
 - b. Isoler la colonne des individus "Code ISO" et isoler les colonnes numériques en utilisant la méthode `drop(columns = ["Code ISO"])`. Répéter la méthode pour les colonnes `Country`, `État` et `Continent`.
 - c. Centrer-réduire les données numériques en utilisant `StandardScaler()` et `fit_transform()`.

Attention ! Il faut filtrer les valeurs NaN en les remplaçant par zéro, sinon vous aurez une erreur.

- d. Faire une A.C.P. avec 77 facteurs sur les données numériques centrées-réduites avec l'objet PCA et sa méthode `fit()`. L'afficher sur la console. Que constatez-vous ?

Attention ! Pour nommer les 77 colonnes des facteurs, il faudra créer une liste en utilisant une boucle.

- e. Afficher la variance expliquée, la variance expliquée en pourcentage et calculer les valeurs propres.
- f. En utilisant Pandas et sa méthode `DataFrame`, afficher le résultat de l'A.C.P.
- g. Calculer les coordonnées des individus et faire un graphique permettant de créer l'image du *mapping* des individus (les deux premiers facteurs) dans un dossier `img`.
- h. Calculer et afficher la contribution des individus aux facteurs. Calculer et afficher la qualité de la projection des individus (les cosinus carrés). Qu'en concluez-vous ?

Attention ! Comme précédemment, pour nommer les 77 colonnes des contributions des individus et de la qualité de projection des individus, il faudra créer une liste pour chacun en utilisant une boucle.

- i. Calculer les coordonnées des variables et créer l'image du cercle de corrélation associé dans un dossier `img`.

N.B. Pour créer le cercle, il n'est pas nécessaire de calculer les corrélations des 77 colonnes. Toutefois, si vous le souhaitez, vous pouvez le faire.

N.B. Vous pouvez vous aider du site <https://fxjollois.github.io/cours-2019-2020/lp-iot-python-ds/seance2-ACP-classif.html>.

2. Faire une A.C.M. avec le fichier `chiens.csv`.

- a. Récupérer les données.
- b. Isoler la colonne `Race` (les individus) et isoler dans un tableau Pandas les colonnes `Taille`, `Poids`, `Vitesse`, `Intelligence`, `Affection`, `Agressivité`, `Fonction`, `Origine` (les variables).
- c. Transformer le tableau des variables en tableau disjonctif complet (T.D.C.) en utilisant la méthode Pandas `get_dummies()`
- d. L'A.C.M. se calcule avec la bibliothèque `Prince` à partir du T.D.C. calculé par Pandas et dans ce format avec les méthodes MCA et `fit()`. Calculer une A.C.M. à huit facteurs.
- e. Calculer les valeurs propres.
- f. Calculer les coordonnées des lignes et des colonnes des variables.
- g. Créer une image du *mapping* des deux premiers facteurs dans un dossier `img`.
- h. Calculer les qualités des données des lignes et des colonnes (les cosinus carrés).

3 Bonus

Faire une C.A.H. à partir des résultats de l'A.C.P. étudiée.

Attention ! Il faudra vous documenter au-delà de la documentation fournie par le `GitHub`.